



universität
wien

BACHELORARBEIT

“Crime Hot Spot Mapping -
Methodenvergleich und praktischer Versuch in ArcGIS Pro”

Verfasst von

Luis Lion Luca Fink

angestrebter akademischer Grad
Bachelor of Science (B.Sc.)

Wien, April 2024

Studienkennzahl lt. Studienblatt: UA 033 655
Studienrichtung lt. Studienblatt: Bachelorstudium Geographie
Schwerpunktsetzung: Kartographie und Geoinformation
Betreuung: Ass.-Prof. Mag. Dr. Andreas Riedl
Matrikelnummer: 12018892

Inhaltsverzeichnis

Abbildungsverzeichnis.....	
Formelverzeichnis.....	
Abkürzungsverzeichnis.....	
Abstract.....	
1. Einleitung.....	1
2. Methodik.....	3
3. Theoretischer Rahmen.....	4
3.1 Wie lässt sich Kriminalität definieren?.....	4
3.2 Crime Mapping – Was ist das?.....	5
3.2.1 GIS als Werkzeug.....	5
3.3 Historische Entwicklung des Crime Mapping.....	6
3.3.1 Chicagoer Schule.....	6
3.3.2 Computergestütztes Crime Mapping.....	7
3.4 Grundlegendes Konzept des Predictive Policing.....	9
3.4.1 Das Raumbezogene Verfahren.....	10
4. Die Analyse von Hot Spots.....	13
4.1 Definition von Hot Spots.....	13
4.2 Die Strategie des Hot-Spot-Policing.....	15
4.2.1 Die drei Perspektiven des Hot-Spot-Policing.....	16
4.3 Leitende Theorien und geeignete Kartierungssymbole.....	17
4.3.1 Theorien auf Ortsebene (Punkte).....	17
4.3.2 Theorien auf Straßenebene (Linien).....	19
4.3.3 Theorien auf Nachbarschaftsebene (zweidimensionale Formen).....	20
5. Methoden im Crime-Hot-Spot-Mapping.....	23
5.1 Hot-Spot-Ermittlung mithilfe thematischer Kartierung.....	24
5.2 Hot-Spot-Ermittlung durch Clustering.....	26
5.2.1 Spatial and Temporal Analysis of Crime (STAC).....	26
5.2.2 Nearest Neighbor Hierarchical Clustering (NNH).....	28
5.3 Hot-Spot-Ermittlung durch Kernel Density Estimation (KDE).....	31
5.4 Hot-Spot-Ermittlung mithilfe statistischer Analysen räumlicher Beziehungen.....	36
5.4.1 Nearest Neighbor Index (NNI).....	36

5.4.2 Local Indicator of Spatial Association (LISA).....	39
5.4.2.1 Anselin's Local Moran Ii.....	40
5.4.2.2 Getis-Ord Local Gi.....	46
6. Prediction Accuracy Index (PAI).....	49
7. Praktischer Versuch in ArcGIS Pro.....	51
7.1 Wahl des Untersuchungsgebiets.....	51
7.2 Datenerhebung und Datenaufbereitung.....	52
7.3 Erstellung der Hot Spot Karten.....	54
7.3.1 Thematische Kartierung im Raster.....	54
7.3.2 Kernel Density Estimation (KDE).....	59
7.3.3 Getis-Ord Local Gi-Statistik.....	63
7.4 Berechnung des Prediction Accuracy Index (PAI).....	68
7.4.1 Ermittlung der Hot-Spot-Parameter.....	68
7.4.2 Berechnung des PAI mithilfe der ermittelten Parameterwerte.....	72
8. Diskussion.....	74
8.1 Bewertung der untersuchten Methoden.....	74
8.2 Auswertung des praktischen Versuchs.....	77
8.3 Allgemeine Bewertung von Hot-Spot-Mapping und -Policing.....	79
9. Fazit und Ausblick.....	81
10. Literaturverzeichnis.....	83
11. Eidesstattliche Erklärung.....	90

Abbildungsverzeichnis

Abb. 1: Punkte (A) (Eigene Darstellung, basierend auf Eck, 2005, S. 12).....	18
Abb. 2: Linien (B) (Eigene Darstellung, basierend auf Eck, 2005, S. 12).....	19
Abb. 3: Choroplethen (C) (Eigene Darstellung, basierend auf Eck, 2005, S. 12).....	20
Abb. 4: Isolinien (D) (Eigene Darstellung, basierend auf Eck, 2005, S. 12).....	21
Abb. 5: Hot-Spot-Ermittlung anhand einer Punktkarte (Chainey, 2005, S. 21).....	23
Abb. 6: Bsp. einer thematischen Kartierung von Grenzgebieten (Chainey, 2005, S. 24).....	24
Abb. 7: Bsp. einer thematischen Kartierung im Raster (250 m ²) (Chainey, 2005, S. 25).....	25
Abb. 8: STAC: Berechnete Standardabweichungsellipsen (B) (Block, 1995, S. 9).....	27
Abb. 9: STAC: Standardabweichungsellipsen und konvexe Hüllen (Levine, 2004, S. 512)...	28
Abb. 10: NNH: Clusteringroutine in drei Schritten (Kundakci, 2014, S. 17).....	29
Abb. 11: NNH: Clustern erster und zweiter Ordnung (Levine, 2004, S. 509).....	30
Abb. 12: KDE: Oberflächenkarte und Konturenkarte (Levine, 2004, S. 675).....	31
Abb. 13: KDE: Anfängliche Dichteschätzung eines Histogramms (Levine, 2004, S. 657)....	32
Abb. 14: KDE: Dichteschätzung anhand von 5 Beispieldatenpunkten (Levine, 2004, S. 659).....	33
Abb. 15: KDE: Schmale und breite Bandbreite (Levine, 2004, S. 660, 661).....	33
Abb. 16: KDE: Fünf Typen von Kernelfunktionen (Levine, 2004, S. 663).....	34
Abb. 17: KDE: Normalverteilung anhand von 4 Beispieldatenpunkten (Levine, 2004, S. 667)....	35
Abb. 18: KDE: Bsp. einer Hot-Spot-Dichtekarte (Chainey, 2005, S. 28).....	35
Abb. 19: NNI: Bsp. einer Ergebnistabelle (Chainey, 2005, S. 18).....	39
Abb. 20: Local Moran II: Verhältnis von p-Wert und Z-Score (Was ist ein Z-Wert? Was ist ein p-Wert? - ArcGIS Pro, o. D.).....	44
Abb. 21: Local Moran II: Beispielkarte (Levine, 2004, S. 612).....	45
Abb. 22: Local Moran II: Bsp. Referenzkarte (Levine, 2004, S. 611).....	45
Abb. 23: Local Gi: Beispielkarte (Levine, 2004, S. 621).....	48
Abb. 24: Punktkarte: Darstellung der Schusswaffenereignisse (ArcGIS Pro).....	53
Abb. 25: Rasterkarte: Create Fishnet Tool (ArcGIS Pro).....	54
Abb. 26: Rasterkarte: Calculate Field Funktion (ArcGIS Pro).....	55
Abb. 27: Rasterkarte: Spatial Join Tool (ArcGIS Pro).....	56

Abb. 28: Rasterkarte: Summary Statistics Funktion (ArcGIS Pro).....	57
Abb. 29: Rasterkarte: Symbology (ArcGIS Pro).....	57
Abb. 30: Rasterkarte: Hot-Spot-Karte (ArcGIS Pro).....	58
Abb. 31: KDE-Karten: Kernel Density Tool für 0,01° & 0,03° (ArcGIS Pro).....	60
Abb. 32: KDE-Karten: 0,01°-Hot-Spot-Karte (ArcGIS Pro).....	61
Abb. 33: KDE-Karten: 0,03°-Hot-Spot-Karte (ArcGIS Pro).....	62
Abb. 34: Local Gi: Aggregate Points Tools (ArcGIS Pro).....	63
Abb. 35: Local Gi: Incremental Spatial Autocorrelation Tool (ArcGIS Pro).....	65
Abb. 36: Local Gi: Ergebnisgrafik der Incremental Spatial Autocorrelation (ArcGIS Pro)....	65
Abb. 37: Local Gi: Hot Spot Analysis (Getis-Ord Gi*) Tool (ArcGIS Pro).....	66
Abb. 38: Local Gi: Hot-Spot-Karte (ArcGIS Pro).....	67
Abb. 39: PAI: Flächengröße des Untersuchungsgebietes (ArcGIS Pro).....	68
Abb. 40: PAI-Raster: Select By Attributes Funktion (ArcGIS Pro).....	69
Abb. 41: PAI-Raster: Ereignisanzahl & Flächengröße (ArcGIS Pro).....	69
Abb. 42: PAI-Raster: Calculate Geometry Funktion (ArcGIS Pro).....	69
Abb. 43: PAI-KDE: 0,01° Raster Calculator Tool (ArcGIS Pro).....	70
Abb. 44: PAI-KDE: 0,03° Raster Calculator Tool (ArcGIS Pro).....	70
Abb. 45: PAI-KDE: Ereignisanzahl & Flächengröße für 0,01° & 0,03° (ArcGIS Pro).....	71
Abb. 46: PAI-Gi: Select By Attributes Funktion (ArcGIS Pro).....	71
Abb. 47: PAI-Gi: Ereignisanzahl & Flächengröße (ArcGIS Pro).....	72

Formelverzeichnis

Formel 1: Berechnung des erwarteten Abstands der nächsten Nachbarn für NNI (Shariff et al., 2018, S. 148).....	37
Formel 2: Berechnung des Anselin's Local Moran Ii (Ratcliffe, 2010, S. 13).....	40
Formel 3: Berechnung des Z-Scores für den Ii-Wert (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.).....	42
Formel 4: Berechnung des Erwartungswerts von Ii (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.).....	42
Formel 5: Berechnung der Varianz von Ii (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.).....	42
Formel 6: Schätzung der 95% und 99% Konfidenzintervalle für Ii (Levine, 2004, S. 609).....	43
Formel 7: Berechnung des Getis-Ord Local Gi (Manepalli et al., 2011, S.4).....	46
Formel 8: Berechnung des Z-Scores für Gi (Manepalli et al., 2011, S.5).....	47
Formel 9: Berechnung des arithmetischen Mittels und der Standardabweichung für Gi (Li et al., 2017, S.686).....	47
Formel 10: Berechnung des Prediction Accuracy Index (PAI) (Chainey et al., 2008, S. 14).....	49
Formel 11: Berechnung der quartischen Funktion in KDE (Funktionsweise von “Kerndichte” - ArcGIS Pro, o. D.).....	59
Formel 12: Raster: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008).....	72
Formel 13: KDE-0,01°: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008).....	72
Formel 14: KDE-0,03°: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008).....	73
Formel 15: Local Gi: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008).....	73

Abkürzungsverzeichnis

GIS	Geografisches Informationssystem
NNH	Nearest Neighbor Hierarchical Clustering
KDE	Kernel Density Estimation
LISA	Local Indicator of Spatial Association
NNI	Nearest Neighbor Index
PAI	Prediction Accuracy Index
STAC	Spatial and Temporal Analysis of Crime

Abstract

Die vorliegende Bachelorarbeit befasst sich mit dem Konzept des Crime-Hot-Spot-Mapping, mit dem Ziel, die wichtigsten und gängigsten Methoden zur Ermittlung von Hot Spots umfassend zu untersuchen, zu vergleichen und in einem praktischen Versuch anzuwenden. Im Zentrum der Arbeit steht die Frage, inwieweit sich die Methoden hinsichtlich ihrer Genauigkeit, Komplexität und Vorgehensweise unterscheiden und inwiefern sie zur Entwicklung präventiver Strategien in der Verbrechensbekämpfung beitragen. Der Praxisversuch wurde in ArcGIS Pro durchgeführt, indem Hot-Spot-Karten auf Basis realer Kriminalitätsdaten mithilfe von drei konkreten Methoden erstellt und hinsichtlich ihrer Vorhersagegenauigkeit mittels des Prediction Accuracy Index (PAI) bewertet wurden. Die Analyse aus Literaturrecherche und Praxisversuch ergab, dass die verschiedenen Methoden unterschiedliche Stärken und Schwächen aufweisen und dass ein gezielter Einsatz dieser Techniken das Potenzial hat, Polizeiressourcen effizienter einzusetzen, Kriminalitätsraten zu senken und die allgemeine Sicherheit in urbanen Räumen zu erhöhen.

1. Einleitung

In unserem alltäglichen Leben navigieren wir, oft ohne es zu merken, durch eine **unsichtbare** “Landkarte der Sicherheit”. Diese Karte, geprägt von persönlichen Erfahrungen, Medienberichten und Erzählungen, lenkt uns durch unsere Städte und Gemeinden. Sie beeinflusst, in welchen Vierteln wir wohnen, welche Routen wir für unsere täglichen Wege wählen und lässt uns bestimmte Gegenden bevorzugen und andere meiden. An manchen Orten lassen wir unser Auto nicht unbeaufsichtigt stehen und begegnen Fremden mit Vorsicht, an anderen bewegen wir uns gelassen und offen. Hinter diesen alltäglichen Entscheidungen steht die grundlegende Erkenntnis, dass das Risiko, Opfer einer Straftat zu werden, nicht gleichmäßig im Raum verteilt ist (Eck, 2005).

Dieses Verhalten zur eigenen Risikominimierung unterstreicht die Bedeutung eines tieferen Verständnisses für die Verteilung von Kriminalität. Es zeigt auf, wie wichtig es ist, die Muster und Trends hinter der Verteilung von Kriminalität zu verstehen und dieses Wissen zu nutzen, um präventive Maßnahmen zu entwickeln, die die Sicherheit und das Wohlergehen der gesamten Gemeinschaft verbessern.

Crime Mapping, zu Deutsch “Kriminalitätskartierung”, ermöglicht Strafverfolgungsbehörden diese “Landkarte der Sicherheit” **sichtbar** zu machen. Eine *Crime Map* visualisiert dabei die Vorkommnisse von Verbrechen innerhalb eines bestimmten Gebietes und für einen bestimmten Zeitraum. Räumlichen Kriminalanalytiker*innen ist es damit möglich, Orte mit besonders hoher Kriminalitätskonzentration, sogenannte *Hot Spots*, zu identifizieren und bestimmte Trends und Muster in der Kriminalität zu erkennen (Räumliche Kriminalanalyse, o. D.; Wang et al., 2013).

Crime-Hot-Spot-Mapping beschreibt in diesem Kontext die Analyse und Kartierung von Hot Spots und stellt damit eine bestimmte Methode des Crime Mappings dar, die auf historischen Verbrechensdaten basiert. Das wesentliche Ziel für Strafverfolgungsbehörden besteht darin, die Strategie des *Hot-Spot-Policing* anzuwenden, die darauf abzielt, präventive Maßnahmen auf diese Gebiete zu konzentrieren, um polizeiliche Ressourcen zu sparen und die Wahrscheinlichkeit von Straftaten zu verringern (Chainey et al., 2008; White et al., 2023).

Die vorliegende Bachelorarbeit macht es sich zur Aufgabe, das grundlegende Konzept von Crime-Hot-Spot-Mapping ausführlich zu untersuchen, darauf aufbauende polizeiliche Strategien zu analysieren und die wichtigsten Methoden zur Ermittlung von Hot Spots aufzuzeigen, zu vergleichen und in einem praktischen Versuch anzuwenden. Für einen geordneten und strukturierten Forschungsablauf wurden hierfür zu Beginn der Forschungsarbeit drei Arbeitsfragen konzipiert, an denen sich orientiert wurde:

“Inwiefern trägt Crime-Hot-Spot-Mapping zur Entwicklung präventiver Strategien in der Verbrechensbekämpfung bei?”

“Wie unterscheiden sich verschiedene Hot-Spot-Methoden in ihrer Komplexität und Vorgehensweise bei der Ermittlung von Hot Spots?”

“Wie unterscheiden sich verschiedene Hot-Spot-Methoden hinsichtlich ihrer Genauigkeit bei der Ermittlung von Hot Spots?”

Um eine umfassende Analyse mit einer organisierten Struktur zu ermöglichen, wurde die Arbeit in folgende Abschnitte gegliedert: Zunächst wird das methodische Vorgehen erläutert. Anschließend werden die Begriffe Kriminalität und Crime Mapping nach einem allgemeinen Verständnis definiert. Weiter folgt ein Kapitel über die historische Entwicklung von Crime Mapping sowie eine Erläuterung des Grundkonzepts von Predictive Policing. Im Anschluss steht das Kapitel zur Untersuchung von Hot Spots, wobei der zentrale Begriff “Hot Spot”, die Strategie des Hot-Spot-Policing sowie leitende Theorien und geeignete Kartierungssymbole erläutert werden. Daraufhin werden die wichtigsten Hot-Spot-Methoden detailliert und umfassend erklärt und die Berechnung der Vorhersagegenauigkeit von Hot-Spot-Karten mithilfe des Prediction Accuracy Index (PAI) aufgezeigt. Es folgt ein Kapitel über die praktische Umsetzung in ArcGIS Pro, wobei vier Hot-Spot-Karten erstellt wurden und deren Vorhersagegenauigkeit mithilfe des PAI berechnet wurde. Nachfolgend werden die einzelnen Methoden, die Ergebnisse des Praxistests sowie Hot-Spot-Mapping und -Policing im Allgemeinen ausführlich diskutiert. Abschließend folgt eine Zusammenfassung der gewonnenen Erkenntnisse im Hinblick auf die Arbeitsfragen sowie ein Ausblick in die Zukunft.

2. Methodik

Die vorliegende Arbeit gliedert sich in zwei Teile. Für die Beantwortung der Arbeitsfragen und um den Stand der Wissenschaft zum Thema Crime-Hot-Spot-Mapping zu ermitteln, wurde zunächst eine umfassende Literaturrecherche durchgeführt. Hierfür wurden Fachliteratur, Studien und sonstige relevante Quellen gesammelt und anschließend ausgewertet. Begriffe, auf die sich während der Recherche überwiegend fokussiert wurde, waren “Hot-Spot-Mapping”, “Hot-Spot-Policing” und “Predictive Policing” sowie verschiedene relevante Kartierungsmethoden. Die ausgewerteten Informationen wurden strukturiert zusammengefasst, um ein grundlegendes Verständnis über die genannten Begriffe und Methoden zu liefern.

Im zweiten Teil der Arbeit wurden drei der wichtigsten Methoden im Crime-Hot-Spot-Mapping in einem praktischen Vergleich in der Softwareanwendung ArcGIS Pro angewendet. Bei der Auswahl der Methoden wurde versucht, Kartierungsmethoden zu wählen, die sich sowohl in ihrer Komplexität als auch Vorgehensweise bei der Ermittlung von Hot Spots unterschieden, um einen möglichst umfangreichen Vergleich mit einem breiten Spektrum zu ermöglichen. Für den Versuch wurden zunächst Ereignisdaten gesammelt, die im Anschluss in ArcGIS Pro auf Fehler und Unvollständigkeiten geprüft und in einer ersten Referenzkarte dargestellt wurden. Basierend auf diesen Daten wurden vier Hot-Spot-Karten erstellt, wobei für eine der Methoden zwei Karten erstellt wurden, um den Nutzen dieser Methode bestmöglich aufzuzeigen. Im Anschluss konnten die Ergebniskarten mithilfe der Formel des Prediction Accuracy Index (PAI) hinsichtlich ihrer Genauigkeit verglichen werden. Ziel dieses praktischen Versuchs war es, die Stärken und Schwächen der einzelnen Methoden zu identifizieren und den konkreten Ablauf der Hot-Spot-Kartierung in der Praxis darzustellen.

Die analysierten Ergebnisse aus Literaturrecherche und dem praktischen Versuch wurden anschließend im Kontext der Arbeitsfragen diskutiert und interpretiert.

Als Hilfsmittel zur sprachlichen Verfeinerung sowie zur Übersetzung komplexer fremdsprachiger Fachtexte wurde *DeepL* und *LanguageTool* verwendet. Für die korrekte Zitierung von Internetquellen nach APA 7 wurde *Scribbr* verwendet. Diese Angaben dienen der Transparenz der Arbeit.

3. Theoretischer Rahmen

Vor dem Hintergrund dieser Arbeit ist es zu Beginn wichtig, einen theoretischen Rahmen zu schaffen. Hierfür wird zunächst der Begriff “Kriminalität” klar definiert und anschließend aufgezeigt, was unter Crime Mapping, insbesondere in Verbindung mit *Geografischen Informationssystemen* (GIS), im Allgemeinen zu verstehen ist. Daraufhin folgt ein Kapitel über die historische Entwicklung von Crime Mapping sowie ein Kapitel, in dem das Grundkonzept von Predictive Policing erläutert wird.

3.1 Wie lässt sich Kriminalität definieren?

Kriminalität kann sowohl aus einer juristischen als auch nicht-juristischen Perspektive betrachtet werden, wobei beide Definitionen jeweils eigene Verständnisse liefern. Juristisch betrachtet bezieht sich Kriminalität auf Handlungen, die gegen die Strafgesetze verstößen, die innerhalb bestimmter geografischer Gebiete gelten. Diese Gesetze sollen das Leben, das Eigentum und die Rechte der Bürger*innen schützen und decken dabei ein breites Spektrum an Delikten ab, von Vergehen gegen Personen wie Mord und sexuelle Nötigung über Eigentumsdelikte wie Diebstahl und Sachbeschädigung bis hin zu spezifischen Regelverstößen wie Verkehrsdelikte (Ahmadi, 2003).

Aus einer nicht-juristischen Perspektive werden Verbrechen hingegen als Handlungen definiert, die den allgemein moralischen oder ethischen Grundsätzen einer Gesellschaft widersprechen. Diese Grundsätze unterliegen allerdings einem stetigen Wandel, der zur Folge hat, dass sich auch die Auffassungen darüber, was als kriminelles Verhalten gilt, über die Zeit ändern können. So wurden bestimmte Handlungen wie Prostitution, Abtreibung, versuchter Selbstmord und gleichgeschlechtliche sexuelle Beziehungen in einigen Ländern entkriminalisiert, während andere Verhaltensweisen, wie etwa Steuerhinterziehung oder Kreditkartenbetrug im Laufe der Zeit als kriminell eingestuft wurden (Ahmadi, 2003).

Diese Unterscheidung zwischen juristischen und nicht-juristischen Ansätzen ist vor allem im Hinblick auf die Erhebung und Analyse von Kriminalitätsdaten von Bedeutung. Während die von Strafverfolgungsbehörden erhobenen Daten auf gesetzlichen Definitionen beruhen, basieren die im Rahmen von Viktimisierungserhebungen gewonnenen Erkenntnisse auf der individuellen Wahrnehmung von Straftaten, was insbesondere bei leichten Delikten zu Diskrepanzen führen kann (Ahmadi, 2003).

3.2 Crime Mapping – Was ist das?

In der Regel befindet sich ein Tatort an einem spezifischen Ort, wodurch er einen eindeutigen räumlich-geografischen Bezug in Form von Koordinaten oder einer Adresse aufweist. Für die Darstellung und Analyse dieser räumlichen Dimension von Kriminalität nutzen Verbrechensanalytiker*innen das Verfahren des Crime Mapping. Crime Mapping bezeichnet dabei im Groben die kartografische Darstellung von Kriminalität. Straftaten können somit auf einer Karte visualisiert und verortet werden, was Einblicke in die räumlichen Muster der Kriminalität ermöglicht und damit die Umsetzung gezielter polizeilicher Maßnahmen erlaubt. Eine Crime Map ist demnach eine Karte, die die Vorkommnisse von Verbrechen innerhalb eines bestimmten Gebietes und Zeitraums visualisiert. Während der Begriff in der Vergangenheit in erster Linie das manuelle Setzen von Stecknadeln auf handgezeichnete Wandkarten umfasste, versteht man im technologischen Zeitalter darunter den Einsatz eines Geografischen Informationssystems (GIS) zur räumlichen Analyse von Straftaten und anderen polizeilichen Themen (Räumliche Kriminalanalyse, n.d.; Santos, 2016).

3.2.1 GIS als Werkzeug

Geografische Informationssysteme (GIS) stellen das grundlegende Werkzeug für Crime Mapping dar, mit dem Nutzer*innen tabellarische und räumliche Daten verändern, abfragen, visualisieren und analysieren können. Ein GIS macht es räumlichen Kriminalanalytiker*innen möglich, Verbrechen auf vielfältige Weise darzustellen, von einer einfachen Punktkarte bis hin zu einer dreidimensionalen Visualisierung von räumlichen oder zeitlichen Daten. Dabei liegt es im Ermessen der Benutzer*innen, welche Funktionen des Systems sie nutzen möchten und wie sie diese einsetzen. Mit GIS ist es Strafverfolgungsbehörden möglich, diverse Datensätze, von soziodemografischen Daten über Tatorte und Spuren bis hin zu sogenannten *Points of Interest* (POI), also Standorte von Interesse, wie Polizeistationen, Verkehrsanbindungen, Banken und Lokale, zu kombinieren und in unterschiedlichen Ebenen in einem räumlichen Kontext zu visualisieren. Damit lassen sich gewisse Trends und Muster in der Kriminalität erkennen sowie Gebiete mit einer hohen Konzentration an Kriminalität identifizieren. GIS ähnelt dabei alltäglichen Softwareprogrammen wie Textverarbeitungs- oder Tabellenkalkulationsprogrammen, indem die Software einen Leitfaden und Rahmen zur Erfassung, Strukturierung und Analyse von Daten bereitstellt (Räumliche Kriminalanalyse, o. D.; Santos, 2016).

3.3 Historische Entwicklung des Crime Mapping

Um zu verstehen, wie die Kartierung von Verbrechen die Strategien der Strafverfolgung revolutioniert hat, beleuchtet dieses Kapitel die historische Entwicklung von Crime Mapping von seinen Anfängen im frühen 19. Jahrhundert bis zur heutigen Anwendung in der digitalen Ära.

Der Beginn der Verbrechenskartierung kann auf den Rechtsanwalt André Guerry und den Ethnografen Adriano Balbi zurückgeführt werden, die bereits im Jahr 1829 in Frankreich Karten erstellten, die den Zusammenhang zwischen dem Bildungsniveau und Gewalt- und Eigentumsdelikten veranschaulichten. Die Analyse ihrer Karten ergab, dass Gebiete mit einem großen Anteil an Eigentumsdelikten tendenziell von Menschen mit einem höheren Bildungsniveau bewohnt wurden (Weisburd & McEwen, 2015).

Dieser Ansatz der visuellen Darstellung von Kriminalitätsunterschieden zwischen geografischen Orten fand Mitte des 19. Jahrhunderts auch in England und Irland Anwendung. Im Jahr 1861 erstellte Henry Mathew Karten, welche die Raten verschiedener Verbrechen in den englischen und walisischen Grafschaften darstellten. Dafür unterteilte er geografische Gebiete in verschiedene Formen und schattierte diese anschließend entsprechend nach dem jeweiligen Wert (Chamard, 2006).

3.3.1 Chicagoer Schule

In den 1920er Jahren entstand die *Chicagoer Schule der Soziologie*, die eine wichtige Rolle in der Untersuchung von urbanen Phänomenen spielte, darunter auch die Verteilung von Kriminalität in Stadtgebieten. Forscher dieser Schule widmeten sich der Beobachtung, wie sich amerikanische Städte unter dem Einfluss wachsender Industrialisierung und der vermehrten Zuwanderung entwickelten. Ein zentraler Gedanke der Chicagoer Schule war, dass das soziale Umfeld einen starken Einfluss auf das menschliche Verhalten ausübt. Sie fanden Zusammenhänge zwischen Kriminalität und Faktoren wie der demografischen Struktur der Bevölkerung und den Jahres- und Klimabedingungen (Lutters & Ackerman, 1996).

Einer der wichtigsten Beiträge dieser Schule zum Thema Crime Mapping war die Entwicklung der Theorie der *sozialen Desorganisation*. Diese Theorie beschreibt die

Schwierigkeit innerhalb einer Gemeinschaft, aufgrund verschiedener Faktoren wie Rassismus, Armut und Abwanderung, gemeinsame Werte und Normen aufrechtzuerhalten, was letztlich zu einem Anstieg der Kriminalität führt. Im Hinblick dieser Theorie untersuchten die Forscher Clifford Shaw und Henry McKay in ihrem bedeutenden Werk “Juvenile Delinquency and Urban Areas”, wie bestimmte städtische Gebiete, insbesondere diejenigen mit hoher Armut und ethnischer Heterogenität, eine Tendenz zu höheren Kriminalitätsraten aufwiesen. Konkret kartierten sie die Wohnorte von jugendlichen Straftätern und entdeckten dabei, dass sich die Vorfälle auf spezifische Stadtteile konzentrierten. Die Arbeit von Shaw und McKay dient nach wie vor als ein wesentlicher Bezugspunkt für Studien über städtische Kriminalität und einige von ihnen erstellte Karten zählen heute zu den bekanntesten in der Kriminologie (Lutters & Ackerman, 1996; Eck, 2005).

3.3.2 Computergestütztes Crime Mapping

Ab den frühen 1900er Jahren erkannten und adaptierten Strafverfolgungsbehörden zunehmend das Konzept der Kartierung von Verbrechen. Bis Mitte des 20. Jahrhunderts nutzten Polizeidienststellen dafür traditionelle Methoden wie die Verwendung von Pin-Karten, um Einblicke in die Kriminalitätsverteilung zu gewinnen und geografische Muster analysieren zu können. Dafür wurden Stecknadeln auf eine ausgedruckte Karte gesteckt, um Orte des Verbrechens darzustellen. Obwohl diese Methode informative und wertvolle Einblicke lieferte, gestalteten sich die Umsetzung und Aktualisierung als sehr zeitaufwendig und unflexibel (Block, 1995; Dağlar & Argun, 2016). Das *New York Police Department* (NYPD) war eine der ersten Behörden, die diese manuelle Verbrechenskartierung als Werkzeug einsetzten, um interaktive Basiskarten zu erstellen und eine effektivere Ressourcenverteilung zu ermöglichen (Harries, 1999).

Mit dem Aufkommen des digitalen Zeitalters und dem Übergang zu digitalen Technologien erlebte die Verbrechenskartierung einen signifikanten Wandel. Auf der dringlichen Suche, die umständliche und zeitintensive manuelle Arbeit für die Erstellung und Aktualisierung solcher interaktiven Karten zu umgehen, entwickelten Forscher der Harvard Universität in den 1960er Jahren eines der ersten Programme für computergestütztes Crime Mapping: das *Synagraphic Mapping System* (SYMAP) (Weisburd & McEwen, 2015; Harries, 1999). Die Einführung solcher frühen Formen von Geografischen Informationssystemen (GIS) erweiterte die Möglichkeiten in der Polizeiarbeit erheblich. Auch wenn Programme wie

SYMAP rückblickend nicht als vollwertige GIS-Programme angesehen werden können, trugen sie dazu bei, die Speicherkapazitäten deutlich zu erhöhen und die Verknüpfung von geografischen Informationen mit Kriminalitätsdaten zu ermöglichen, wodurch komplexe Fragestellungen in der Strafverfolgung effizienter bearbeitet werden konnten (Dağlar & Argun, 2016).

Allerdings stellte die Digitalisierung anfangs noch eine erhebliche Hürde dar. Viele Dienststellen konnten es sich nicht leisten, solche Technologien eigenständig zu implementieren. Software und Hardware waren komplex und teuer und erforderten Experten für ihre Nutzung. Dazu kam, dass Städte, für die Kartenmaterial verfügbar war, dies meist in Einrichtungen außerhalb von Polizeibehörden, wie zum Beispiel in Stadtplanungsämtern, verwalteten und sich der Einsatz an zwei Standorten meist als unpraktikabel und teuer erwies (Block, 1995). Dennoch stellten schon damals einige Polizeidienststellen die praktische Anwendung und den Nutzen von Crime Mapping unter Beweis. Ein Beispiel dafür ist das *Saint Louis Police Department* in Missouri, USA, welches als eine der ersten Behörden automatisierte, computergestützte Verbrechenskarten nutzte, um Autodiebstähle zu dokumentieren (Weisburd & McEwen, 2015).

Im Jahr 1969 wurde das *Environmental Science and Research Institute* gegründet, welches sich in späteren Jahren zu einem der führenden Anbieter von GIS Software, mit bekannten Programmen wie *ArcView* und *ArcGIS*, entwickelte. In etwa zur gleichen Zeit wurde das *Geographic Base Files and Dual Independent Map Encoding* (GBF/DIME) Projekt ins Leben gerufen mit dem Ziel, digitalisierte Straßen für alle Städte in den USA zu erstellen. Dieses wegweisende Projekt bildete die Grundlage für die Entwicklung von GIS-Programmen und computergestützter Kriminalitätskartierung (Mark et al., 1997).

Eine flächenhafte Verbreitung von computergestützter Crime-Mapping-Technologie in den USA fand jedoch erst in den frühen 1990er Jahren statt. Erst zu diesem Zeitpunkt war die Technologie weit genug fortgeschritten und die Kosten so weit reduziert, dass diese einem breiten Nutzerkreis zugänglich gemacht werden konnte und auch kleinere Polizeidienststellen von den Möglichkeiten profitierten (Block, 1995). Das im Jahr 1994 in New York City ins Leben gerufene *Compstat-Programm* spielte dabei eine zentrale Rolle für die Verbreitung von computergestützter Verbrechenskartierung unter Polizeibehörden. Ebenso unterstützte das *National Institute of Justice* und das *Office of Community Oriented Police Services* die Förderung solcher Technologien. Vor allem ist jedoch die Gründung des *Crime Mapping*

Research Centers (CMRC) durch das US-Justizministerium hervorzuheben, die das nationale Engagement zur Weiterentwicklung dieser Methode deutlich vorantrieb. Bei einer Umfrage aus dem Jahr 1997 berichteten bereits 35 Prozent der Polizeibehörden mit über 100 Beamten, Verbrechenskartierung als Teil ihrer Polizeiarbeit einzusetzen (Harries, 1999; Weisburd & Lum, 2005).

Wie aus den vorangegangenen Abschnitten ersichtlich wird, stammen die wesentlichen Fortschritte im Bereich des Crime Mapping bis zum 21. Jahrhundert, überwiegend aus den Vereinigten Staaten. Dies sollte sich im Jahr 2002 mit der Umbenennung des Crime Mapping Research Center (CMRC) in *Mapping and Analysis for Public Safety* (MAPS) ändern. Von diesem Zeitpunkt an beschränkte sich der Einfluss dieser Initiative der US-Regierung nicht mehr ausschließlich auf die Vereinigten Staaten. Sie wurde vielmehr zu einem wesentlichen Fundament für die Entwicklung und Verbreitung der Verbrechenskartierung weltweit, einschließlich Ländern wie dem Vereinigten Königreich, Australien, Südafrika und verschiedenen Staaten Südamerikas. Das Engagement des MAPS-Programms umfasste die Organisation von Workshops, die Ausrichtung von Konferenzen, das Veröffentlichen von Fachliteratur sowie die Entwicklung spezifischer Softwarewerkzeuge für das Crime Mapping. Darüber hinaus förderte es auch neue Forschungsansätze in diesem Bereich (Chainey & Ratcliffe, 2013).

Auch heute noch spielt das MAPS-Programm eine zentrale Rolle bei der Förderung der Verbrechenskartierung. Mittlerweile haben sich zahlreiche weitere Institutionen und Organisationen dem Programm angeschlossen, was dazu geführt hat, dass Crime Mapping inzwischen von Regierungen und Strafverfolgungsbehörden auf der ganzen Welt als wertvolles Werkzeug zur Unterstützung in der Polizeiarbeit und im Kampf gegen Kriminalität anerkannt und eingesetzt wird (Chainey & Ratcliffe, 2013).

3.4 Grundlegendes Konzept des Predictive Policing

Der Begriff *Predictive Policing*, im deutschen Kontext auch "vorausschauende Polizeiarbeit", hat sich in den letzten Jahrzehnten entwickelt und stellt einen innovativen Ansatz in der Verbrechensprävention dar, der auf der Analyse großer Datenmengen basiert, um zukünftige individuelle Typen von Verbrechen zu prognostizieren. Dieser Ansatz nutzt mitunter mathematische Algorithmen zur Strukturierung polizeilicher Daten, um Muster und

Wahrscheinlichkeiten für das Auftreten bestimmter Kriminalitätsformen zu identifizieren. Die zentrale These des Predictive Policing lautet dabei, dass Kriminalität kein zufälliges Phänomen ist, sondern bestimmten Mustern folgt. Diese Muster beziehen sich nicht nur auf Zeitpunkt und Art des Verbrechens, sondern in erster Linie auf die räumliche Verteilung (Povalej & Volkmann, 2021).

Die Analyse stützt sich dabei auf umfassende Datenmengen, die aus verschiedenen Quellen wie aktuellen Polizeiberichten, öffentlich zugänglichen Informationen und Sensordaten gesammelt werden. Man geht von der Grundannahme aus, dass die Analyse vorhandener Kriminalitätsdaten Rückschlüsse auf die Wahrscheinlichkeit zukünftiger Verbrechen zulässt. Ziel ist es, wiederkehrende Muster in der Kriminalität zu erkennen, sei es in Bezug auf die Region, bestimmte Delikte oder wiederholte Vorfälle bei denselben Opfern innerhalb kurzer Zeitabstände. Die Qualität dieser riesigen Datenmengen spielt dabei eine entscheidende Rolle für die Effektivität und die Wirksamkeit der Kriminalitätsprognose. Daher ist eine sorgsame Auswahl und Verwaltung der Daten erforderlich, um deren Vollständigkeit, Korrektheit und Redundanzfreiheit zu gewährleisten (Povalej & Volkmann, 2021).

Im Rahmen des Predictive Policing kann im Groben zwischen zwei Verfahren unterschieden werden. Zum einen das sogenannte *Personenbezogene Verfahren*, welches sich in erster Linie auf eine/n bestimmte/n Täter*in und/oder ein bestimmtes Opfer fokussiert. Zum anderen das *Raumbezogene Verfahren*, welches sich auf die Identifizierung bestimmter Kriminalitäts-Risikogebiete in Verbindung eines zeitlichen Rahmens stützt (Povalej & Volkmann, 2021). Im Hinblick auf den geografischen Kontext dieser Arbeit wird letzteres in weiterer Folge genauer beleuchtet.

3.4.1 Das Raumbezogene Verfahren

Innerhalb des Konzepts des Raumbezogenen Verfahrens finden sich erneut zwei Varianten, die sich jeweils in ihrer Art der Vorhersage unterscheiden. Egbert et al. (2022) nennen hierbei als zentrales Kriterium der Unterscheidung “den Grad, zu dem die Vorhersagen der Software für Nutzer*innen verständlich sind, also inwieweit diejenigen Personen, die über die Weitergabe und Umsetzung der Prognosen entscheiden, den Eindruck bekommen können, dass sie ausreichend über die Gründe und Kriterien des Verfahrens informiert sind” (S. 191).

Laut Egbert et al. (2022) umfasst die erste Variante “**verständliche**” Vorhersagen. Hierfür wird konkret die *Near-Repeat-Methode* im Zusammenhang mit der Prognosesoftware PRECOBS hervorgehoben, die vor allem in deutschen Polizeibehörden zum Einsatz kommt und auf der kriminologischen Annahme basiert, dass nach einem Wohnungseinbruch die Wahrscheinlichkeit für ähnliche Delikte in räumlicher und zeitlicher Nähe erhöht ist (Egbert et al., 2022). Neben der Near-Repeat-Methode lässt sich auch das Konzept des *Hot-Spot-Mapping* unter diese Kategorie der verständlichen Vorhersagen einordnen (Chainey, 2005).

Die Prognose der verständlichen Vorhersagen unterliegt dabei einer nachvollziehbaren Logik. Sie basiert auf klaren theoretischen Grundlagen, was ihre Anwendung intuitiv und zugänglich macht. Außerdem fokussiert sie sich hauptsächlich auf spezifische Deliktarten, wodurch ihr Einsatzbereich zwar begrenzt, aber auf bestimmte Arten von Kriminalität präzise ausgerichtet ist. Die Eindeutigkeit und Effektivität solcher Vorhersagen wird zudem dadurch gesteigert, dass sie in hohem Maße mit bereits vorhandenen polizeilichen Wissen übereinstimmen, wodurch ihre Integration in bereits bestehende Ermittlungsstrategien erleichtert wird. Diese Vorhersagen dienen somit der Präzisierung und Automatisierung von Kriminalitätsanalysen, die zuvor weitgehend manuell durchgeführt wurden. Die eingesetzten Programme integrieren Kenntnisse, die Polizist*innen durch ihre berufliche Erfahrung bereits besitzen, und erleichtern ihre Arbeit durch die Bereitstellung von vorverarbeiteten und einsatzrelevanten Informationen (Egbert et al., 2022).

Im Unterschied zum ersten Prognoseverfahren umfasst die zweite Variante “**unverständliche**” Vorhersagen. Diese basieren auf einer Vielzahl kriminologischer Theorien und auf verschiedenen Verfahren des *Maschinellen Lernens* (ML), einer Technik, die es Computern ermöglicht, aus Datenmengen zu lernen und selbstständig Entscheidungen zu treffen. Im Gegensatz zur ersten Variante, die sich auf deliktspezifische Daten beschränkt, nutzt diese viele weitere, nicht deliktspezifische Informationen, was zwar den Anwendungsbereich ausdehnt, aber zu geringerer Übereinstimmung mit polizeilichem Wissen führt und Vorhersagen somit schwerer zu verstehen macht. Diese unverständliche Variante wird auch als *Risk-Terrain-Modeling* (RTM) bezeichnet und soll durch die Integration verschiedener polizeilicher als auch nicht-polizeilicher Daten komplexe räumliche Vorhersagen ermöglichen (Egbert et al., 2022).

Algorithmen im Rahmen des unverständlichen Verfahrens sind mithilfe von ML in der Lage, selbstständig zu entscheiden, was genau sie lernen und wie sie dabei vorgehen (Burrell, 2016). Laut Esposito (2022) sind diese Technologien daher nicht nur für Personen ohne entsprechendes technisches Verständnis unzugänglich, sondern aufgrund ihrer komplexen Beschaffenheit, insbesondere im Bereich des *Deep Learnings*, eine fortschrittliche ML-Technik die auf komplexen neuronalen Netzwerken basiert, selbst für ihre Entwickler*innen schwer zu durchschauen (Sugomori et al., 2017). Zudem stellte Brayne (2020) fest, dass solche unverständlichen und undurchsichtigen Algorithmen Polizist*innen daran hindern, den gelieferten Hinweisen einen Sinn zu geben. Dies ist vor allem in Fällen zu beobachten, die weder gewohnten Abläufen noch der Intention der Polizist*innen entsprechen. Oft werden Ergebnisse dadurch als Unsinn abgetan oder nur mit Misstrauen hingenommen. Brayne (2020) zeigte außerdem, dass im Gegensatz dazu verständliche Verfahren, wie die Methode des Hot-Spot-Mapping, in Polizeidienststellen nicht infrage gestellt und problemlos akzeptiert werden. Egbert et al. (2022) verdeutlichen diese These durch den direkten Vergleich zweier spezifischer Prognose-Softwareprogramme, um die Unterschiede zwischen den beiden Vorhersage-Varianten aufzuzeigen. Auch ihre Untersuchung ergab, dass das RTM-Programm für “deutlich unverständlichere Prognosen” (S. 195) sorgte, was bei Nutzer*innen regelmäßig zu Verständnisschwierigkeiten führte.

Aufgrund der größeren Transparenz, einfacheren Nachvollziehbarkeit sowie empirischer Belege für die Wirksamkeit konzentriert sich die vorliegende Arbeit auf verständliche Verfahren innerhalb des Predictive Policing, insbesondere auf die Analyse von Hot Spots mithilfe verschiedener Hot-Spot-Mapping-Methoden sowie der darauf aufbauenden Strategie des *Hot-Spot-Policing* (Rosser et al., 2017).

Das nachfolgende Kapitel beschäftigt sich eingehend mit der Analyse von Hot Spots, wobei der Fokus auf den genannten Begriffen “Hot Spot” und “Hot-Spot-Policing” sowie den leitenden Theorien und geeigneten Kartierungssymbolen liegt.

4. Die Analyse von Hot Spots

“On Valentine’s Day 1989, in the capital of the U. S., 14 people were hit by gunshots. Four of them were shot on one block of Drake Place, S.E... This one small block of Drake Place and its adjacent public housing complex had witnessed five murders in 1988. That was bad enough. But in the first seven weeks of 1989, Drake Place was the site of 4 murders and 14 bullet woundings.

Drake Place was a “hot spot” of crime. It was so hot that the police said they stayed away from it as much as possible, unless they got a call. It was so hot that every night after dark, one officer claimed there were gunshots all night long. It was so hot that after the St. Valentine’s Day Massacre, the Washington, D.C. police assigned a special patrol car to guard the block 24 hours a day. Drake Place may have been one of the hottest spots of crime in the U.S. in 1989.”

- Sherman, 1995, S. 35-36

Neben diesem eindrücklichen Beispiel aus Drake Place in Washington D.C. aus dem Jahr 1989 bestätigen jahrzehntelange empirische Untersuchungen das Phänomen, dass Kriminalität in den meisten Fällen räumlich stark konzentriert ist. So zeigen weitere Fallbeispiele aus verschiedenen Städten weltweit, wie ein geringer Prozentsatz bestimmter Orte für einen unverhältnismäßig großen Anteil der Kriminalität verantwortlich ist. Sherman et al. (1989) stellten beispielsweise fest, dass 50 Prozent der Anrufe bei der Polizei in Minneapolis (USA) von 3,3 Prozent der Adressen der Stadt ausgingen. Darüber hinaus konnte Budd im Jahr 2001 zeigen, dass in Großbritannien 42 Prozent der Wohnungseinbrüche in einem Prozent der Haushalte stattfanden. Zudem ist auch die Feststellung von Braga et al. aus dem Jahr 2011 interessant, die aufzeigen konnten, dass 50 Prozent der Straßenraubüberfälle in Boston (USA) auf einem Prozent der Straßenabschnitte der Stadt stattfanden sowie der Bericht von Andresen und Malleson aus dem gleichen Jahr, der zeigt, dass 50 Prozent der Fahrzeugdiebstähle in Vancouver (Kanada) auf rund fünf Prozent der Straßenabschnitte stattfanden (Rosser et al., 2017).

4.1 Definition von Hot Spots

Zahlreiche Studien belegen also die Annahme, dass Kriminalität nicht gleichmäßig im Raum verteilt ist, sondern in der Regel auf bestimmte Gebiete konzentriert ist. Diese Gebiete, in denen die Kriminalitätskonzentration besonders hoch ist, werden in der Fachliteratur als *Hot*

Spots bezeichnet. Obwohl es keine einheitliche Definition des Begriffs Hot Spot gibt, lässt er sich nach einem allgemeinen Verständnis definieren. Eck (2005) beschreibt in seinem Werk “Crime hot spots: What they are, why we have them, and how to map them” einen Hot Spot als ein Gebiet, in dem sich überdurchschnittlich viele Straftaten oder Unruhen ereignen, oder alternativ als einen Ort, an dem Menschen einem erhöhten Risiko ausgesetzt sind, Opfer einer Straftat zu werden. Im Allgemeinen handelt es sich also um Gebiete, an denen sich Kriminalität konzentriert. Dabei haben Hot Spots einen qualitativen Ansatz und beziehen sich jeweils nur auf eine bestimmte Art von Verbrechen (Harries, 1999). In der Regel handelt es sich dabei um Straßenkriminalität, wobei es gelegentlich auch Ausnahmen für andere Arten von Kriminalität gibt. Harries (1999) nennt als Beispiel für weitere Kriminalitätsarten den Fall, dass innerhalb eines bestimmten Zeitraums mehrere Schießereien oder terroristische Anschläge an bestimmten Orten erfolgen.

In der Forschung und von Polizeibehörden wird der Begriff unterschiedlich verwendet. So beziehen sich einige auf Hot-Spot-Adressen (Sherman, 1989), andere auf Hot-Spot-Blöcke (Weisburd & Green, 1994) und wieder andere auf Cluster von Hot-Spot-Blöcken (Block, 1995). Dabei lassen sich Hot Spots in verschiedenen Größenordnungen finden, von kleineren Hot-Spot-Orten bis hin zu ganzen Hot-Spot-Regionen (Eck, 2005). Neben der geografischen Dimension können Hot Spots auch nach zeitlichen Kriterien definiert werden. Hierbei stellt sich für Strafverfolgungsbehörden in erster Linie die Frage, über welchen Zeitraum hinweg ein Hot Spot als “heiß” gilt. Um diese Frage beantworten zu können, müssen Hot Spots in Verbindung mit den Tatzeitpunkten der jeweiligen Verbrechen kartiert werden. Mithilfe von GIS ist es dann möglich, Hot Spots oder einzelne Vorfälle innerhalb von Hot Spots in der Karte je nach Alter farblich abzustufen (Harries, 1999).

Die Methode des Hot-Spot-Mapping beschreibt die Kartierung und Analyse von Hot Spots und stellt damit eine bestimmte Methode innerhalb des Crime Mappings dar. Hierbei werden historische Verbrechensdaten und Muster genutzt, um diese Gebiete mit einer hohen Kriminalitätsrate zu identifizieren. Das übergeordnete Ziel ist es, die Strategie des Hot-Spot-Policing anzuwenden (Chainey et al., 2008).

4.2 Die Strategie des Hot-Spot-Policing

Um den Nutzen für Strafverfolgungsbehörden hinter der Kartierung und Analyse von Hot Spots aufzuzeigen, wird in diesem Kapitel die Strategie des Hot-Spot-Policing erläutert.

Traditionelle kriminologische Ansätze konzentrieren sich in ihrer präventiven Polizeiarbeit auf das Individuum, ohne die Bedeutung des Ortes mit einzubeziehen (Sherman et al., 1989). In der Regel wendet die Polizei dabei viel Mühen und Ressourcen auf, um beispielsweise Drogenverkäufer*innen im kleinen Maßstab zu verhaften, ohne den allgemeinen Drogenhandel dabei spürbar zu beeinträchtigen (Braga et al., 2012). Um kriminelle Aktivitäten jedoch nachhaltig und effizient zu stören, müssen sich Strafverfolgungsbehörden laut Braga et al. (2012) bei ihren Ermittlungen auf die Merkmale des Ortes konzentrieren, die dafür verantwortlich sind, dass Straftaten an diesen bestimmten Orten stattfinden.

Diese Überlegungen von Braga et al. (2012) sowie die Ergebnisse aus den oben genannten Studien zur räumlichen Konzentration von Kriminalität legen nahe, dass eine gezielte Überwachung an Hot Spots eine wirksame Strategie in der Verbrechensprävention darstellen kann. Auf dieser Grundannahme baut die Strategie des Hot-Spot-Policing auf, die sich auf die Bekämpfung von Kriminalität durch gezielte Polizeipräsenz an Hot Spots konzentriert (Trotta et al., 2013; Braga et al., 2012). Ziel dieser Strategie ist es, polizeiliche Ressourcen einzusparen und gleichzeitig die Wahrscheinlichkeit von Straftaten zu verringern (Chainey et al., 2008; Rosser et al., 2017).

Verschiedene Studien belegen dabei die Wirksamkeit dieser Strategie. Forrester et al. (1988) nennen hierfür als Beispielstudie das Projekt zur Verhinderung von Wohnungseinbrüchen in Kirkholt, Dänemark. Ziel des Projekts war es, die wiederholten Einbrüche von bestimmten Haushalten zu verhindern, indem die Sicherheit von kürzlich betroffenen Haushalten durch Polizeipräsenz verbessert wurde. Die Strategie zeigte eine gute Wirkung. Nach Einsetzen der Maßnahmen gingen die Einbrüche im gesamten Gebiet um mehr als 50 Prozent zurück (Rosser et al., 2017). Ein weiterer Beleg für die Wirksamkeit ist die Studie eines Committees des *National Research Council*, die zu dem Schluss kam, dass Hot-Spot-Strategien die effektivste polizeiliche Methode zur Verbrechensbekämpfung darstellen (Skogan & Frydl, 2004). Darüber hinaus konnten DiTella und Schargrodsky (2004) in ihrer Studie über proaktive Patrouillen in Brennpunktgebieten einen Rückgang der Drogenkriminalität in Jersey City in New Jersey um 58 Prozent und einen Rückgang der Prostitutionsdelikte um 45

Prozent feststellen. Es ist daher nicht verwunderlich, dass die Kartierung von Hot Spots zu einem sehr beliebten Instrument für Strafverfolgungsbehörden geworden ist. Laut Weisburd et al. (2003) gaben bei einem Bericht der *Police Foundation* sieben von zehn Polizeibehörden mit über 100 Beamten*innen an, Karten für die Ermittlung von Hot Spots zu verwenden. Bei einer weiteren Befragung des *Police Executive Research Forums* (2008) von 176 US-Polizeidienststellen gaben sogar fast neun von zehn Dienststellen an, bei ihrer Polizeiarbeit Hot-Spot-Strategien anzuwenden (Braga et al., 2012).

4.2.1 Die drei Perspektiven des Hot-Spot-Policing

Laut Braga et al. (2012) und Rosser et al. (2017) wird die Strategie des Hot-Spot-Policing von drei sich ergänzenden theoretischen Perspektiven beeinflusst, die versuchen, das kriminelle Verhalten während einer Tat zu erklären: *Rational Choice*, *Routine Activities* und *Environmental Criminology*.

Nach der Rational-Choice-Perspektive handeln Straftäter*innen bei ihren Entscheidungen rational. Sie begehen deshalb Straftaten bevorzugt an Orten, mit denen sie bereits vertraut sind, um sich dadurch selbst Vorteile zu verschaffen und gleichzeitig potenzielle Risiken besser einschätzen zu können (Rosser et al., 2017; Braga et al., 2012).

Dieser Ansatz wird oft in Verbindung mit der Routine-Activity-Perspektive betrachtet, die davon ausgeht, dass Straftaten mit direktem Kontakt, wie beispielsweise Raubüberfälle oder Einbrüche, ungeplant bei alltäglichen Aktivitäten entstehen. Demnach kommt es dann zu einer Straftat, wenn ein rationaler Täter in seinem Alltag auf ein Opfer oder Ziel trifft, das nicht beschützt wird. Demzufolge sind beispielsweise Einbrüche an wenig bevölkerten Orten zu erwarten und Raubüberfälle dort, wo es genügend potenzielle Ziele, aber wenig bis gar keine Beschützer gibt. Im Hinblick auf die Bildung von Hot Spots, entstehen diese an Orten, an denen eine Vielzahl von Gelegenheiten für Straftaten zusammentreffen. Ziel der Polizei ist es, Straftaten zu reduzieren, indem die Gelegenheiten für das räumliche und zeitliche Zusammenkommen von Täter und Opfer bzw. Ziel minimiert werden (Rosser et al., 2017; Braga et al., 2012).

Die Environmental-Criminology-Perspektive befasst sich mit den Eigenschaften eines Ortes. Diese Eigenschaften dienen im Rahmen dieser Perspektive als Schlüssel zur Erklärung der Entstehung von Hot Spots. Für ein besseres Verständnis nennen Braga et al. (2012) ein

Beispiel für einen idealen Standort für einen Drogenmarkt. Konkret beschreiben sie hierfür ein verlassenes Gebäude an einer schlecht beleuchteten Straßenecke in der Nähe einer Hauptverkehrsstraße. Die fehlende Beleuchtung ermöglicht hierbei eine Art verdecktes Agieren im Dunkeln, die nahe Anbindung an eine Durchfahrtsstraße sorgt für einen ständigen Strom an potenziellen Kund*innen und die Lagerung der Drogen in einem verlassenen Gebäude könnte verhindern, dass die Drogen auf die Händler*innen zurückzuführen sind (Braga et al., 2012).

4.3 Leitende Theorien und geeignete Kartierungssymbole

Laut Eck (2005) ist die Methode des Hot-Spot-Mapping, dann am effektivsten, wenn der Prozess für die Erstellung der Karten von einer bestimmten Theorie geleitet wird, die mit bestimmten Kartierungssymbolen einhergeht. Solche Kriminalitätstheorien sind für eine effektive Kriminalitätskartierung von entscheidender Bedeutung, da sie maßgeblich bei der Interpretation von Daten helfen. Zudem geben sie Hinweise darauf, welche polizeilichen Maßnahmen in einem bestimmten Fall am besten geeignet sind (Eck, 2005).

Zwar stimmen viele der Theorien nicht immer überein, dennoch erklären sie verschiedene Arten von Kriminalitätsphänomenen, die auf unterschiedlichen geografischen Ebenen auftreten und bieten einen Anhaltspunkt für die Auswahl von geeigneten Mapping-Symbolen. Dabei unterscheiden sich die Theorien in Bezug auf das geografische Gebiet, auf das sie sich beziehen. Während einige Theorien versuchen, punktuelle Konzentrationen von Kriminalität zu erklären, tragen andere dazu bei, lineare Konzentrationen von Straftaten oder Hot-Spot-Polygone zu erklären. Welche Theorie und welche Kartierungsart am nützlichsten ist, hängt von der Art der Straftat ab (Eck, 2005). Im Folgenden werden die drei für Polizeibehörden wichtigsten Theorie-Ebenen zusammen mit geeigneten Kartierungssymbolen näher erläutert und für ein besseres Verständnis mit Beispieltheorien untermauert.

4.3.1 Theorien auf Ortsebene (Punkte)

Theorien auf Ortsebene versuchen zu erklären, warum Straftaten an einzelnen spezifischen Orten begangen werden. Als zentrale Kartierungseinheiten dienen genaue Adressen, Kreuzungen, Geschäfte und andere kleinere Orte, die in der Karte in der Regel als Punkte

dargestellt werden (siehe Abbildung 1, A). Punkte stellen die genaueste Ebene der Verbrechenskartierung dar. Kartografen können somit zwischen Orten mit Problemen und ganz in der Nähe liegenden Orten ohne Probleme präzise unterscheiden und entsprechende polizeiliche Maßnahmen gezielt durchführen. Beispielsweise kann somit genau zwischen zwei gegenüberliegenden Tankstellen unterschieden werden, für den Fall, dass eine der beiden vielen Überfällen ausgesetzt ist und die andere nur wenigen. Weitere Beispiele für polizeiliche Maßnahmen an spezifischen Orten wäre ein Haftbefehl an einer bestimmten Adresse oder ein Polizeieinsatz wegen Belästigung an einem bestimmten Ort (Eck, 2005).

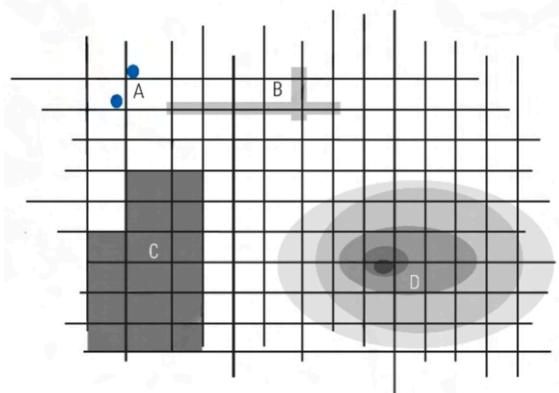


Abb. 1: Punkte (A) (Eigene Darstellung, basierend auf Eck, 2005, S. 12)

Nach Eck und Weisburd (1995) haben Orte in der Regel eine/n Eigentümer*in und eine bestimmte Funktion. Auf dieser Grundlage versucht eine exemplarische Theorie auf Ortsebene, die sogenannte *Routine-Activity-Theorie*, zu erklären, warum Kriminalität häufig an bestimmten Orten konzentriert ist. Dabei wird von der Annahme ausgegangen, dass das Verhalten an einem Ort durch den/die jeweilige/n Eigentümer*in des Ortes reguliert wird (Eck, 2005). Als Beispiel nennt Eck (2005) den Unterschied zwischen einer Bar, in der es viele Übergriffe gibt, und einer Bar, in der es nur selten zu Übergriffen kommt. Nach dieser Theorie besteht der Unterschied darin, dass die Bar im zweiten Fall das Verhalten der Gäste aktiv reguliert, indem sie sicherstellt, dass diese sich benehmen und sich nicht übermäßig betrinken. Im ersten Fall findet solch eine Regulierung seitens des/der Eigentümers/Eigentümerin nicht statt. Hiernach ist das zugrunde liegende Problem hinter dem Auftreten von Straftaten an bestimmten Orten folglich das Fehlen einer effektiven Ortsverwaltung (Eck, 1995).

4.3.2 Theorien auf Straßenebene (Linien)

Theorien auf Straßenebene versuchen zu ergründen, warum Straftaten in bestimmten ausgedehnten Gebieten wie längliche Häuserblocks oder Straßen auftreten. Eck (2005) nennt als Beispiel einen Straßenstrich. Betrachtete Gebiete sind in der Regel Straßen, Wege oder bestimmte Straßenabschnitte. Auf einer Karte werden diese als gerade, geschwungene oder gekrümmte Linien dargestellt (siehe Abbildung 2, B). Polizeiliche Maßnahmen sind hier noch relativ genau, wenn auch nicht so genau wie auf Ortsebene. Ein Beispiel für konkretes polizeiliches Handeln wäre eine routinemäßige Bestreifung an den betroffenen Straßenabschnitten (Eck, 2005).

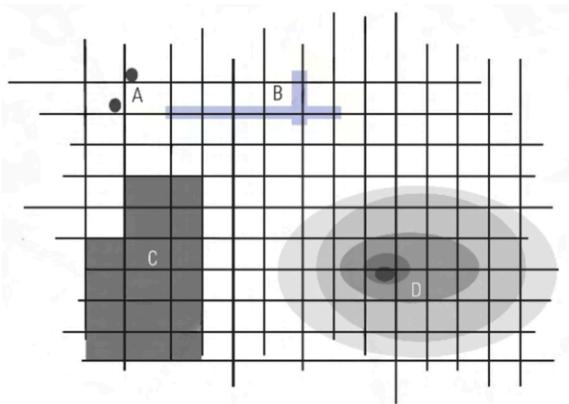


Abb. 2: Linien (B) (Eigene Darstellung, basierend auf Eck, 2005, S. 12)

Die Unterscheidung von linearen und punktuellen Hot Spots ist nicht immer eindeutig. So finden manchmal auch beide Darstellungsarten Anwendung. Ein Beispiel hierfür wäre der Handel von Drogen. Häufig arbeiten Drogendealer an bestimmten Straßen, wobei sich der Drogenhandel entlang eines bestimmten Straßenabschnitts als Linien-Hot-Spot abzeichnet. Gleichzeitig ist der Dealer aber auch an eine bestimmte Adresse gebunden, mit Drogenumschlagplätzen an bestimmten Ankerpunkten, die als Punkt-Hot-Spots dargestellt werden können (Eck, 2005).

Die *Crime-Opportunity*-Theorie liefert einen beispielhaften Ansatz für eine Theorie auf Straßenebene. Diese Theorie besagt, dass Straftaten vor allem dann begangen werden, wenn die Chance, sie erfolgreich zu begehen, mögliche Risiken überwiegen. Hierbei liegt der Fokus also auf bestimmten Kriminalitätszielen, die sich aufgrund einer bestimmten Gelegenheit ergeben. Als Beispiel nennt Eck (2005) eine Gegend ohne gesicherte Parkhäuser, wodurch Autos auf bestimmten Straßen geparkt werden, die Parkplätze am Gehsteig

anbieten. Eine solche Straße mit vielen Parkmöglichkeiten kann sich folglich als Hot Spot für Fahrzeugdiebstähle herauszustellen (Eck, 2005).

4.3.3 Theorien auf Nachbarschaftsebene (zweidimensionale Formen)

Theorien auf Nachbarschaftsebene versuchen zu erklären, warum Kriminalität in verhältnismäßig großen und dadurch oft sehr vielfältigen Gebieten auftritt. Betrachtete Gebiete sind verschiedene Stadtteile, Bezirke, Nachbarschaften oder Gemeinden. Als Darstellungsform dienen zweidimensionale Formen wie Rechtecke, Ellipsen oder Polygone. Abhängig von der Größe der Gebiete können polizeiliche Maßnahmen wie gezielte Patrouillen hier weniger präzise und effektiv sein. Daher werden oft zusätzliche Maßnahmen ergriffen, wie zum Beispiel der Versuch, die Anwohner zu kollektiven Maßnahmen gegen Kriminalität zu bewegen oder sich innerhalb der Hot-Spot-Gebiete wieder auf bestimmte Orte und Straßen zu konzentrieren (Eck, 2005).

Bei dieser zweidimensionalen Darstellungsart von Hot Spots kommen verschiedene Kartenarten zum Einsatz. Ein Beispiel sind Choroplethenkarten (siehe Abbildung 3, C). Diese suggerieren eine feste Grenze zwischen keiner Kriminalität im äußeren Bereich und gleichmäßig verteilter Kriminalität im inneren Bereich. Dass Kriminalität so feste Grenzen im Raum hat, entspricht nur selten der Realität. Daher dienen solche Darstellungen meist als erste grobe Orientierungshilfe in größeren Gebieten. Für eine präzisere Identifikation von Hot Spots verwenden Polizist*innen vorwiegend kleinere zweidimensionale Formen, wie beispielsweise die Kartierung im Raster (Eck, 2005).

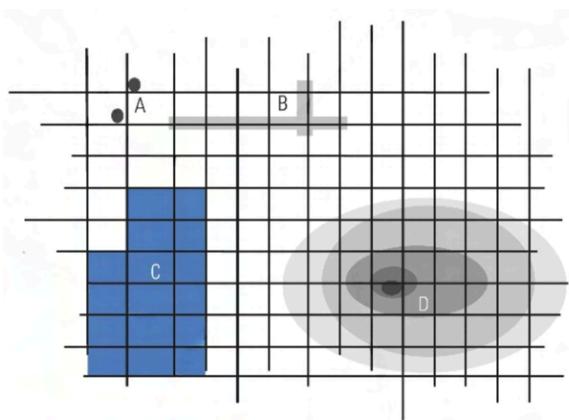


Abb. 3: Choroplethen (C) (Eigene Darstellung, basierend auf Eck, 2005, S. 12)

Isolinienkarten (siehe Abbildung 4, D) wirken diesem Problem entgegen, indem sie innerhalb eines Hot Spots ein kontinuierliches Risikogefälle aufzeigen. Verschiedene Orte innerhalb der Hot Spots weisen hierbei ein unterschiedlich hohes Kriminalitätsrisiko auf. Dank dieser realitätsnäheren Karten können Beamte*innen auch in größeren Untersuchungsgebieten umfassende Informationen gewinnen und gezielte Maßnahmen ergreifen (Eck, 2005).

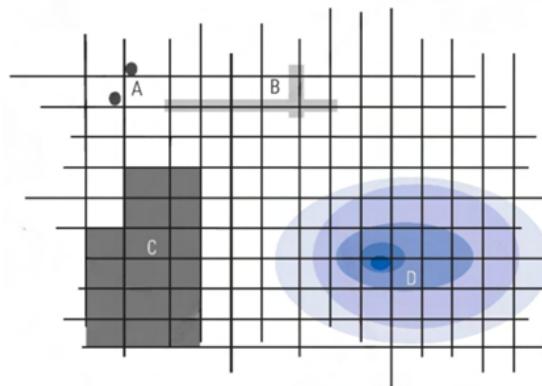


Abb. 4: Isolinien (D) (Eigene Darstellung, basierend auf Eck, 2005, S. 12)

Nachbarschafts-Theorien stellen die am häufigsten behandelten Theorien in der Hot-Spot-Mapping-Literatur dar (Eck, 2005). Wie bereits im Kapitel zur historischen Entwicklung von Crime Mapping erwähnt, beschäftigten sich Shaw und McKay bereits im Jahr 1931 mit dieser Art von Theorien, wobei sie feststellen, dass die Jugendkriminalität über Jahrzehnte hinweg in bestimmten Stadtvierteln besonders hoch war (Shaw & McKay, 1969). Dazu stellten sie selbst eine Theorie auf Nachbarschaftsebene auf, die besagt, dass soziale Netzwerke in einer Nachbarschaft der Hauptgrund für soziale Kontrolle darstellen. Diese sozialen Netzwerke werden durch Faktoren wie Abwanderung, Rassismus und Armut unterbrochen oder daran gehindert überhaupt erst zu entstehen, was letztendlich zu einem Anstieg in der Kriminalität führt (Eck, 2005; Lutters & Ackerman, 1996).

Seitdem sind in den letzten Jahrzehnten weitere Nachbarschafts-Theorien entstanden, die versuchen Erklärungen dafür zu finden, dass in bestimmten Vierteln eine erhöhte Kriminalitätsrate vorzufinden ist. Ein Erklärungsversuch ist die Theorie der *Social Efficacy*, die untersucht, inwieweit die Bereitschaft der Anwohner einer Nachbarschaft vorhanden ist, sich für das Wohl der Allgemeinheit einzusetzen. Diese Einsatzbereitschaft ist laut Sampson et al. (1997) davon abhängig, wie groß das Vertrauen und die Solidarität unter den Nachbarn

ist. Eine niedrige Bereitschaft, führt demnach zu einer höheren Kriminalitätsrate in der Nachbarschaft (Sampson et al., 1997).

Ein zusätzlicher Theorieansatz ist die *Broken-Windows*-Theorie, die besagt, dass in einer Nachbarschaft, kleinerer Verstöße gegen soziale Normen, wie zum Beispiel das Versäumnis den Garten sauber zu halten, zu einem gewissen sozialen Druck führen. Dieser soziale Druck bringt laut Wilson und Kelling (1982) die Person, die den Verstoß begangen hat, zur Vernunft. Wenn die Nachbarschaft jedoch erst einmal verwahrlost ist, ziehen sich Bewohner*innen von der Durchsetzung der Normen zurück und die Bereitschaft, die soziale Ordnung durchzusetzen, geht zurück. Dies führt zu einer Abwärtsspirale mit einer immer weiteren Verschlechterung der Nachbarschaft und letztlich zu steigender Kriminalität (Eck, 2005).

Zusätzlich zu den genannten Theorien-Ebenen gibt es Ansätze, die Gebiete in einem noch größeren Maßstab betrachten, mit ganzen Städten oder Regionen als Hot Spots. Obwohl diese Theorien ebenfalls nützlich sind, sind sie für lokale Polizeidienststellen weit weniger hilfreich und werden daher nicht weiter behandelt (Eck, 2005).

5. Methoden im Crime-Hot-Spot-Mapping

Die sichere und konsequente Identifizierung von Hot Spots mithilfe von einfachen Punktkarten, die jeweils einzelne Straftaten auf der Karte darstellen, stellt sich vor allem in größeren Gebieten als Hürde da. So lassen sich dabei meist nur schwer einheitliche und eindeutige Hot Spots erkennen. In einem Versuch demonstriert Chainey (2005) die Mehrdeutigkeit dieser Kartierungsart, indem er drei verschiedene Kriminalitätsanalytiker*innen anhand derselben Punktkarte, die Kfz-Kriminalitätsdelikte im Londoner Bezirk Hackney aus dem Jahr 1999 zeigt, nach eigenem Ermessen Hot Spots identifizieren ließ (siehe Abbildung 5). Die Karte B zeigt das Ergebnis dieses Versuchs, wobei zu sehen ist, dass die Analytiker*innen jeweils unterschiedliche Hot Spots identifizierten. Zwei der von *Kriminalanalytiker 1* (blau) markierten Hot Spots unterschieden sich hierbei sogar völlig von denen der anderen beiden (Chainey, 2005).

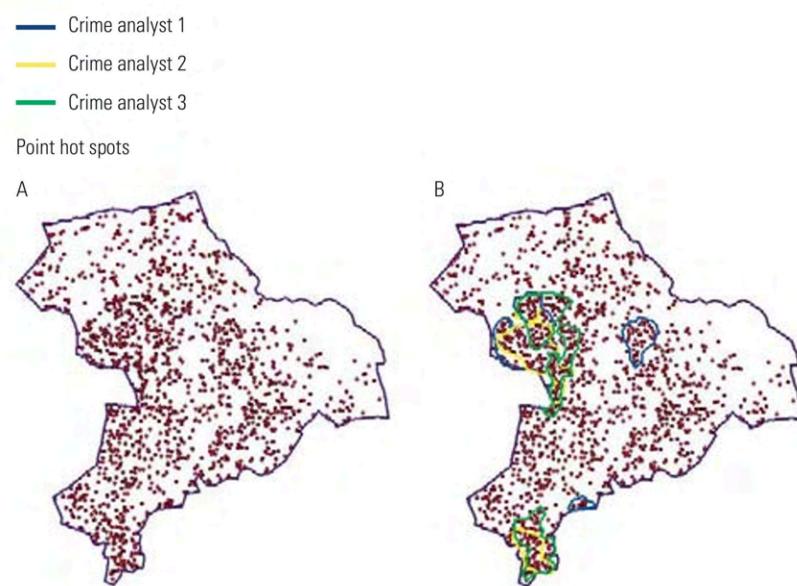


Abb. 5: Hot-Spot-Ermittlung anhand einer Punktkarte (Chaineys, 2005, S. 21)

Dieser Versuch verdeutlicht die Notwendigkeit von konsequenteren Methoden zur Identifizierung von Hot Spots. Neben der mittlerweile überholten Punktkartierung, kommen aus diesem Grund in Polizeibehörden seit der Verbreitung von GIS-Software weltweit unterschiedliche Mapping-Methoden zum Einsatz, die Kriminalitäts-Hot-Spots anhand verschiedener Kriterien und statistischen Methoden berechnen, um Polizist*innen eine einfachere und präzisere Interpretation und Analyse von Kriminalitätsschwerpunkten zu

ermöglichen (Chainey et al., 2008). In diesem Kapitel werden die wichtigsten und bewährtesten Mapping-Methoden vorgestellt, deren Wirksamkeit durch zahlreiche Studien belegt wurden und die weltweit in Polizeidienststellen zum Einsatz kommen (Chainey, 2005; Levine, 2004).

5.1 Hot-Spot-Ermittlung mithilfe thematischer Kartierung

Thematische Kartierungen stellen eine der am weit verbreitetsten Methoden im Hot-Spot-Mapping dar. Ähnlich wie Punktkarten sind diese schnell und einfach zu erstellen und setzen nur wenig technisches Fachwissen zur Interpretation voraus. Innerhalb dieser Methode wird im Allgemeinen zwischen zwei Vorgängen unterschieden (Chainey et al., 2008).

Zum einen der Vorgang der thematischen Kartierung von **geografischen Grenzgebieten**. Bei diesen Grenzgebieten handelt es sich meist um vordefinierte administrative oder politische Gebiete wie Stadtteile, Blöcke, Wahlbezirke oder Polizeibezirke. Straftaten, die zuvor als Punkte auf der Karte vorliegen, werden hierbei zu einem geografischen Grenzgebiet aggregiert und anschließend, je nach Ermessen, thematisch entsprechend der Anzahl an Straftaten kartiert. Ein Beispiel so einer Kartierung findet sich in Abbildung 6. Hierbei wurden erneut die Daten der Kfz-Kriminalitätsdelikte in Hackney kartiert, diesmal nach Zählbezirken, wobei drei konkrete Bereiche als Hot Spots identifiziert und blau umrandet wurden (Chainey, 2005).

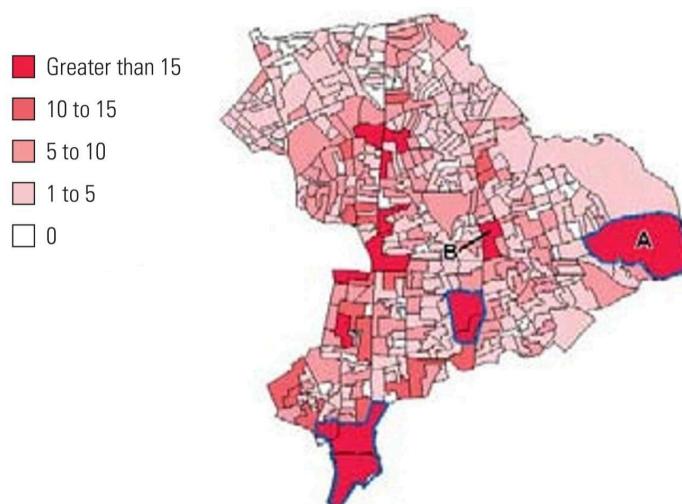


Abb. 6: Bsp. einer thematischen Kartierung von Grenzgebieten (Chainey, 2005, S. 24)

Um dem Problem der unterschiedlichen Gebietsgrößen und Formen der Hot Spots entgegenzuwirken, die bei der Kartierung von Grenzgebieten entstehen, gibt es den Vorgang der thematischen Kartierung im **Raster**. Dazu wird in einem GIS ein einheitliches Raster über das Untersuchungsgebiet gelegt und die einzelnen Rasterzellen je nach Anzahl der Ereignisse unterschiedlich schattiert. Diese kleinräumigeren und präziseren Raster ermöglichen es, die Verteilung der Kriminalität innerhalb größerer administrativ oder politisch definierter Grenzgebiete zu bestimmen und damit eine einheitlichere und genauere Darstellung der Verteilung der Kriminalität zu erhalten (Chainey, 2005; Chainey et al., 2008).

Abbildung 7 zeigt ein Beispiel einer solche Rasterkartierung. Dabei handelt es sich um dasselbe Beispielgebiet und denselben Datensatz für Kfz-Kriminalitätsdelikte, diesmal in 250 m² großen Rastern, wobei ermittelte Hot Spots erneut blau umrandet wurden. Interessant ist ein Vergleich der beiden thematischen Karten. Während das östliche Gebiet A aus Abbildung 6 in der Kartierung der Zählerbezirke als Hot Spot dargestellt ist, wird es in der Rasterkartierung nicht mehr als solcher erkannt. Dies lässt sich laut Chainey (2005) damit erklären, dass sich die Kriminalität in diesem Bereich A gleichmäßig über das Gebiet verteilt und daher in kleineren Rasterzellen nicht mehr als Hot Spot identifiziert wird. Solche präziseren Erkenntnisse, die durch die Kartierung kleinerer Rastern gewonnen werden, können letztlich für den Einsatz polizeilicher Maßnahmen von großem Nutzen sein (Chainey, 2005).

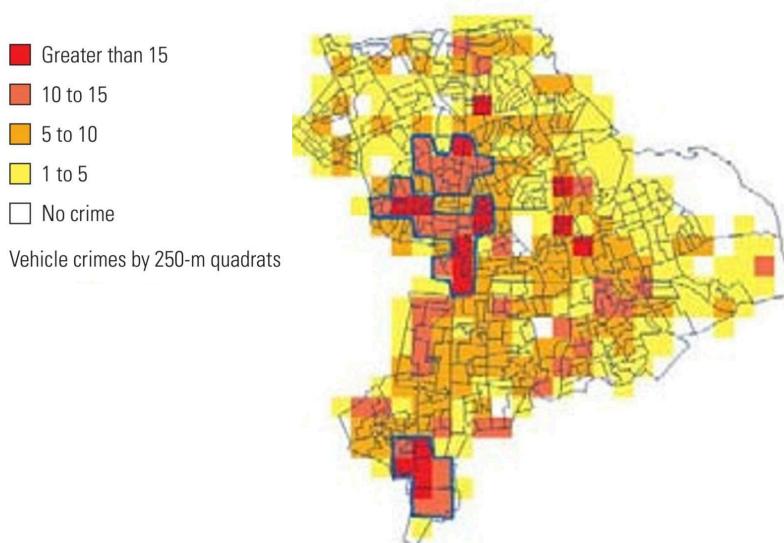


Abb. 7: Bsp. einer thematischen Kartierung im Raster (250 m²) (Chainey, 2005, S. 25)

5.2 Hot-Spot-Ermittlung durch Clustering

Die Identifizierung von Hot Spots mithilfe von Clusteringprozessen hat sich im Laufe der Zeit als ein gängiges Verfahren etabliert. Hierbei werden Kriminalitätsereignisse mithilfe spezieller Clusterroutinen zu Hot Spots in Form von Ellipsen oder konvexen Hüllen zusammenfasst (Levine, 2004). Im Weiteren werden die beiden wichtigsten Methoden zur Hot-Spot-Ermittlung dieser Art näher erläutert: *Spatial and Temporal Analysis of Crime* (STAC) und das *Nearest Neighbor Hierarchical Clustering* (NNH).

5.2.1 Spatial and Temporal Analysis of Crime (STAC)

Die Hot-Spots-Bestimmung mithilfe von Clusteringverfahren reicht historisch gesehen bis in die 1980er Jahre zurück. Die Polizeibehörde von Illinois in den USA erkannte damals die Wichtigkeit einer Methode, um Kriminalitätsereignisse nach bestimmten Kriterien zusammenfassen zu können. Vor diesem Hintergrund, entwickelte die *Illinois Criminal Justice Information Authority* im Jahr 1989 eine der ersten Softwareanwendungen zur Erkennung von Kriminalitätsbrennpunkten: die Spatial and Temporal Analysis of Crime (STAC) (Block, 1995).

Der Algorithmus der STAC-Software folgt bei der Erkennung von Kriminalitätsbrennpunkten immer einem bestimmten Schema. Zunächst beginnt er damit, ein Gitter über das zu untersuchende Gebiet zu legen und anschließend um jeden Knoten des Gitters einen Kreis zu platzieren. Der Abstand zwischen den Knoten des Gitters entspricht dabei genau der Hälfte des Kreisradius, sodass die Kreise sich stets überlappen und keine unabgedeckten Gebiete zurückbleiben. Mithilfe dieser anfänglich vergleichsweise großen Kreise werden zunächst grobe Kriminalitätsbrennpunkte identifiziert. Anschließend wird die Anzahl der Kriminalitätsereignisse in jedem Kreis erfasst und die Kreise entsprechend der jeweiligen Ereignisanzahl geordnet (Block, 1995).

Weiter wird ein zweites, feineres Raster erstellt, bei dem sowohl der Abstand der Knoten als auch der Radius der Kreise um die Hälfte reduziert sind. Dies ermöglicht die Lokalisierung kleinerer und präziserer Brennpunkt-Kreise innerhalb der zuvor identifizierten größeren Kreise, um spezifischere Muster zu erkennen. Auch hier werden die Kriminalitätsereignisse innerhalb der verkleinerten Kreise gezählt und nach dem gleichen Schema geordnet. Die Kreise mit der höchsten Anzahl an Ereignissen werden in der Karte als Hot-Spot-Kreise (A)

markiert (siehe Abbildung 8). Die Anwendung eines zweiten, verfeinerten Rasters dient demnach dazu, die Genauigkeit der Hotspot-Analyse zu verbessern (Block, 1995).

Im Anschluss ermittelt der STAC-Algorithmus, wo sich die verschiedenen berechneten Hot-Spot-Kreise überschneiden. Kriminalitätsereignisse innerhalb einer Gruppe von sich überschneidenden Hot-Spot-Kreisen werden in weiterer Folge zu einem sogenannten *Hot Cluster* zusammengefasst. Ereignisse innerhalb eines isolierten Kreises, der sich mit keinem anderen überschneidet, bilden ebenfalls einen Hot Cluster (Block, 1995).

Ellipsen können die tatsächliche Form von Kriminalitätsbrennpunkten jedoch um einiges besser abbilden als Kreise. Auf dieser Grundlage wurde der Algorithmus innerhalb der STAC-Software dahingehend programmiert, dass dieser für jeden Hot Cluster die jeweils am besten geeignete Standardabweichungsellipse berechnet. Diese Ellipsen werden anschließend mithilfe eines Geografischen Informationssystems (GIS) auf der Karte als endgültige Hot Spots (B) visualisiert. Somit ist die STAC-Software kein eigenständiges GIS, sondern vielmehr ein ergänzendes Werkzeug, das in Kombination mit einem GIS eingesetzt wird (Block, 1995; Chainey et al., 2008).

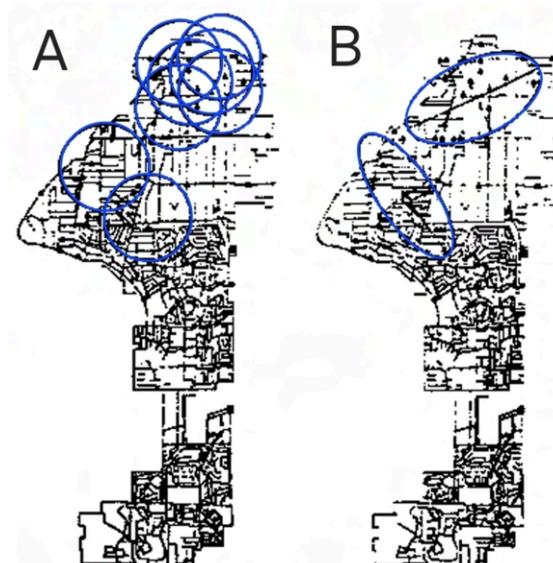


Abb. 8: STAC: Berechnete Standardabweichungsellipsen (B) (Block, 1995, S. 9)

Alternativ können Hot Cluster auch mittels konvexer Hüllen in der Karte dargestellt werden, wobei jeweils ein Polygon um die äußeren Punkte des Hot Clusters gezeichnet wird. Während die Ellipse eine Abstraktion eines Hot Spots repräsentiert, bietet die konvexe Hülle eine buchstäbliche Definition des Clusters (Levine, 2004). Abbildung 9 zeigt ein Beispiel für

den visuellen Unterschied zwischen konvexen Hüllen (Rosa) und berechneten Standardabweichungsellipsen (Grün).

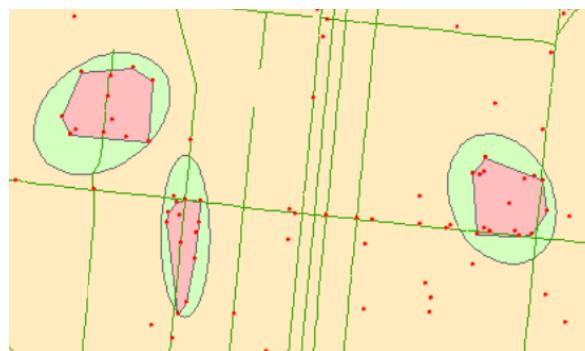


Abb. 9: STAC: Standardabweichungsellipsen und konvexe Hüllen (Levine, 2004, S. 512)

Ein Beispiel für die Bereitstellung beider Darstellungsmethoden ist die unter Kriminalanalytiker*innen beliebte Softwareanwendung *CrimeStat*. Entwickelt von Ned Levine & Associates mit finanzieller Unterstützung des National Institute of Justice, ermöglicht diese Anwendung umfangreiche Analysen von Punktdaten und stellt dafür eine Reihe von Methoden und Tools zur Verfügung (Kundakci, 2014). Neben STAC bietet *CrimeStat* auch die Analysemethode des Nearest Neighbor Hierarchical Clustering (NNH) an, welche im anschließenden Kapitel näher erläutert wird.

5.2.2 Nearest Neighbor Hierachical Clustering (NNH)

Nearest Neighbor Hierarchical Clustering (NNH) ist eine hierarchische Clusteringroutine, die den Abstand eines Ereignispunktes zu seinen nächstgelegenen Nachbarpunkten im Verhältnis zu allen Ereignispunkten im Untersuchungsgebiet berechnet. Basierend auf diesen Abständen und weiteren Kriterien werden bestimmte Punkte in Form von Ellipsen oder konvexen Hüllen in Clustern zusammengefasst (siehe Abbildung 10). Dafür muss zunächst ein konkreter Schwellenwert für den Abstand definiert werden, welcher anschließend mit den Abständen zwischen allen Punktpaaren verglichen wird. Nur diejenigen Punkte, die näher an einem oder mehreren anderen Punkten liegen als der definierte Schwellenwertabstand, werden zu einem Cluster zusammengefasst (Levine, 2004).

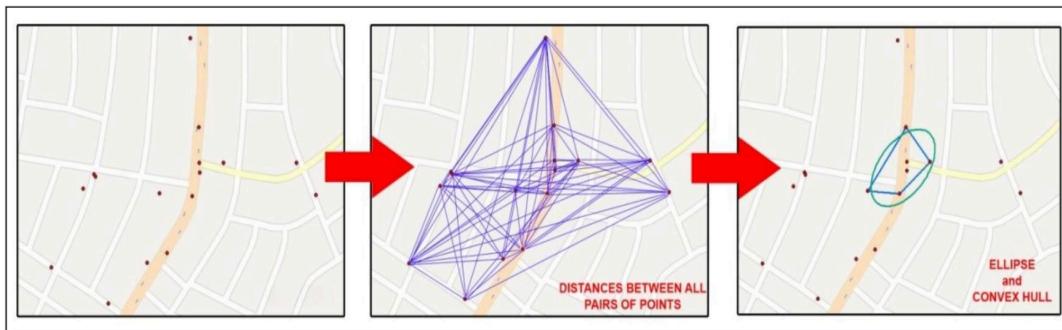


Abb. 10: NNH: Clusteringroutine in drei Schritten (Kundakci, 2014, S. 17)

Diese Routine wiederholt sich so oft, bis alle Ereignispunkte in einem einzigen Cluster zusammengefasst sind oder die Kriterien für die weitere Bildung von Clustern nicht mehr erfüllt sind (Levine, 2004).

Innerhalb von CrimeStat gibt es für die Wahl des Schwellenwertabstands zum einen die Möglichkeit, einen zufällig bestimmten Abstand zu ermitteln und zum anderen die Möglichkeit, selbstständig einen festen Abstand zu definieren. Die Besonderheit des zufällig bestimmten Schwellenwertabstands ist, dass dieser mithilfe statistischer Methoden aus den Punktdaten ermittelt wird. Dadurch ist der Schwellenwert variabel und passt sich der spezifischen räumlichen Verteilung der Punktdaten innerhalb des definierten Untersuchungsgebietes an. Zudem bietet diese Variante den Vorteil, dass die Wahl des Schwellenwertes nicht subjektiv bestimmt wird, wodurch verschiedene Analytiker*innen mit demselben Datensatz auch dieselben Cluster erhalten. Im Gegensatz dazu bietet das eigenständige Definieren eines Schwellenwertabstandes den Vorteil, dass die Anzahl der Cluster für verschiedene Arten von Verbrechen verglichen werden kann (Levine, 2004).

Unabhängig von der gewählten Variante für die Auswahl des Schwellenwerts, können bei sehr großen Datensätzen oftmals hunderte bis tausende Cluster gefunden werden, die näher beieinander liegen als der definierte Schwellenabstand. Um diese Vielzahl an Cluster zu minimieren, gibt es in CrimeStat zusätzlich die Möglichkeit, eine Mindestanzahl an Punkten anzugeben, die erforderlich sind, um ein Cluster bilden zu können. Dies ist in erster Linie hilfreich, um die Anzahl an sehr kleinen Clustern zu reduzieren, die sich oftmals aus nur einem Punktpaar bilden. Dabei hat die Wahl der Mindestanzahl keinen Einfluss auf die Auswahl der Cluster, sondern ausschließlich auf die Anzahl der ausgegebenen Cluster (Levine, 2004).

Damit Punkte zu Clustern zusammengefasst werden können, müssen diese also näher beieinander liegen als der Schwellenabstand und zu einer Gruppe mit einer Mindestanzahl von Punkten gehören. Diese erstmalig erzeugten Cluster werden als *Cluster erster Ordnung* definiert. Anschließend wird für jedes dieser Cluster das Zentrum mit dem geringsten Abstand zu allen Punkten im Cluster als sogenanntes *Clusterzentrum* definiert (Levine, 2004).

Diese Clusterzentren der Cluster erster Ordnung werden nun für den weiteren Verlauf der Routine als Referenzpunkte behandelt. Anhand dieser Punkte führt der Algorithmus ein erneutes Clustering durch, wobei die vorher definierten Kriterien für die Clusterbildung bestehen bleiben. Die hierbei erzeugten Cluster werden zu *Cluster zweiter Ordnung* (Levine, 2004). Diese Clusteringroutine wird nun so oft wiederholt, bis alle Sub-Cluster zu einem einzigen Cluster zusammengefügt wurden oder die Kriterien für die Bildung weiterer Cluster nicht mehr gegeben sind. Die finale Visualisierung der Cluster auf der Karte erfolgt ebenfalls als Ellipse oder als konvexe Hülle, wobei für die Ellipsendarstellung, ähnlich wie bei STAC, eine Ellipse auf Basis der Standardabweichung der Punkte im Cluster berechnet wird (Levine, 2004).

Um die Unterschiede zwischen Clustern unterschiedlicher Ordnung zu verdeutlichen, zeigt Abbildung 11 einen Vergleich zwischen Clustern erster Ordnung (grün) und dem darauf basierenden Cluster zweiter Ordnung (blau). Der Datensatz des Kartenausschnitts basiert hierbei auf Raubüberfällen in San Antonio in Texas im Jahr 2003 (Levine, 2004).

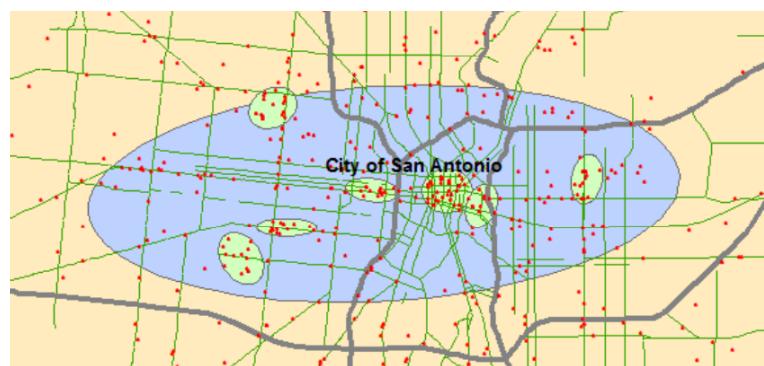


Abb. 11: NNH: Clustern erster und zweiter Ordnung (Levine, 2004, S. 509)

5.3 Hot-Spot-Ermittlung durch Kernel Density Estimation (KDE)

Die *Kernel Density Estimation* (KDE) oder auch *Kernel Density Interpolation* löst das Problem der homogenen Darstellung von Hot Spots mithilfe von vordefinierten geometrischen Formen wie Ellipsen, konvexen Hüllen und Rastern. Durch die Verwendung von Isoplethen werden Hot Spots innerhalb von KDE als kontinuierliche Risikogefälle vom Zentrum nach außen dargestellt, was eine genauere Wiedergabe der räumlichen Verteilung von Kriminalitätsschwerpunkten ermöglicht. Dabei wird diese Methode von vielen in der Literatur als die am besten geeignete Methode zur Ermittlung von Hot Spots hervorgehoben. KDE liefert für jeden Ort im Untersuchungsgebiet die Konzentration der Dichte an Kriminalitätsereignissen und gibt jeweils einen Z-Wert als Intensitätsvariable an. Im Gegensatz zur STAC-Methode, bei der viele Parameter eingegeben werden müssen, was zu schnell zu Mehrdeutigkeiten führt, besteht hier die einzige Aufgabe der Benutzer*innen darin, eine geeignete Bandbreite für die Schätzung anzugeben. Das Ergebnis ist eine kontinuierliche Oberfläche der geschätzten Dichte über das gesamte Untersuchungsgebiet, die als dreidimensionale Oberflächenkarte oder als zweidimensionale Konturenkarte dargestellt werden kann (siehe Abbildung 12) (Chainey et al., 2008; Levine, 2004; Wang et al., 2013).

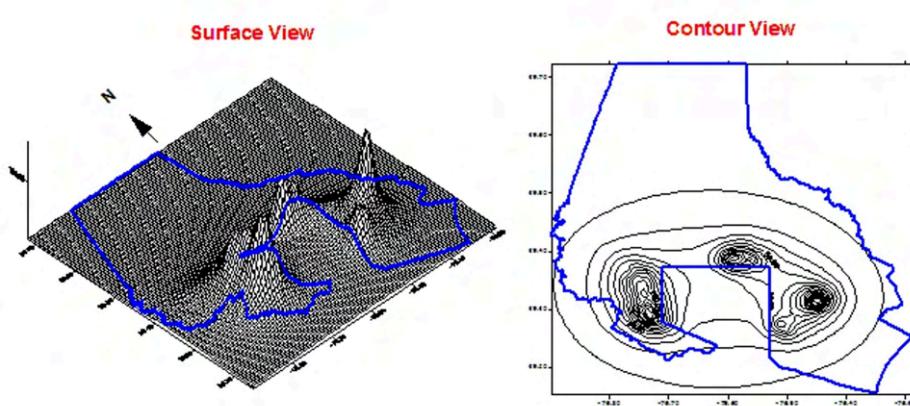


Abb. 12: KDE: Oberflächenkarte und Konturenkarte (Levine, 2004, S. 675)

Die KDE-Methode wurde in den 1950er Jahren als eine alternative Technik entwickelt, um die Dichteverteilung eines Histogramms zu schätzen. Ein Histogramm ist eine grafische Darstellung der Häufigkeitsverteilung von Daten, wobei die einzelnen Ereignisdaten in vordefinierte Intervalle (Bins) aufgeteilt sind. Die Methode basiert auf der Grundannahme, dass ein Histogramm einer glatten Dichteverteilung zugrunde liegt und daher nicht von

einzelnen Intervallgrößen abhängt. Um diese glatte Dichtefunktion aus einem Histogramm schätzen zu können, wurden ursprünglich die Mittelpunkte der benachbarten Intervalle einfach durch Linien miteinander verbunden (siehe Abbildung 13). Diese Methode der Verbindung der Intervallmittelpunkte führte jedoch oft zu Problemen wie dem Verlust einzelner Daten innerhalb der Intervalle und der Bildung einer diskontinuierlichen und nicht vollständig glatten Dichtefunktion (Levine, 2004).

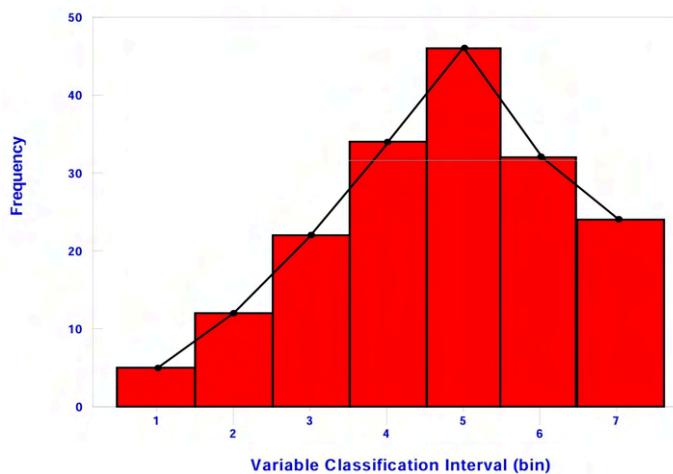


Abb. 13: KDE: Anfängliche Dichteschätzung eines Histogramms (Levine, 2004, S. 657)

Um diesen Problemen entgegenzuwirken, betrachtet die KDE-Methode keine Intervalle, sondern die einzelnen Datenpunkte selbst. Dabei wird über jeden Datenpunkt eine glatte und symmetrische Kernelfunktion gelegt. Dieser Vorgang wird in Abbildung 14 durch die roten gestrichelten Linien anhand von fünf Beispieldatenpunkten veranschaulicht. Anschließend werden an allen Stellen im Diagramm die einzelnen Kernel-Dichtefunktionen summiert, um schließlich eine kumulative Gesamtdichtefunktion zu erhalten (blaue Linie) (Levine, 2004).

Ein wichtiger Parameter dieser Methode ist die Bandbreite, also die Breite der Kernelfunktion, die je nach Ermessen variiert werden kann. Dadurch entstehen, je nach gewählter Bandbreite, unterschiedlich glatte Dichtefunktionen. Wie extrem diese Unterschiede in der Glätte sein können, zeigt die Abbildung 15. Die linke Grafik zeigt die anfängliche Kernelfunktion mit einer schmalen Bandbreite, was eine detaillierte Dichteschätzung ermöglicht und kleine Variationen hervorhebt. Die rechte Grafik zeigt dieselbe Kernelfunktion mit einer breiten Bandbreite, was eine glatte und generalisierte Dichteschätzung erzeugt (Levine, 2004).

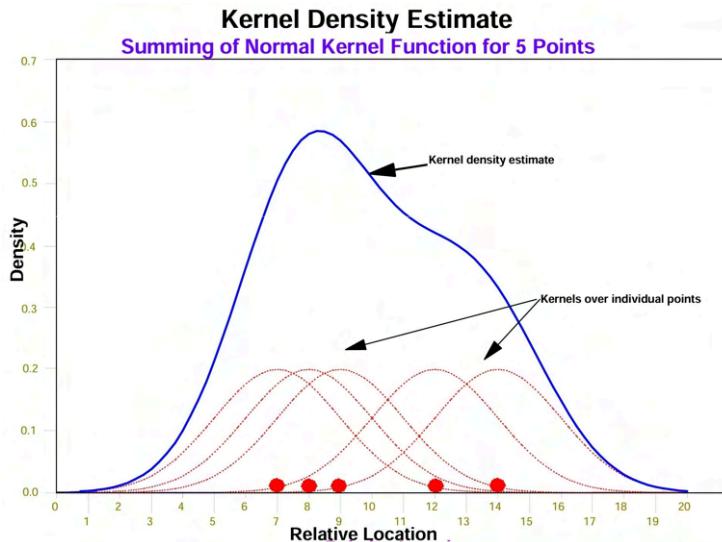


Abb. 14: KDE: Dichteschätzung anhand von 5 Beispieldaten (Levine, 2004, S. 659)

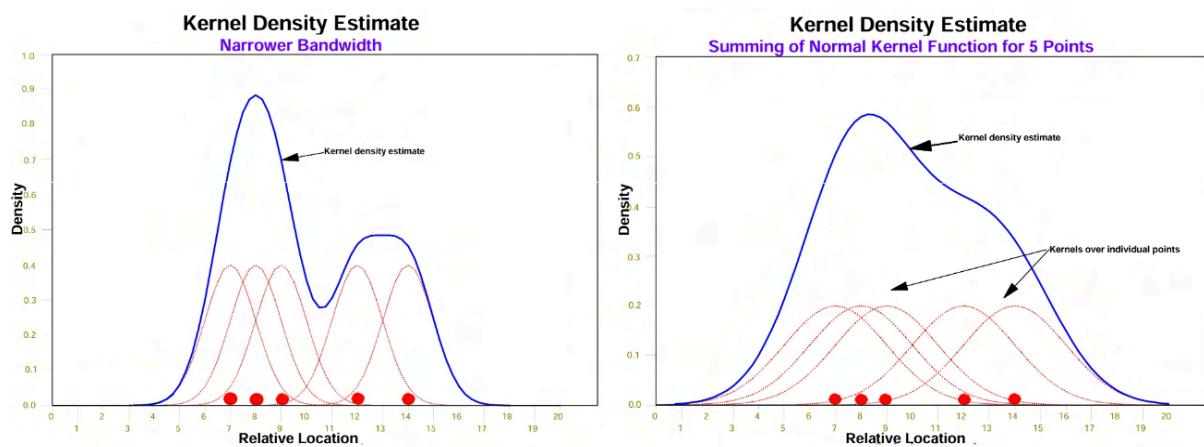


Abb. 15: KDE: Schmale und breite Bandbreite (Levine, 2004, S. 660, 661)

Levine (2004) vergleicht in seiner Arbeit fünf verschiedene Kernel-Funktionen, die zur Erkennung von Hot Spots in der Softwareanwendung CrimeStat zur Verfügung stehen: *Normal*, *Uniform*, *Quartic*, *Triangular* und *Negative Exponential*. Diese Funktionen unterscheiden sich jeweils in ihrer mathematischen Formel und damit auch in der Art und Weise, wie sie die Dichte um jeden Punkt schätzen. Die Unterschiede in der Berechnung führen dabei zu unterschiedlichen Kernelgraphen, die umliegende Punkte mit zunehmendem Entfernung unterschiedlich gewichten.

In Abbildung 16 ist ein direkter Vergleich der fünf Kernelfunktionen zu sehen. Während beispielsweise bei der negativen Exponentialverteilung (dunkelblau) der Abfall vom betrachteten Ereignispunkt aus extrem schnell ist und daher nahe Punkte viel stärker gewichtet werden als weiter entfernte Punkte, werden bei der Gleichverteilung (hellrot) alle Punkte innerhalb des Radius gleich gewichtet. Bei der quartischen Funktion (grün) werden nahe gelegene Punkte ebenfalls stärker gewichtet als weiter entfernte, jedoch fällt die Gewichtung mit zunehmender Entfernung um einiges langsamer ab (Levine, 2004).

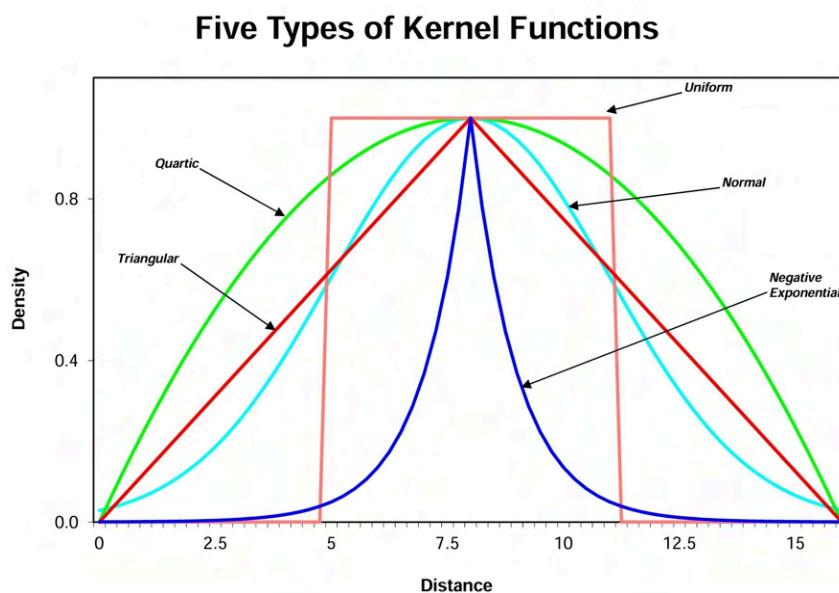


Abb. 16: KDE: Fünf Typen von Kernelfunktionen (Levine, 2004, S. 663)

Um nun mithilfe dieser Methode konkrete Kriminalitäts-Hot-Spots in einem bestimmten Gebiet schätzen zu können, wird wie folgt vorgegangen: Zunächst wird über jeden Kriminalitätsereignispunkt eine symmetrische, dreidimensionale Fläche gelegt, wobei die Form dieser Fläche durch die gewählte Kernelfunktion bestimmt wird. Die Höhe der Fläche, also die Intensität, ist dabei am Standort des Ereignisses am höchsten und nimmt mit zunehmender Entfernung, je nach Funktion, unterschiedlich ab (Levine, 2004). Anschließend wird für jeden Ereignispunkt der Abstand zu allen umliegenden Ereignissen innerhalb eines festgelegten Radius (Bandbreite) berechnet. Abhängig von der Anzahl der im Radius befindlichen Ereignisse und der gewählten Kernelfunktion unterscheidet sich nun, wie viel ein Ereignispunkt zur Höhe der Fläche, also letztlich zur Dichte, beiträgt (Levine, 2004; Chainey, 2005). Die berechneten Werte aller Ereignispunkte werden zum Schluss addiert, um eine kontinuierliche Schätzung der Dichte zu erhalten. Dabei gilt: Je höher der berechnete Wert, desto höher ist auch die geschätzte Dichte.

Um sich dieses Verfahren grafisch vorstellen zu können, zeigt die Abbildung 17 ein Beispiel, bei dem eine dreidimensionale Normalverteilung über vier Ereignispunkte gelegt wurde. Anschließend wurden diese Punkte auf einer Oberflächenkarte aufsummiert und entsprechend der berechneten Dichte dargestellt (Levine, 2004).

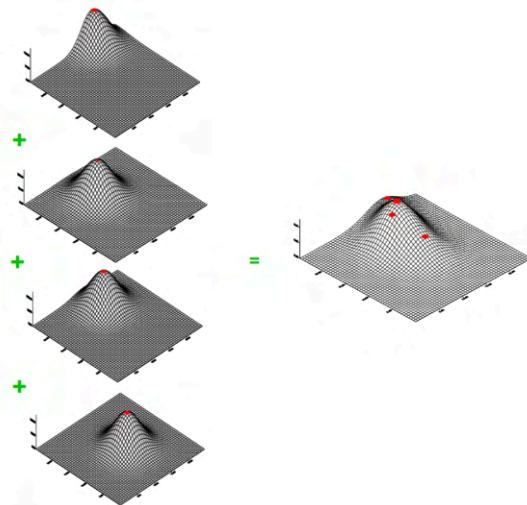


Abb. 17: KDE: Normalverteilung anhand von 4 Beispelpunkten (Levine, 2004, S. 667)

In einem letzten Schritt werden die Ergebnisse in einem GIS visualisiert, wobei die Hot Spots farblich oder durch Schattierung hervorgehoben und je nach Wert abgestuft werden (Levine, 2004). Chainey (2005) gibt ein Beispiel für eine fertige Hot-Spot-Dichtekarte (siehe Abbildung 18), die erneut auf dem Datensatz für Kfz-Kriminalität in Hackney basiert und mit der quartischen Kernelfunktion berechnet und anschließend geglättet dargestellt wurde. Die ausgewählte Bandbreite beträgt hier 220 Meter (Chainey, 2005).

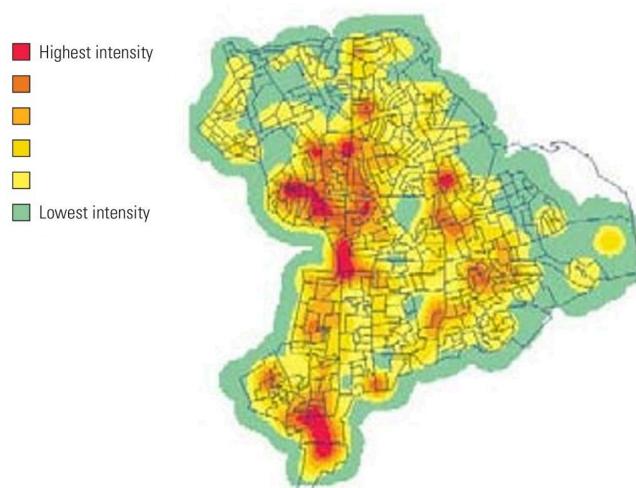


Abb. 18: KDE: Bsp. einer Hot-Spot-Dichtekarte (Chainey, 2005, S. 28)

5.4 Hot-Spot-Ermittlung mithilfe statistischer Analysen räumlicher Beziehungen

Die Ermittlung von Hot Spots mithilfe statistischer Analysen räumlicher Beziehungen zählt laut Chainey (2005) zu den nützlichsten Methoden, um Hot Spots zu identifizieren. Diese Methoden basieren auf der Grundannahme, dass die Verteilung von Kriminalität geclustert vorliegt. Um diese Cluster identifizieren zu können, gibt es verschiedene Ansätze, wobei die meisten Methoden auf den Grundprinzipien der Hypothesentests und der klassischen Statistik beruhen. Hierbei wird von der Nullhypothese ausgegangen, dass die Verteilung von Straftaten zufällig ist. Diese Hypothese wird anschließend mit einem bestimmten Signifikanzniveau verglichen, um sie anzunehmen oder abzulehnen (Chainey, 2005). Während die bereits genannten Analysemethoden lediglich die Lage von Orten mit einer hohen Kriminalitätsdichte aufzeigen, können statistische Analysen feststellen, ob es sich dabei auch um statistisch signifikante Hot Spots handelt.

Zu den wichtigsten statistischen Analysemethoden für räumliche Beziehungen zählt der *Nearest Neighbor Index* (NNI) sowie räumliche Autokorrelationsstatistiken auf lokaler Ebene, insbesondere Statistiken innerhalb des *Local Indicator of Spatial Association* (LISA) Konzepts, wie die *Anselin's Local Moran Ii-* und *Getis-Ord Local "Gi"-Statistik* (Chainey, 2005; Levine, 2004).

5.4.1 Nearest Neighbor Index (NNI)

Um festzustellen, ob im betrachteten Untersuchungsgebiet auch tatsächlich eine statistisch signifikante Clusterbildung in Form von Hot Spots vorliegt, greifen viele Analytiker*innen auf den Nearest Neighbor Index (NNI) zurück (Shariff et al., 2018). Der NNI stellt eine Maßzahl der räumlichen Autokorrelation auf globaler Ebene dar, um die Verteilung von Punktereignissen im gesamten Untersuchungsgebiet statistisch zu bewerten. Die Ermittlung des NNI erfolgt durch einen einfachen und schnellen Test auf Clusterbildung, indem die tatsächliche Verteilung von Kriminalitätseignissen mit einer zufälligen bzw. erwarteten Verteilung verglichen wird. Auf diese Weise kann bereits im Vorfeld einer erstellten Hot-Spot-Karte, ein Verständnis darüber vermittelt werden, was im Untersuchungsgebiet zu erwarten ist.

Für die Bestimmung des Index folgen Analysten einem bestimmten Ablauf: Zunächst wird für jeden Kriminalitätseignispunkt der Abstand zum nächsten Nachbarpunkt berechnet. Anschließend werden die Nachbarschaftsdistanzen für alle Kriminalitätspunkte addiert und durch die Anzahl aller Punkte geteilt. Dieser Wert ist somit der beobachtete durchschnittliche Abstand der nächsten Nachbarn (Chainey, 2005). Im nächsten Schritt wird für dasselbe Gebiet eine simulierte Zufallsverteilung mit derselben Anzahl an Kriminalitätspunkten erstellt. Auch hier wird für jeden Ereignispunkt der Abstand zum nächsten Nachbarpunkt gemessen und anschließend die Summe der nächsten Nachbarabstände durch die Anzahl aller Punkte geteilt. Dieser Wert gilt als der zufällige durchschnittliche Abstand der nächsten Nachbarn (Chainey, 2005).

Der NNI-Ergebniswert ist schließlich das Verhältnis des beobachteten durchschnittlichen Abstands der nächsten Nachbarn, geteilt durch den zufälligen durchschnittlichen Abstand der nächsten Nachbarn (Chainey, 2005).

Shariff et al. (2018) beschreiben in ihrer Arbeit noch eine zweite, eng verwandte Methode der Berechnung des NNI, wobei eine eigenständige Formel verwendet wird, um anstelle des zufälligen, den erwarteten durchschnittlichen Abstand der nächsten Nachbarn zu berechnen. Diese Methode bietet den Vorteil, keine extra simulierte Zufallsverteilung generieren zu müssen. Stattdessen basiert die Methode auf der Annahme einer idealen Zufallsverteilung innerhalb des definierten Gebietes. Die Berechnungen des beobachteten durchschnittlichen Abstands der nächsten Nachbarn bleibt dabei gleich (Shariff et al., 2018).

Die Formel für die Berechnung des erwarteten Abstands der nächsten Nachbarn ergibt sich aus der Wurzel der Größe der Fläche des Untersuchungsgebietes geteilt durch die Anzahl aller im Gebiet liegenden Kriminalitätspunkte. Das Ergebnis der Wurzel wird anschließend mit 0,5 multipliziert (siehe Formel 1) (Shariff et al., 2018).

$$\text{Expected Average Nearest Neighbor} = \frac{1}{2} \sqrt{\frac{\text{Area}}{\text{Number of Points}}}$$

Formel 1: Berechnung des erwarteten Abstands der nächsten Nachbarn für NNI (Shariff et al., 2018, S. 148)

Der NNI ist hierbei folglich das Verhältnis des beobachteten durchschnittlichen Abstands der nächsten Nachbarn, geteilt durch den erwarteten durchschnittlichen Abstand der nächsten Nachbarn (Shariff et al., 2018).

Unabhängig von der gewählten Methode zur Ermittlung des NNI bleibt die Interpretation der Ergebnisse gleich: Ist das Ergebnis der Gleichung 1, so liegt die Verteilung der Kriminalitätsereignisse im Untersuchungsgebiet zufällig vor. Ist das Ergebnis kleiner als 1, weisen die Kriminalitätsdaten Anzeichen einer Clusterbildung oder Häufung auf, wobei gewisse Ereignisse näher beieinander liegen, als es bei einer zufälligen Verteilung möglich wäre. Wenn das Ergebnis jedoch größer als 1 ist, deutet dies auf eine gleichmäßige oder gestreute Verteilung der Ereignisse im Gebiet hin, ohne Anzeichen auf Clusterbildung. (Shariff et al., 2018; Chainey, 2005).

Um das Ergebnis des NNI-Tests statistisch zu bewerten, wird abschließend eine Z-Score-Statistik angewendet, die die statistische Signifikanz der Ergebnisse misst. (Shariff et al., 2018). Diese Statistik gibt an, wie sehr sich der tatsächliche durchschnittliche Abstand der nächsten Nachbarn von dem durchschnittlichen zufälligen bzw. erwarteten Abstand der nächsten Nachbarn unterscheidet. Die Signifikanz des Z-Scores kann in jeder NNI-Ergebnistabelle gefunden werden und folgendermaßen interpretiert werden: Je negativer der Z-Score, desto größer ist das Vertrauen in den NNI-Ergebniswert. Dabei ist anzumerken, dass der Z-Score bei größeren Stichprobengrößen auch größer negativ ausfällt (Chainey, 2005).

In Abbildung 19 findet sich ein Beispiel für eine solche Ergebnistabelle. Diese basiert auf einem erweiterten Kriminalitätsdatensatz von Hackney in London für das Jahr 1999 und zeigt den Vergleich der berechneten NNI-Werte und Z-Scores für Raubüberfälle, Wohnungseinbrüche und Kfz-Kriminalität sowie für den gesamten Kriminalitätsdatensatz. Dabei ist deutlich der Einfluss des größeren Stichprobenumfangs des gesamten Kriminalitätsdatensatzes zu erkennen, wodurch der Z-Score hier deutlich negativer ausfällt. Alle NNI-Ergebniswerte weisen einen Wert unter 1 sowie einen deutlich negativen Z-Score auf. Dies bedeutet, dass für alle Datensätze eine statistisch signifikante Clusterbildung in Form von Hot Spots vorliegt (Chainey, 2005).

Crime type and bounding area*	NNI	Z-score
All crime		
Bounding rectangle area	0.32	-129.11
True boundary area	0.46	-103.14
Robbery		
Bounding rectangle area	0.59	-19.14
True boundary area	0.80	-9.20
Residential burglary		
Bounding rectangle area	0.57	-27.14
True boundary area	0.74	-16.46
Vehicle crime		
Bounding rectangle area	0.52	-38.73
True boundary area	0.72	-22.16

Abb. 19: NNI: Bsp. einer Ergebnistabelle (Chainey, 2005, S. 18)

5.4.2 Local Indicator of Spatial Association (LISA)

Der NNI bietet also eine nützliche erste Einschätzung dessen, was in einer Karte zu erwarten ist. Jedoch zeigt der NNI dabei nicht die spezifische Lage von Clustern oder die allgemeine räumliche Verteilung von Datenpunkten auf einer Karte. Um den Aspekt der statistischen Signifikanz mit dem Aspekt der visuellen Darstellung auf der Karte zu verbinden, nutzen Analytiker*innen räumliche Autokorrelationsstatistiken auf lokaler Ebene (Levine, 2004). Diese bewerten nicht nur, ob eine räumliche Beziehung zwischen Datenpunkten besteht, sondern identifizieren auch die jeweiligen Standorte (Chainey, 2005).

Local Indicator of Spatial Association (LISA) bildet das Grundkonzept für räumliche Autokorrelation auf lokaler Ebene und stellt eine der fortschrittlichsten Methoden für die Ermittlung von Hot Spots dar (Levine, 2004; Chainey, 2005). LISA-Statistiken sind ein Indikator für das Ausmaß, in dem der Wert einer Beobachtung durch benachbarte Beobachtungen beeinflusst wird. Dabei werden zwei Bedingungen vorausgesetzt: Zum einen, dass jede Beobachtung zusätzlich zu ihrem X und Y Koordinatenwert, einen weiteren zugewiesenen Identitätswert einer Attributvariablen hat. Im Falle von Kriminalitätsereignissen werden die einzelnen Daten hierfür in bestimmte Zonen aggregiert, wie zum Beispiel

Zählbezirken oder Postleitzahl-Gebiete. Zum anderen muss eine konkrete Nachbarschaft definiert sein (Levine, 2004).

Mithilfe verschiedener LISA-Statistiken lassen sich somit lokale Zusammenhänge zwischen Datenpunkten bewerten, indem lokale Durchschnittswerte von kleineren Gebietsteilen mit dem globalen Durchschnittswert des gesamten Gebiets verglichen werden. Die zwei wichtigsten LISA-Statistiken für die Ermittlung von Hot Spots sind die Anselin's Local Moran Ii- und Getis-Ord Local Gi Statistik (Levine, 2004).

5.4.2.1 Anselin's Local Moran II

Die Anselin's Local Moran II Statistik wurde von Luc Anselin im Jahr 1995 entwickelt und stellt die älteste LISA-Statistik dar. Das Verfahren baut auf der globalen Moran's I Statistik auf, die, ähnlich wie der NNI, die globale räumlichen Autokorrelation misst, wobei jeder Ereigniswert mit allen anderen Werten im Untersuchungsgebiet verglichen wird. Dieses Routineverfahren wird innerhalb der II-Statistik auf einzelne lokale Zonen angewandt, um die räumliche Autokorrelation auf lokaler Ebene zu bestimmen. Das Ziel ist es aufzuzeigen, wie ähnlich eine Zone im Vergleich zu ihrer lokalen Umgebung ist. Dabei werden einerseits Cluster von benachbarten Zonen mit ähnlichen Werten identifiziert und andererseits Zonen, die sich signifikant von ihren Nachbarn unterscheiden (Levine, 2004).

Die Formel der Anselin's Local Moran I_i Statistik ist wie folgt definiert:

$$I_i = \sum_{j \in J_i} w_{ij} z_j$$

Formel 2: Berechnung des Anselin's Local Moran II (Ratcliffe, 2010, S. 13)

Hierbei ist der **Ii**-Wert das Maß für die räumliche Autokorrelation für die beobachtete Zone i. z_j stellt den standardisierten Identitätswert der benachbarten Zone j dar. Standardisiert bedeutet in diesem Fall, dass der Wert so angepasst wurde, dass er den Mittelwert 0 und die Standardabweichung 1 hat, wodurch dieser sich über unterschiedliche Zonen hinweg vergleichen lässt. w_{ij} beschreibt das Abstandsgewicht zwischen der beobachteten Zone i und der benachbarten Zone j, das mit zunehmender Entfernung der beiden Zonen abnimmt. Damit lässt sich die räumliche Beziehung definieren, wobei eine weit entfernte Zone j einen

geringeren Einfluss auf die Zone i hat als eine näher gelegene. $j \in J_i$ besagt, dass nur diejenigen Zonen j in die Summe mit einbezogen werden, die in der Menge J_i sind, also als Nachbarn von Zone i definiert sind. Im Allgemeinen berücksichtigt die I_i -Statistik also im Gegensatz zur globalen I -Statistik nur die benachbarten Zonen j von i und nicht das gesamte Gebiet (Anselin, 1995; Ratcliffe, 2010; Levine, 2004).

Wenn benachbarte Zonen ähnliche Attributwerte aufweisen, ist der Wert der I_i -Statistik positiv. Das bedeutet, dass der I_i -Wert sowohl positiv ist, wenn die betrachtete Zone und die benachbarten Gebiete um die betrachtete Zone herum jeweils hohe Attributwerte aufweisen, als auch, wenn die betrachtete Zone und die benachbarten Gebiete jeweils niedrige Attributwerte aufweisen. Ob es sich um mehrere ähnliche benachbarte Zonen mit einer hohen Dichte an Ereignissen handelt (Hot Spots) oder um mehrere Zonen mit einer niedrigen Dichte an Ereignissen (Cold Spots) kann aus dem I_i -Wert nicht herausgelesen werden. Der Wert der Statistik ist demnach ausschließlich ein Indikator für die Ähnlichkeit, jedoch nicht für den absoluten Wert der Intensitätsvariable (Levine, 2004).

Ist der I_i -Wert allerdings negativ, bedeutet das, dass eine Unähnlichkeit vorliegt, wobei die beobachtete Zone entweder einen hohen Attributwert aufweist, während ihre Nachbarn niedrige Werte aufweisen oder anders herum, dass die betrachtete Zone einen niedrigen und die benachbarten Gebiete einen hohen Wert aufweisen (Levine, 2004).

Zonen mit stark negative Ergebniswerte stellen sogenannte "räumlich isolierte" Hot Spots oder Cold Spots dar. Ein Hot Spot liegt vor, wenn die Anzahl der Ereignisse in der betrachteten Zone deutlich größer ist als in den benachbarten Gebieten. Im Gegensatz dazu liegt ein Cold Spot vor, wenn die Anzahl der Ereignisse in der betrachteten Zone deutlich niedriger ist als in den benachbarten Gebieten. Ob es sich jeweils um ein Cold Spots oder Hot Spot handelt, lässt sich aus der Ergebniskarte jedoch nicht entnehmen (Levine, 2004).

Berechnung der statistischen Signifikanz des I_i -Werts:

Zur Beurteilung der statistischen Signifikanz der berechneten I_i -Werte gibt es drei etablierte Methoden, die sich gegenseitig ergänzen. Mit ihrer Hilfe kann abgeschätzt werden, ob es sich bei den identifizierten Zonen mit einer hohen räumlichen Autokorrelation nicht nur um Zufälle handelt, sondern um tatsächlich signifikante Hot Spots oder Cold Spots. Die erste Methode verwendet die Varianz und den Erwartungswert für jede Zone i , um einen Z-Score zu berechnen:

$$Z_{Ii} = \frac{I_i - E[I_i]}{\sqrt{Var[I_i]}}$$

Formel 3: Berechnung des Z-Scores für den Ii-Wert (In Anlehnung an Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.)

Wobei gilt:

$$E[I_i] = -\frac{\sum_{j=1, j \neq i}^n w_{ij}}{n - 1}$$

Formel 4: Berechnung des Erwartungswerts von Ii (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.)

$$V[I_i] = E[I_i^2] - E[I_i]^2$$

Formel 5: Berechnung der Varianz von Ii (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.)

E[Ii] ist hierbei der Erwartungswert von Ii, **Var[Ii]** ($V[I_i]$) stellt die Varianz von Ii dar und **n** die Gesamtzahl der Beobachtungen. **j=1, j ≠ i** bedeutet, dass die Berechnung bei der ersten Zone beginnt ($j=1$) und dabei spezifisch die Zone i ausgeschlossen wird ($j \neq i$) (Anselin, 1995, S. 93-115; Funktionsweise des Werkzeugs „Cluster- und Ausreißeranalyse (Anselin Local Morans I)“ - ArcGIS Pro, o. D.).

Die zweite Methode schätzt die Konfidenzintervalle, um die Signifikanz des Ii-Werts zu beurteilen. Unter der Voraussetzung, dass die Stichprobengröße größer als 120 ist, lassen sich 95 % und 99 % Konfidenzintervalle mit folgenden Formen abschätzen:

$$95\% \text{ confidence intervals} = I_i \pm 1.98SE_i$$

$$99\% \text{ confidence intervals} = I_i \pm 2.58SE_i$$

Formel 6: Schätzung der 95% und 99% Konfidenzintervalle für I_i (Levine, 2004, S. 609)

SE_i stellt die Standardabweichung von I_i dar und wird durch das Ziehen der Quadratwurzel aus der Varianz von I_i bestimmt (Levine, 2004).

Wenn der Stichprobenumfang allerdings zu klein ist oder I_i möglicherweise nicht einer normalen Standardverteilung folgt, könnte das zu Ungenauigkeiten innerhalb dieser Berechnungsmethode führen. Aus diesem Grund gibt es noch eine dritte Methode, um die Signifikanz von I_i zu beurteilen. Dabei wird eine sogenannte *Monte-Carlo-Simulation* angewendet, die eine Simulation vom Typ *Permutation* durchgeführt, um damit sogenannte "glaubhafte Intervalle" zu schätzen. Hierbei werden die Standorte der Zonen konstant gehalten, während die ursprünglichen Werte der Intensitätsvariable Z zufällig unter den Zonen neu zugewiesen werden. Dieser Prozess wird viele Male wiederholt (100 - 10.000 Mal), um eine Verteilung von I_i unter der Annahme der Zufälligkeit zu generieren. Aus dieser simulierten Verteilung können anschließend glaubhafte Intervalle für I_i abgeleitet werden. Die Simulation gibt also eine Vorstellung davon, wie stark der beobachtete I_i -Wert von dem abweicht, was man unter zufälligen Bedingungen erwarten würde. Unterscheidet sich der beobachtete Wert von I_i deutlich von dem, was in der Simulation beobachtet wird, wird dieser als statistisch signifikant angesehen. Da hierbei von keiner Normalverteilung ausgegangen werden muss und stattdessen die tatsächliche Verteilung der Daten berücksichtigt wird, ist diese Simulationsmethode oft robuster (Levine, 2004).

Abschließend wird für jede Zone noch ein p-Wert berechnet, der die statistische Signifikanz des Z-Scores bewertet. Der p-Wert ist ein Maß für die Wahrscheinlichkeitsverteilung des berechneten Z-Scores. Dieser Wert gibt somit die Wahrscheinlichkeit an, ob die ermittelten stark positiven bzw. negativen Autokorrelationen zufällig entstanden sind. Ist der p-Wert sehr klein (<0,05), bedeutet das, dass es äußerst unwahrscheinlich ist, dass eine starke Autokorrelation das Ergebnis eines zufälligen Prozesses ist. Umgekehrt deutet ein hoher p-Wert darauf hin, dass eine beobachtete Autokorrelation auch bei einer zufälligen Verteilung der Ereignisse zu erwarten wäre. Im Allgemeinen gehen sowohl sehr hohe, als auch sehr niedrige Z-Scores mit sehr kleinen p-Werten einher (siehe Abbildung 20). Während der

Z-Score in einer Karte visualisiert wird, um die räumliche Autokorrelation der Zonen darzustellen, wird der p-Wert meist in einer Zusatztabelle für die Interpretation der Z-Scores aufgelistet (Wang et al., 2013; Was ist ein Z-Wert? Was ist ein p-Wert? - ArcGIS Pro, o. D.)

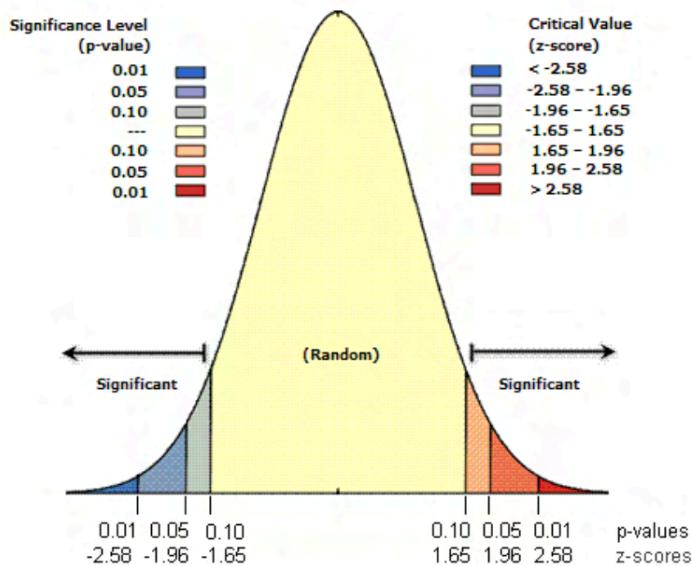


Abb. 20: Local Moran II: Verhältnis von p-Wert und Z-Score (Was ist ein Z-Wert? Was ist ein p-Wert? - ArcGIS Pro, o. D.)

Abbildung 21 liefert eine Beispielkarte, in der die Zonen nach dem berechneten Z-Wert des Local Moran II dargestellt sind. Die Karte basiert auf einem Datensatz zu Fahrzeugdiebstählen in Baltimore im Jahr 1996. Dunkelrote Bereiche zeigen hierbei stark negative Z-Werte ($> -2,58$ (99 % Signifikanzniveau)), was auf Zonen mit starker räumlicher Unähnlichkeit zu den benachbarten Zonen hinweist. Dunkelblaue Bereiche zeigen dagegen Gebiete mit stark positiver räumlicher Autokorrelation ($Z > 2,58$), in denen Fahrzeugdiebstähle sehr ähnlich zu den benachbarten Gebieten konzentriert sind. Die hellblauen und hellroten Gebiete zeigen negative bzw. positive Z-Score-Werte mit einem Signifikanzniveau von 95% an, mit Z-Werten über +1,96 bzw. unter -1,96. Um nun erkennen zu können, ob es sich bei diesen Gebieten um Hot Spots oder Cold Spots handelt, liefert Levine (2004) eine zweite Referenzkarte (siehe Abbildung 22), in der die absoluten Zahlen der Fahrzeugdiebstähle für jede Zone darstellt sind. Durch den Vergleich der beiden Karten kann schließlich festgestellt werden, ob es sich bei den jeweiligen Zonen mit signifikant hohen bzw. niedrigen Z-Score-Werten um Hot Spots oder Cold Spots handelt (Levine, 2004).

Local Spatial Autocorrelation of 1996 Vehicle Thefts

Local Moran Z-Value of Block Groups

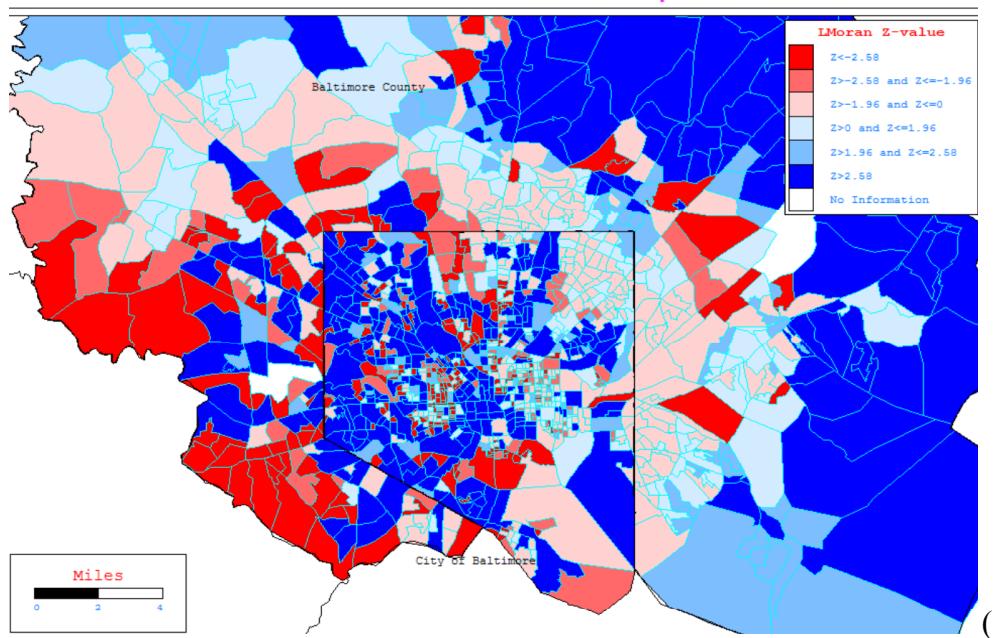


Abb. 21: Local Moran II: Beispielkarte (Levine, 2004, S. 612)

1996 Motor Vehicle Thefts

Number of Auto Thefts Per Block Group

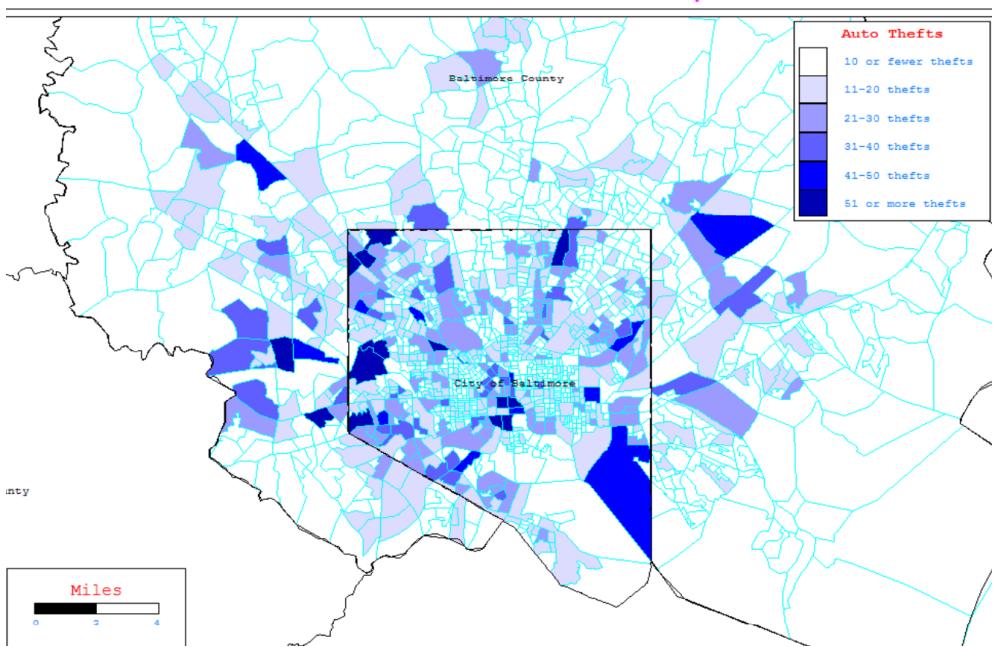


Abb. 22: Local Moran II: Bsp. Referenzkarte (Levine, 2004, S. 611)

5.4.2.2 Getis-Ord Local Gi

Die Getis-Ord Local Gi-Statistik stellt die am häufigsten angewandte LISA-Statistik dar (Chainey, 2005). Diese Statistik baut auf der globalen Getis-Ord G-Statistik auf, die die räumliche Autokorrelation im gesamten Untersuchungsgebiet bestimmt und dabei einen einzigen globalen Ergebniswert zurückgibt. Getis-Ord Local Gi wendet diese globale Statistik, ähnlich wie Local Moran II, auf einzelne lokale Zonen an und bestimmt so, ob bestimmte Zonen in einem statistisch signifikanten räumlichen Zusammenhang zu ihren Nachbarzonen stehen (Levine, 2004). Während der Local Moran II lediglich eine positive oder negative räumliche Autokorrelation erkennt, also ähnliche und unähnliche benachbarte Zonen, identifiziert die Gi-Statistik konkrete statistisch signifikante Hot Spots und Cold Spots.

Die vereinfachte Formel, um den Rohwert für Gi zu berechnen, ist folgende:

$$G_i^* = \frac{\sum_{j=1}^n w_{ij} x_j}{\sum_{j=1}^n x_j}$$

Formel 7: Berechnung des Getis-Ord Local Gi (Manepalli et al., 2011, S.4)

wobei w_{ij} erneut die räumliche Gewichtung zwischen den Zonen i und j darstellt und x_j den Identitätswert der Zone j. n ist die Gesamtzahl der Ereignisse und $j=1$ beschreibt, dass die Berechnung bei der ersten beobachteten Zone beginnt (Li et al., 2017; Manepalli et al., 2011).

Um den standardisierten Z-Score von Gi zu berechnen und damit die statistische Signifikanz nachweisen zu können, kommt folgende Formel zum Einsatz:

$$Z(G_i^*) = \frac{\sum_{j=1}^n w_{ij} x_j - \bar{x} \sum_{j=1}^n w_{ij}^2}{S \sqrt{\frac{n \sum_{j=1}^n w_{ij}^2 - (\sum_{j=1}^n w_{ij})^2}{n-1}}}$$

Formel 8: Berechnung des Z-Scores für Gi (Manepalli et al., 2011, S.5)

Wobei gilt:

$$\bar{X} = \frac{\sum_{j=1}^n x_j}{n}, \quad S = \sqrt{\frac{\sum_{j=1}^n x_j^2}{n-1} - (\bar{X})^2}$$

Formel 9: Berechnung des arithmetischen Mittels und der Standardabweichung für Gi (Li et al., 2017, S.686)

\bar{X} steht hierbei für das arithmetische Mittel, also den Mittelwert des Identitätswertes x_j über alle Zonen j . S für die Standardabweichung des Identitätswerts.

Ein hoher Identitätswert einer Zone i stellt nicht automatisch einen statistisch signifikanten Hot Spot dar. Stattdessen muss diese Zone inmitten anderer Zonen mit ähnlich hohen Werten liegen. Ob nun eine statistische Signifikanz vorliegt, wird durch einen Vergleich mit globalen Werten bestimmt, indem die lokale Summe der beobachteten Zone i und seiner Nachbarn j proportional mit der Summe aller Zonen im Untersuchungsgebiet verglichen wird. Unterscheidet sich diese lokale Summe so signifikant von der erwarteten lokalen Summe, wie es allein durch Zufall nicht möglich wäre, so ergibt sich ein statistisch signifikanter Z-Score. Vereinfacht ausgedrückt kann sich ein signifikanter Z-Score nur dann ergeben, wenn sowohl die beobachtete Zone i einen hohen Identitätswert aufweist, als auch die benachbarten Zonen j in der direkten Umgebung. Der jeweilige Z-Score-Wert gibt dann konkret an, wie viele Standardabweichungen der Wert von Gi der Zone i vom erwarteten Mittelwert entfernt ist (How Hot Spot Analysis (Levine, 2004; Getis-Ord Gi^* works - ArcGIS Pro, o. D.; Was ist ein Z-Wert? Was ist ein p-Wert? - ArcGIS Pro, o. D.).

Schließlich bedeutet ein hoher positiver Z-Score ($> 2,58 / > 1,96$), dass die Ereignisse in Zone i und den benachbarten Zonen j deutlich dichter beieinander liegen als im globalen Durchschnitt, was einen Hot Spot darstellt. Ein hoher negativer Z-Score ($< -2,58 / < -1,96$) deutet auf das Gegenteil hin, also auf einen Cold Spot (How Hot Spot Analysis (Getis-Ord Gi*) works - ArcGIS Pro, o. D.). Für den Fall einer Nicht-Normalverteilung kann alternativ ebenfalls eine Monte-Carlo Simulation vom Typ Permutation angewendet werden. Die Vorgehensweise ist hierfür die gleiche wie für den Local Moran's Ii (Levine, 2004). Schließlich wird auch hier für jeden Z-Score ein p-Wert berechnet, um die statistische Signifikanz zu bewerten. Die Z-Score-Werte der einzelnen Zonen können abschließend als Hot Spot oder Cold Spots auf der Karte dargestellt werden (Wang et al., 2013).

Abbildung 23 gibt ein Beispiel für eine solche Ergebniskarte. Die Karte basiert auf einem Datensatz zu Einbrüchen in Houston, USA im Jahr 2006, wobei die Ereignisse nach Stadtvierteln aggregiert wurden. Dargestellt sind Cluster mit einem Signifikanzniveau von 95 %, wobei Hot Spots durch Z-Werte $> 1,96$ und Cold Spots durch Z-Werte $< -1,96$ gekennzeichnet sind. Im Zentrum der Karte sind zwei große Cold-Spot-Cluster (rot) zu erkennen. In den Randbereichen sind dagegen eine Reihe von Hot-Spot-Clustern (blau) zu erkennen (Levine, 2004).

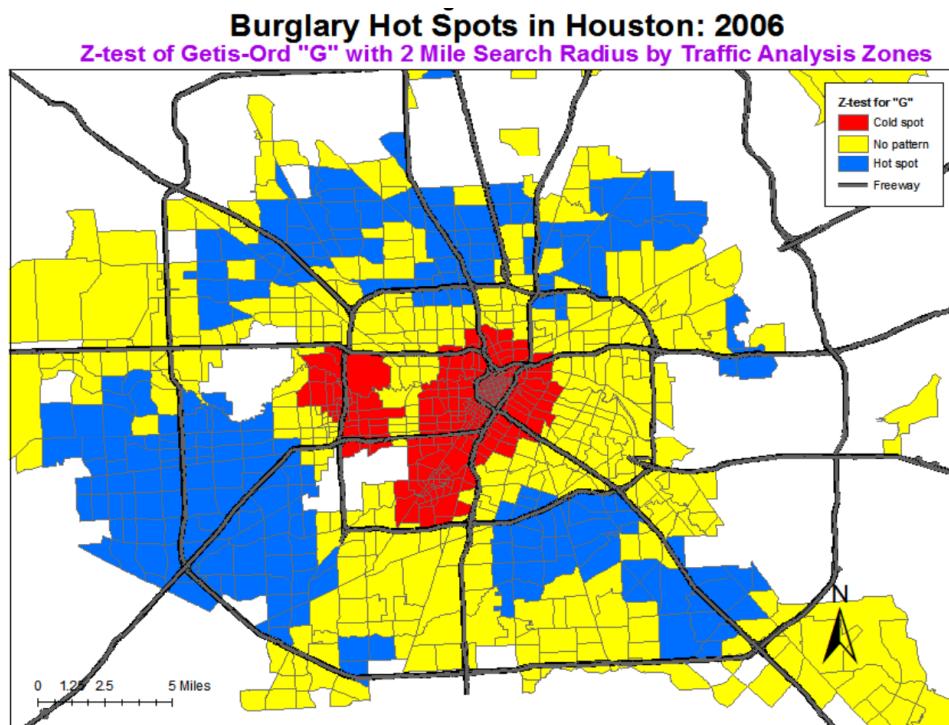


Abb. 23: Local Gi: Beispielkarte (Levine, 2004, S. 621)

6. Prediction Accuracy Index (PAI)

Die verschiedenen Methoden zur Ermittlung von Hot Spots unterscheiden sich sowohl in der Art der Vorhersage als auch in der Darstellung auf der Karte. Um feststellen zu können, welche dieser Methoden Hot Spots für bestimmte Straftaten am genauesten identifiziert, haben Chainey et al. (2008) den *Prediction Accuracy Index* (PAI) entwickelt (Chainey et al., 2008; Kundakci, 2014).

Der PAI ist eine weit verbreitete und häufig angewendete Technik, um die Genauigkeit verschiedener Hot-Spot-Mapping-Methoden für verschiedene Arten von Verbrechen zu bewerten. Die Methodik basiert auf dem Verhältnis des Prozentsatzes der Ereignisse, die in den Hotspots gefunden werden, zu allen Ereignissen im gesamten Untersuchungsgebiet (HitRate), im Verhältnis zum Flächenprozentsatz der identifizierten Hotspots über das gesamte Untersuchungsgebiet (AreaPercentage). Vereinfacht ausgedrückt beschreibt der PAI das Verhältnis des prozentualen Anteils der Trefferquote zum prozentualen Flächenanteil der identifizierten Hot Spots (Chainey et al., 2008; Kundakci, 2014). Die konkrete Grundformel lautet wie folgt:

$$\frac{\left(\frac{n}{N}\right)*100}{\left(\frac{a}{A}\right)*100} = \frac{\text{HitRate}}{\text{AreaPercentage}} = \text{Prediction Accuracy Index}$$

Formel 10: Berechnung des Prediction Accuracy Index (PAI) (Chainey et al., 2008, S. 14)

n stellt hierbei die Anzahl der Verbrechen innerhalb der ermittelten Hot Spots dar, *N* die Anzahl an Verbrechen im gesamten Untersuchungsgebiet, *a* die Größe der Fläche der Hot-Spot-Gebiete und *A* die Größe der Fläche des gesamten Untersuchungsgebiets (Chainey et al., 2008).

Dabei gilt: Je höher der PAI-Wert, desto genauer hat die angewandte Methode bestimmte Hot Spots identifiziert. Wenn zum Beispiel 100 % der Straftaten in 100 % der Flächen gefunden werden, ergibt sich ein PAI-Wert von 1. Je mehr Straftaten also in einem Hot-Spot-Gebiet

vorkommen, das kleiner ist als das gesamte Untersuchungsgebiet, desto höher ist der PAI-Wert (Shariff et al., 2018).

Damit ist der PAI einfach zu berechnen und kann nach Chainey et al. (2008) auf jede Art von Verbrechen, jedes Untersuchungsgebiet und jedes Hot-Spot-Mapping-Verfahren angewendet werden. Chainey et al. (2008) weisen in diesem Zusammenhang außerdem darauf hin, dass die Berechnung der Trefferquote (HitRate) auch als eigenständige Formel für Polizeibehörden von großem Nutzen sein kann, um zu ermitteln, wie viele Straftaten durch gezielte Maßnahmen in Hot-Spot-Gebieten potenziell verhindert werden könnten.

7. Praktischer Versuch in ArcGIS Pro

Um praktische Erfahrungen mit der Erstellung und Interpretation von Hot-Spot-Karten zu sammeln und um die Stärken und Schwächen der einzelnen Methoden besser aufzeigen zu können, folgt im Anschluss an den theoretischen Teil dieser Bachelorarbeit ein praktischer Versuch in ArcGIS Pro. ArcGIS Pro wurde als Programm gewählt, da bereits während des Studiums intensiv damit gearbeitet wurde und somit ein gewisses Fachwissen über verschiedene Funktionen dieses Programms vorhanden war.

Für den Praxistest wurden drei Methoden ausgewählt, die in ArcGIS Pro gut umsetzbar sind und sich in ihrer Komplexität bei der Ermittlung von Hot Spots unterscheiden: die thematische Kartierung im Raster, die Kernel Density Estimation (KDE) und die Getis-Ord Local Gi Statistik. Als Datensatz dienten Schusswaffenereignisse in New York City für das Jahr 2023, die in einem ersten Schritt für die spätere Anwendung aufbereitet und in einer Referenzkarte dargestellt wurden. Als Ergebnis wurden vier Hot Spot Karten erstellt, wovon zwei Karten mit der KDE-Methode erstellt wurden, um den Mehrwert dieser Methode bestmöglich zu demonstrieren. Abschließend konnten die erforderlichen Parameter bestimmt und der Prediction Accuracy Index (PAI) für jede Hot-Spot-Karte berechnet werden.

7.1 Wahl des Untersuchungsgebiets

New York City (NYC) liegt an der Ostküste der USA und ist mit mehr als 8,7 Millionen Einwohnern die bevölkerungsreichste Stadt des Landes. Die Stadt teilt sich in die fünf Bezirke Bronx, Brooklyn, Manhattan, Queens und Staten Island auf und umfasst eine Fläche von knapp 783 km² (New York, NY - Data USA, o. D.). NYC ist bekannt für seine beeindruckende Skyline und zählt zu den wichtigsten wirtschaftlichen und kulturellen Zentren der Welt. Daneben zeichnet sich die Stadt jedoch auch durch eine extreme Spaltung zwischen wohlhabenden Vierteln und ärmeren Stadtgebieten aus. Statistiken aus dem Jahr 2022 zeigen beispielsweise, dass knapp 2 Millionen Menschen, also ungefähr 22 % der Einwohner der Stadt unterhalb der Armutsgrenze leben (Sarnoff, 2024). Die teilweise hohe Armut sowie hohe Bevölkerungsdichte und -diversität bringen Herausforderungen mit sich, insbesondere in Bezug auf die öffentliche Sicherheit und Kriminalität. NYC eignet sich daher gut als Untersuchungsgebiet, um die Verteilung von Kriminalitätsereignissen grafisch

darzustellen und verschiedene HotSpot-Mapping-Methoden in einem praktischen Selbstversuch zu vergleichen.

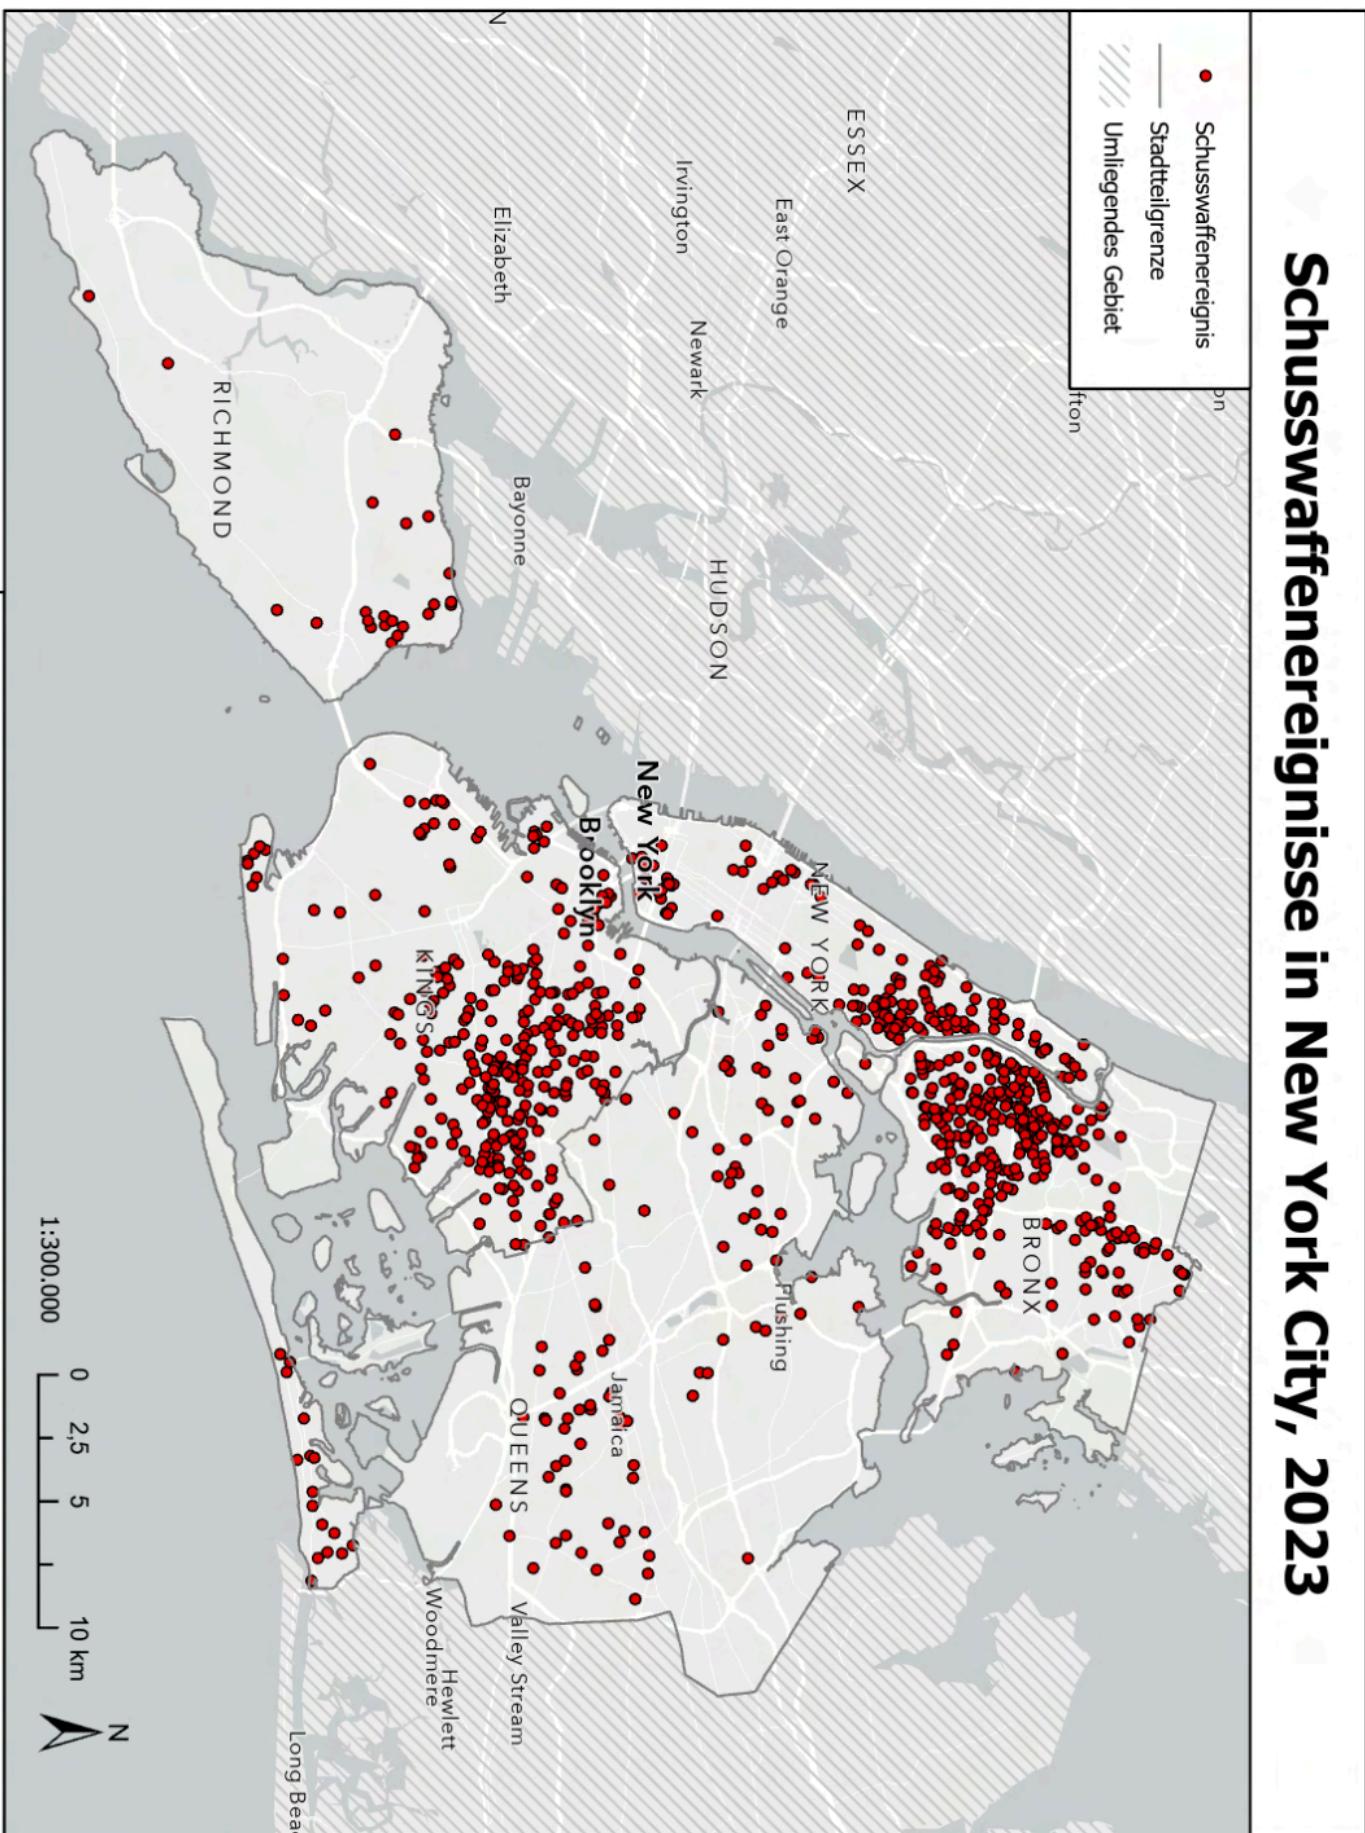
7.2 Datenerhebung und Datenaufbereitung

Für den praktischen Versuch wurden 1250 Schusswaffeneignisse für New York City für den Zeitraum vom 01.02.2023 bis 29.12.2023 untersucht. Die Ereignisdaten stammen von DATA.GOV und wurden als .csv-Datei heruntergeladen (City of New York - NYPD Shooting Incident Data (2023), 2024). Zusätzlich wurden verschiedene Kartendaten als .shp-Dateien heruntergeladen, um die Ergebniskarte anschaulicher zu gestalten. Zum einen eine Basiskarte in einem hellgrauen Farbschema und weißen Straßenverläufen, um die identifizierten Hot Spots mit auffälligen, kontrastreichen Farben stärker hervorzuheben (OpenStreetMap (Light Gray Canvas), o. D.). Zum anderen zwei Shapefiles, die die Gebiete in der Karte grafisch abgrenzen: Ein Shapefile mit Polygonen zu allen Bundesstaaten in den USA (US Census Bureau, 2021) sowie ein Shapefile zu den Stadtteilgrenzen der fünf Bezirke von NYC (Borough Boundaries - NYC Open Data, o. D.), um die ermittelten Hot Spots räumlich besser zuordnen zu können.

Die gesammelten Ereignis- und Kartendaten wurden anschließend in ArcGIS Pro importiert, in die Grundkarte geladen und auf das Koordinatensystem WGS 1984 projiziert. Anschließend wurde die Grundkarte angepasst, indem die Fläche von NYC mit dem *Erase-Tool* und dem Shapefile der Stadtteilgrenzen von NYC als Erase-Input aus dem Polygon der Staaten ausgeschnitten wurde (Erase (Analysis) - ArcGIS Pro, o. D.). Der ausgeschnittene Bereich wurde anschließend entfernt und das restliche Polygon schraffiert dargestellt, um dem Betrachter zu signalisieren, dass diese umliegenden Bereiche nur der Orientierung dienen, jedoch für den eigentlichen Inhalt der Karte keine Bedeutung haben. Weiter wurden die Ereignisdaten in der Attributabelle auf Fehler und Unvollständigkeiten überprüft. Hierbei konnten 49 Schusswaffeneignisse mit unvollständigen Koordinatendaten identifiziert werden, die nicht in der Karte dargestellt wurden. Nach dem Entfernen dieser fehlerhaften Ereignisse blieben 1201 Ereignisse übrig, die anschließend als rote Punkte in der Karte dargestellt wurden und mit denen nun im weiteren Verlauf gearbeitet werden konnte (siehe Abbildung 24).

Abb. 24: Punktkarte: Darstellung der Schusswaffeneignisse (ArcGIS Pro)

Schusswaffeneignisse in New York City, 2023



7.3 Erstellung der Hot-Spot-Karten

In diesem Kapitel werden die einzelnen Schritte zur Erstellung der Hot-Spot-Karten detailliert beschrieben, beginnend mit der thematischen Kartierung im Raster über die Erstellung von zwei Dichtekarten mit KDE und der Erstellung einer statistisch signifikanten Hot-Spot-Karte mit der Getis-Ord Local Gi Statistik.

7.3.1 Thematische Kartierung im Raster

Da die thematische Kartierung von Grenzgebieten am Beispiel von NYC aufgrund der Größe der fünf Stadtbezirke zu keinen gezielten polizeilichen Maßnahmen führen würde, wurde sich für eine thematische Kartierung im Raster entschieden.

Zunächst wurde mit dem Tool *Create Fishnet* (siehe Abbildung 25) ein Raster (Fishnet_Grid1) über das Untersuchungsgebiet gelegt (Netz erstellen (Data Management) - ArcGIS Pro, o. D.). Die Größe des Gitters wurde hierbei durch das Shapefile der Stadtteilgrenzen festgelegt und der Geometriertyp auf *Polygon* gesetzt, um jeder Gitterzelle eine Fläche zuzuweisen. Um die Ergebniskarte möglichst ansprechend zu gestalten und gleichzeitig gezielte polizeiliche Maßnahmen auf Basis des Rasters zu ermöglichen, ist die anschließende Evaluierung einer geeigneten Rasterzellengröße von großer Bedeutung. Nach mehreren Anpassungen wurde schließlich eine Zellengröße von $0,01^{\circ}$ ($\approx 1 \text{ km}^2$) festgelegt.

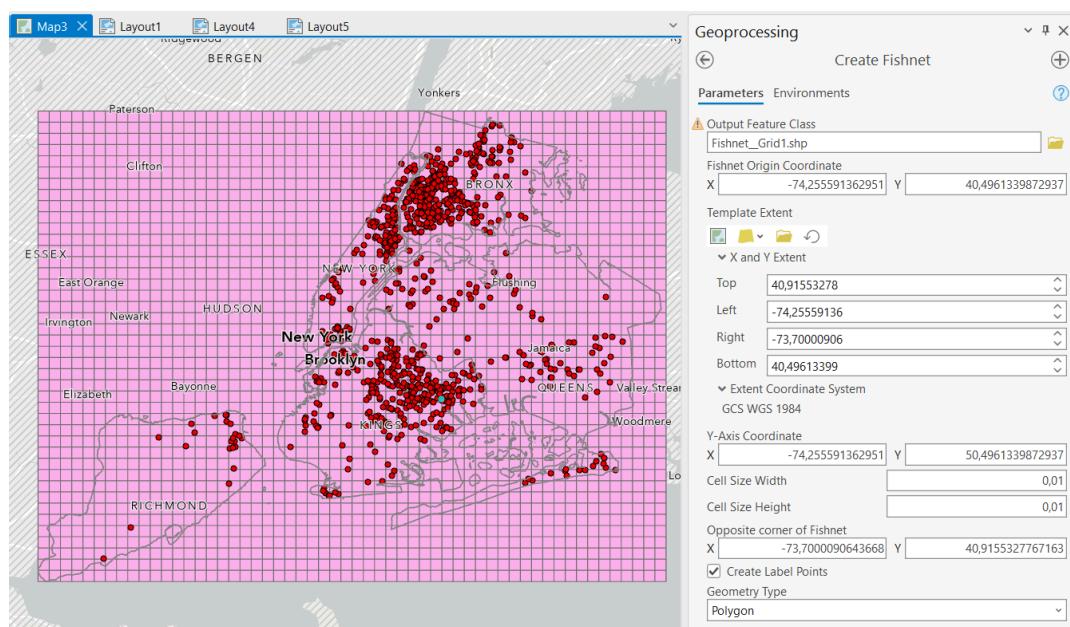


Abb. 25: Rasterkarte: Create Fishnet Tool (ArcGIS Pro)

Um später die einzelnen Rasterzellen entsprechend der Anzahl an Schusswaffeneignissen farblich darstellen zu können, musste jeder Zelle zunächst ein eigener Wert als eindeutiges Identifikationsmerkmal (Fishnet_ID) zugewiesen werden. Zwar wies das vordefinierte FID-Feld bereits jeder Zelle einen alleinigen Wert zu, jedoch kann dieses Feld in den ArcGIS-Tools nicht als Input-Feld ausgewählt werden. Daher musste in der Attributabelle zunächst ein neues Feld hinzugefügt werden, dem über die Funktion *Calculate Field* die Werte des FID-Feldes zugeordnet wurden (Feld Berechnen: Python-Beispiele - ArcGIS Pro, o. D.). Damit war es nun möglich, die einzelnen Rasterzellen als eigenständige Zonen zu betrachten (siehe Abbildung 26).

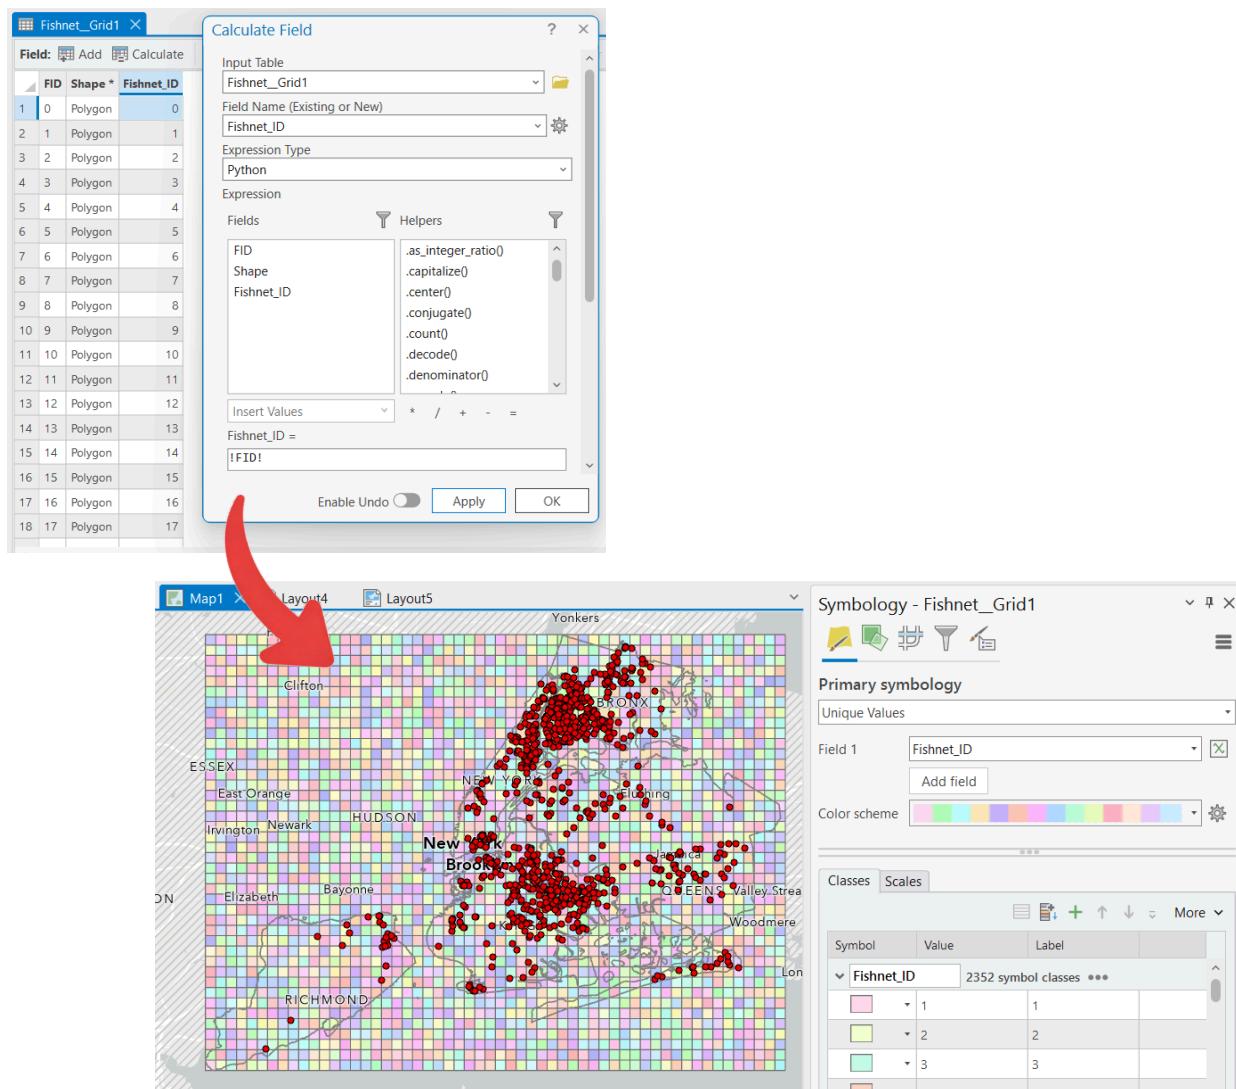


Abb. 26: Rasterkarte: Calculate Field Funktion (ArcGIS Pro)

Im Anschluss konnten die Schusswaffenereignisse und die Rasterzellen über das Tool *Spatial Join* (siehe Abbildung 27) in einem neuen Shapefile zusammengefügt werden, wobei nur die Zellen mit aufgenommen wurden, in denen auch Ereignisse stattfanden. Mit der Join-Operation *Join One to One* wurde hierbei festgelegt, dass jedes Schusswaffenereignis im Ergebnis-Shapefile in einer eigenen Zeile, zusammen mit der zugehörigen Rasterzelle, aufgeführt wird (Räumliche Verbindung (Analysis) - ArcGIS Pro, o. D.). Mit der Match-Option *Intersect* wurde sichergestellt, dass nur diejenigen Ereignisse den Rasterzellen zugeordnet werden, die auch innerhalb der jeweiligen Zellengrenzen liegen (Überschneiden (Intersect) - ArcGIS Pro, o. D.).

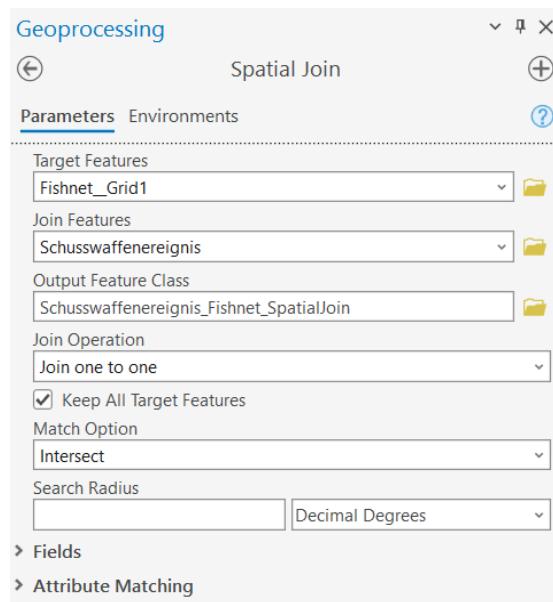


Abb. 27: Rasterkarte: Spatial Join Tool (ArcGIS Pro)

In einem nächsten Schritt wurden die Schusswaffenereignisse für jede Zelle gezählt und in einer neuen Tabelle (Schusswaffenereignis_Count) aufgelistet. Dafür wurde die Anzahl der jeweiligen Identifikationsnummern der Zellen (Fishnet_ID) mithilfe der *Summary Statistics* Funktion und dem Statistiktyp *Count* aufsummiert (Summenstatistik (Analysis) - ArcGIS Pro, o. D.). In der resultierenden Tabelle konnten nun für jede Zelle im Feld “COUNT_Fishnet_ID” die Anzahl der Schusswaffenereignisse abgelesen werden (siehe Abbildung 28).

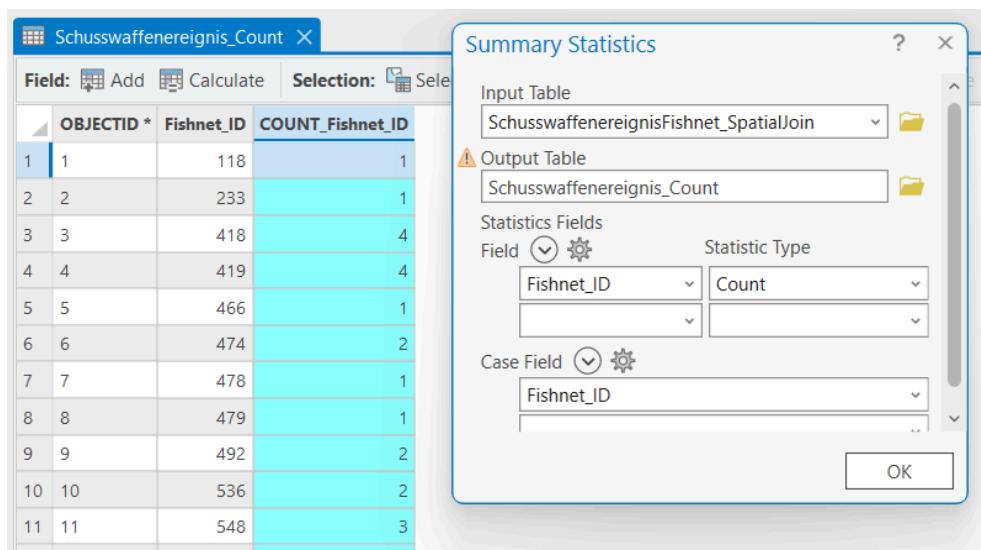
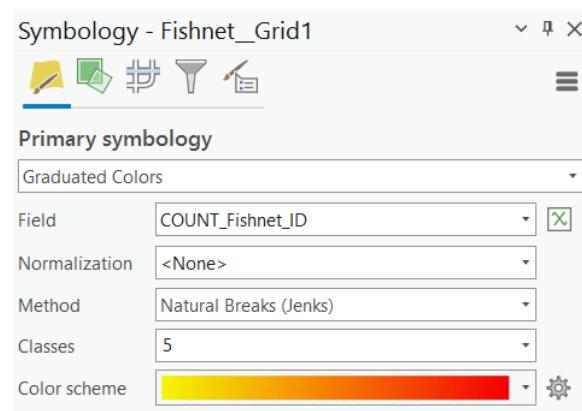


Abb. 28: Rasterkarte: Summary Statistics Funktion (ArcGIS Pro)

Diese Tabelle wurde schließlich dem ursprünglichen Fishnet_Grid1-Shapefile mit der Funktion *Add Join* hinzugefügt, wodurch das Feld mit der Anzahl der Ereignisse pro Rasterzelle (COUNT_Fishnet_ID) nun in der Symbology als Input-Feld für die Darstellung ausgewählt werden konnte (Verbindung hinzufügen (Data Management) - ArcGIS Pro, o. D.).



Für die Visualisierung wurde schließlich ein für Hot-Spot-Karten üblicher Farbverlauf von Gelb zu Rot gewählt, der in fünf Klassen abgestuft dargestellt wurde. Als Klassifizierungsmethode wurde *Natural Breaks (Jenks)* gewählt, wobei die Unterschiede innerhalb einer Klasse minimiert und zwischen den Klassen maximiert werden.

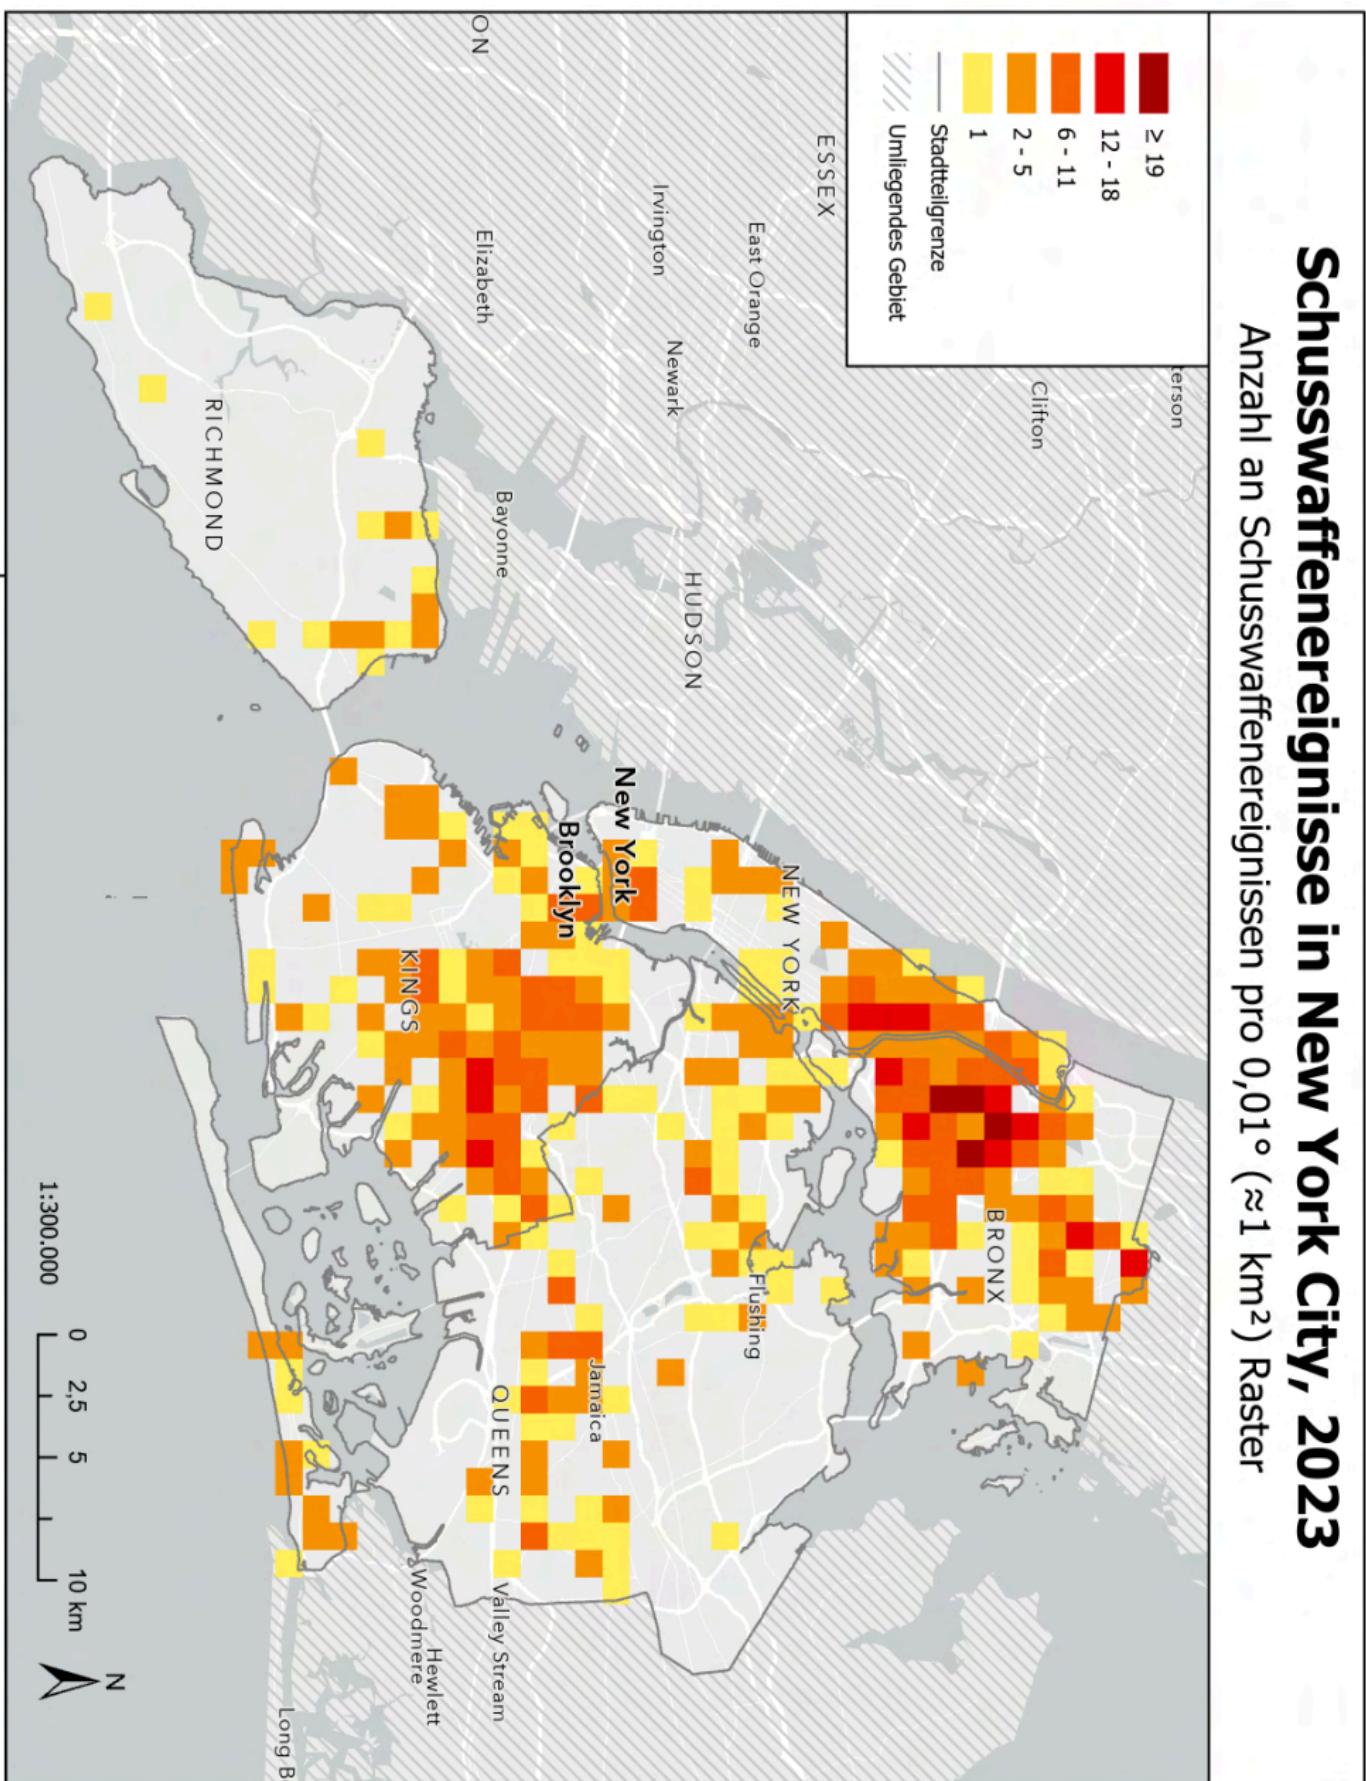
Abb. 29: Rasterkarte: Symbology (ArcGIS Pro)

Dadurch wird das tatsächliche Verteilungsmuster der Ereignisse bestmöglich abgebildet und signifikant unterschiedliche Werte werden in eigenen Kategorien dargestellt (Datenklassifizierungsmethoden - ArcGIS Pro, o. D.). Somit ist diese Klassifizierungsmethode am besten geeignet, um Hot Spots übersichtlich und aussagekräftig darzustellen. Abbildung 30 zeigt schließlich die fertige Hot-Spot-Karte.

Abb. 30: Rasterkarte: Hot-Spot-Karte (ArcGIS Pro)

Schusswaffeneignisse in New York City, 2023

Anzahl an Schusswaffeneignissen pro $0,01^\circ$ ($\approx 1 \text{ km}^2$) Raster



Kartendaten:
OpenStreetMap (Light Gray Canvas), 2024;
Borough Boundaries | NYC Open Data, n.d.;
US Census Bureau, 2021

Ereignisdaten:
City of New York - NYPD Shooting Incident Data (2023), 2024

Copyright:
© 2024 Luis Fink, 12018892

Ereignisdaten:
City of New York - NYPD Shooting Incident Data (2023), 2024
Copyright:
© 2024 Luis Fink, 12018892

7.3.2 Kernel Density Estimation (KDE)

Wie bereits im Kapitel zur Funktionsweise von KDE beschrieben, gibt es fünf verschiedene Kernelfunktionen, die zur Ermittlung von Hot Spots genutzt werden können. Diese Funktionen unterscheiden sich in ihrer mathematischen Formel und damit auch in der Art, wie die Dichte um jeden Punkt geschätzt wird, also wie die umliegenden Punkte mit zunehmender Entfernung innerhalb des Suchradius gewichtet werden (Levine, 2004).

ArcGIS Pro stellt ein eigenes Tool für die Kernel Density Estimation zur Verfügung, das auf der quartischen Kernelfunktion basiert, wobei die Gewichtung der umliegenden Punkte mit zunehmender Entfernung quartisch abnimmt (siehe Abbildung 16) und somit eine glatte Dichteschätzung erzeugt wird. Die konkrete Formel sieht wie folgt aus:

$$\text{Density} = \frac{1}{(\text{radius})^2} \sum_{i=1}^n \left[\frac{3}{\pi} \cdot \text{pop}_i \left(1 - \left(\frac{\text{dist}_i}{\text{radius}} \right)^2 \right)^2 \right]$$

For $\text{dist}_i < \text{radius}$

Formel 11: Berechnung der quartischen Funktion in KDE (Funktionsweise von “Kerndichte” - ArcGIS Pro, o. D.)

n stellt hierbei die Gesamtzahl an Ereignispunkten dar, **pop_i** den Wert des Ereignisses i und **dist_i** den Abstand zwischen dem Ereignis i und der Position (XY), für die die Dichte vorhergesagt wird (Funktionsweise von “Kerndichte” - ArcGIS Pro, o. D.). Da die Schusswaffenereignisse in diesem Fall nicht nach einem bestimmten Attribut gewichtet, sondern jeweils als ein Ereignis betrachtet wurden, gilt: pop_i = 1.

Innerhalb des KDE-Tools konnten die Punktdaten der Schusswaffenereignisse direkt als Input genommen werden. Anschließend musste ein geeigneter Suchradius eingestellt werden, der bestimmt, wie weit der Einfluss eines jeden Punktes reicht. Während ein großer Suchradius, glattere und stärker generalisierte Dichte-Raster erzeugt, liefert ein kleinerer Radius detailliertere Informationen (Levine, 2004). Da je nach Analyseziel sowohl große als auch kleine Suchradiuseinstellungen hilfreich sein können und es laut Chainey et al. (2008) für Dichtekarten üblich ist, verschiedene Suchradien zu vergleichen, wurde für einen umfassenden Vergleich entschieden, zwei Karten mit unterschiedlichen Suchradien zu erstellen: eine mit einem Suchradius von 0,01° und eine mit einem Suchradius von 0,03°.

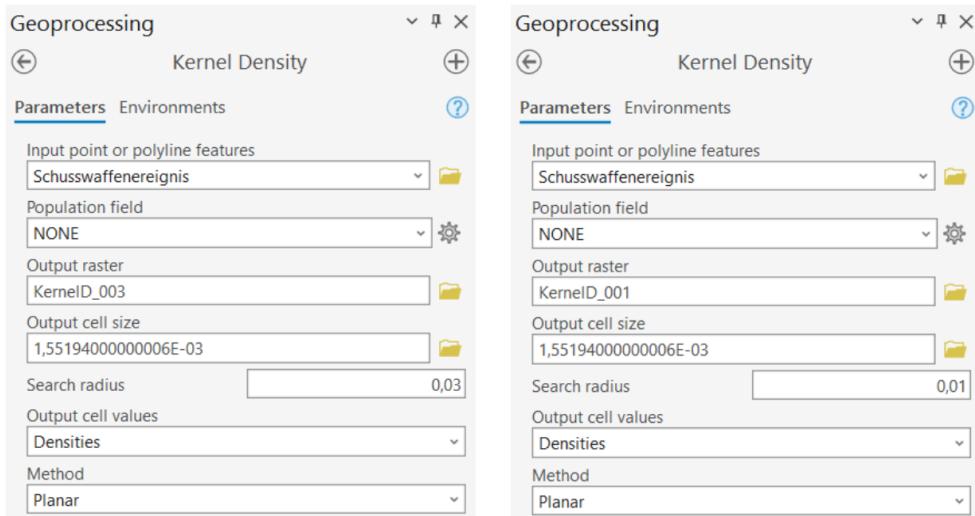


Abb. 31: KDE-Karten: Kernel Density Tool für 0,01° & 0,03° (ArcGIS Pro)

Da es sich bei New York City um ein vergleichsweise kleines Gebiet handelt, bei dem die Erdkrümmung vernachlässigbar ist, wurde als Methode *Planar* ausgewählt. Als Ausgabenzellenwert wurde *Densities* gewählt, wodurch, wie für KDE-Karten typisch, ein Dichtewert pro Rasterzelle berechnet wird. Die ausgegebene Zellengröße wurde automatisch auf Basis des eingegebenen Suchradius berechnet (Kerndichtevehältnis berechnen (Spatial Analyst) - ArcGIS Pro, o. D.).

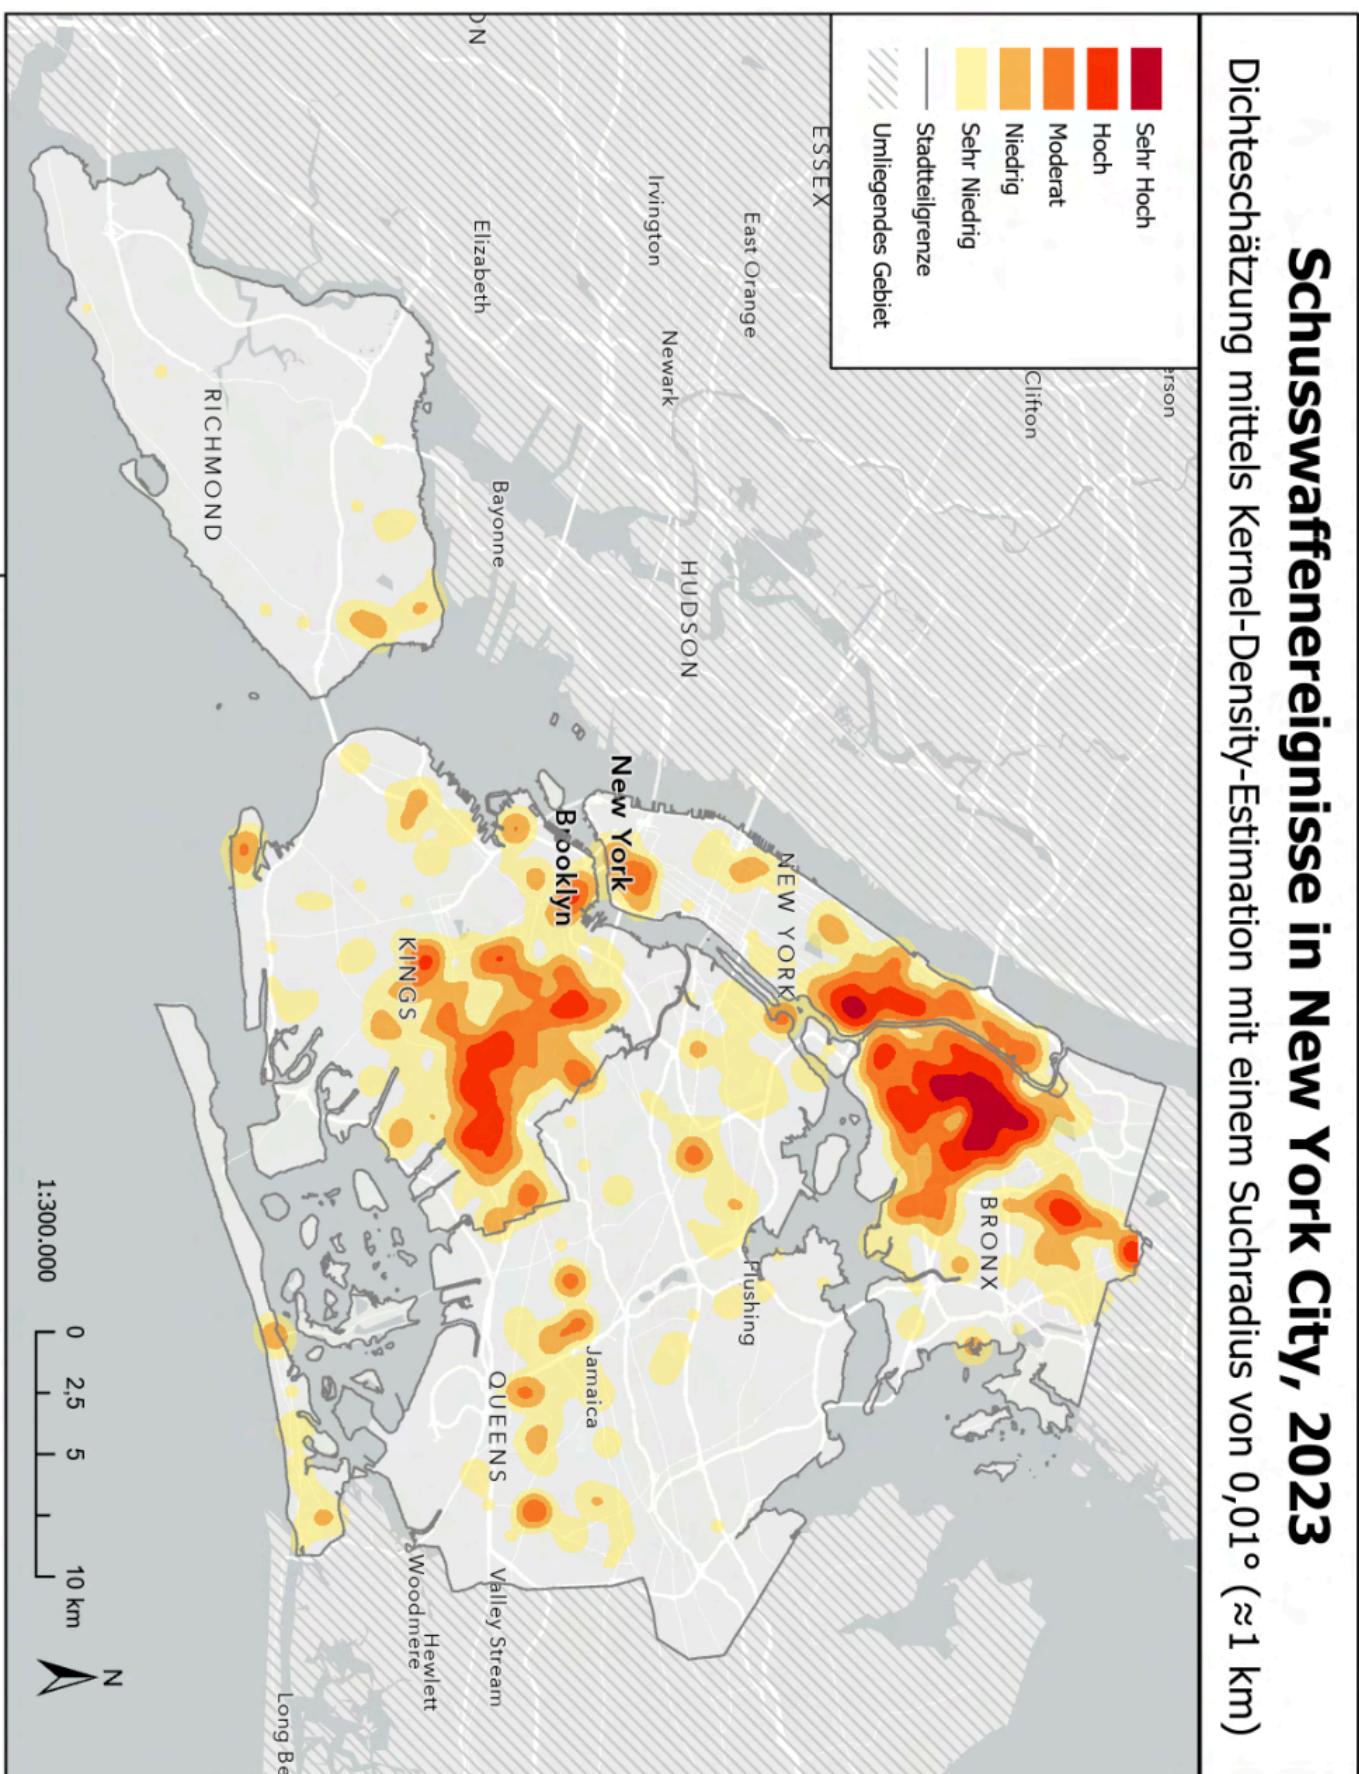
Um die erzeugten Dichtekarten übersichtlicher zu gestalten und für einen späteren Vergleich anzupassen, wurde darauf geachtet, innerhalb der Symbology die gleichen Parameter wie für die Rasterkarte einzustellen. Die Darstellung wurde somit erneut in fünf Klassen unterteilt und im gleichen Farbschema von rot nach gelb abgestuft. Zudem wurde als Klassifizierungsmethode erneut Natural Breaks (Jenks) gewählt. Da die Werte der einzelnen Klassen aufgrund der komplexen Dichteberechnung dieser Methode keinen Mehrwert für den Betrachter bieten, wurden die Klassen anschließend, wie bei Dichtekarten üblich, von sehr hoch bis sehr niedrig abgestuft. Im letzten Schritt erfolgte eine abschließende Glättung beider Karten unter dem Punkt *Resampling Type*, um ein möglichst ansprechendes Endergebnis zu erhalten. Hierbei wurde *Bilinear* als Typ gewählt, wobei der Wert einer Zelle aus dem gewichteten durchschnittlichen Abstand der vier nächstgelegenen Zellen bestimmt wird (Resampling Method Environment Setting - ArcGIS Pro, o. D.). Abbildung 32 & 33 zeigen die fertigen Dichtekarten.

Abb. 32: KDE-Karten: 0,01°-Hot-Spot-Karte (ArcGIS Pro)

Abb. 33: KDE-Karten: 0,03°-Hot-Spot-Karte (ArcGIS Pro)

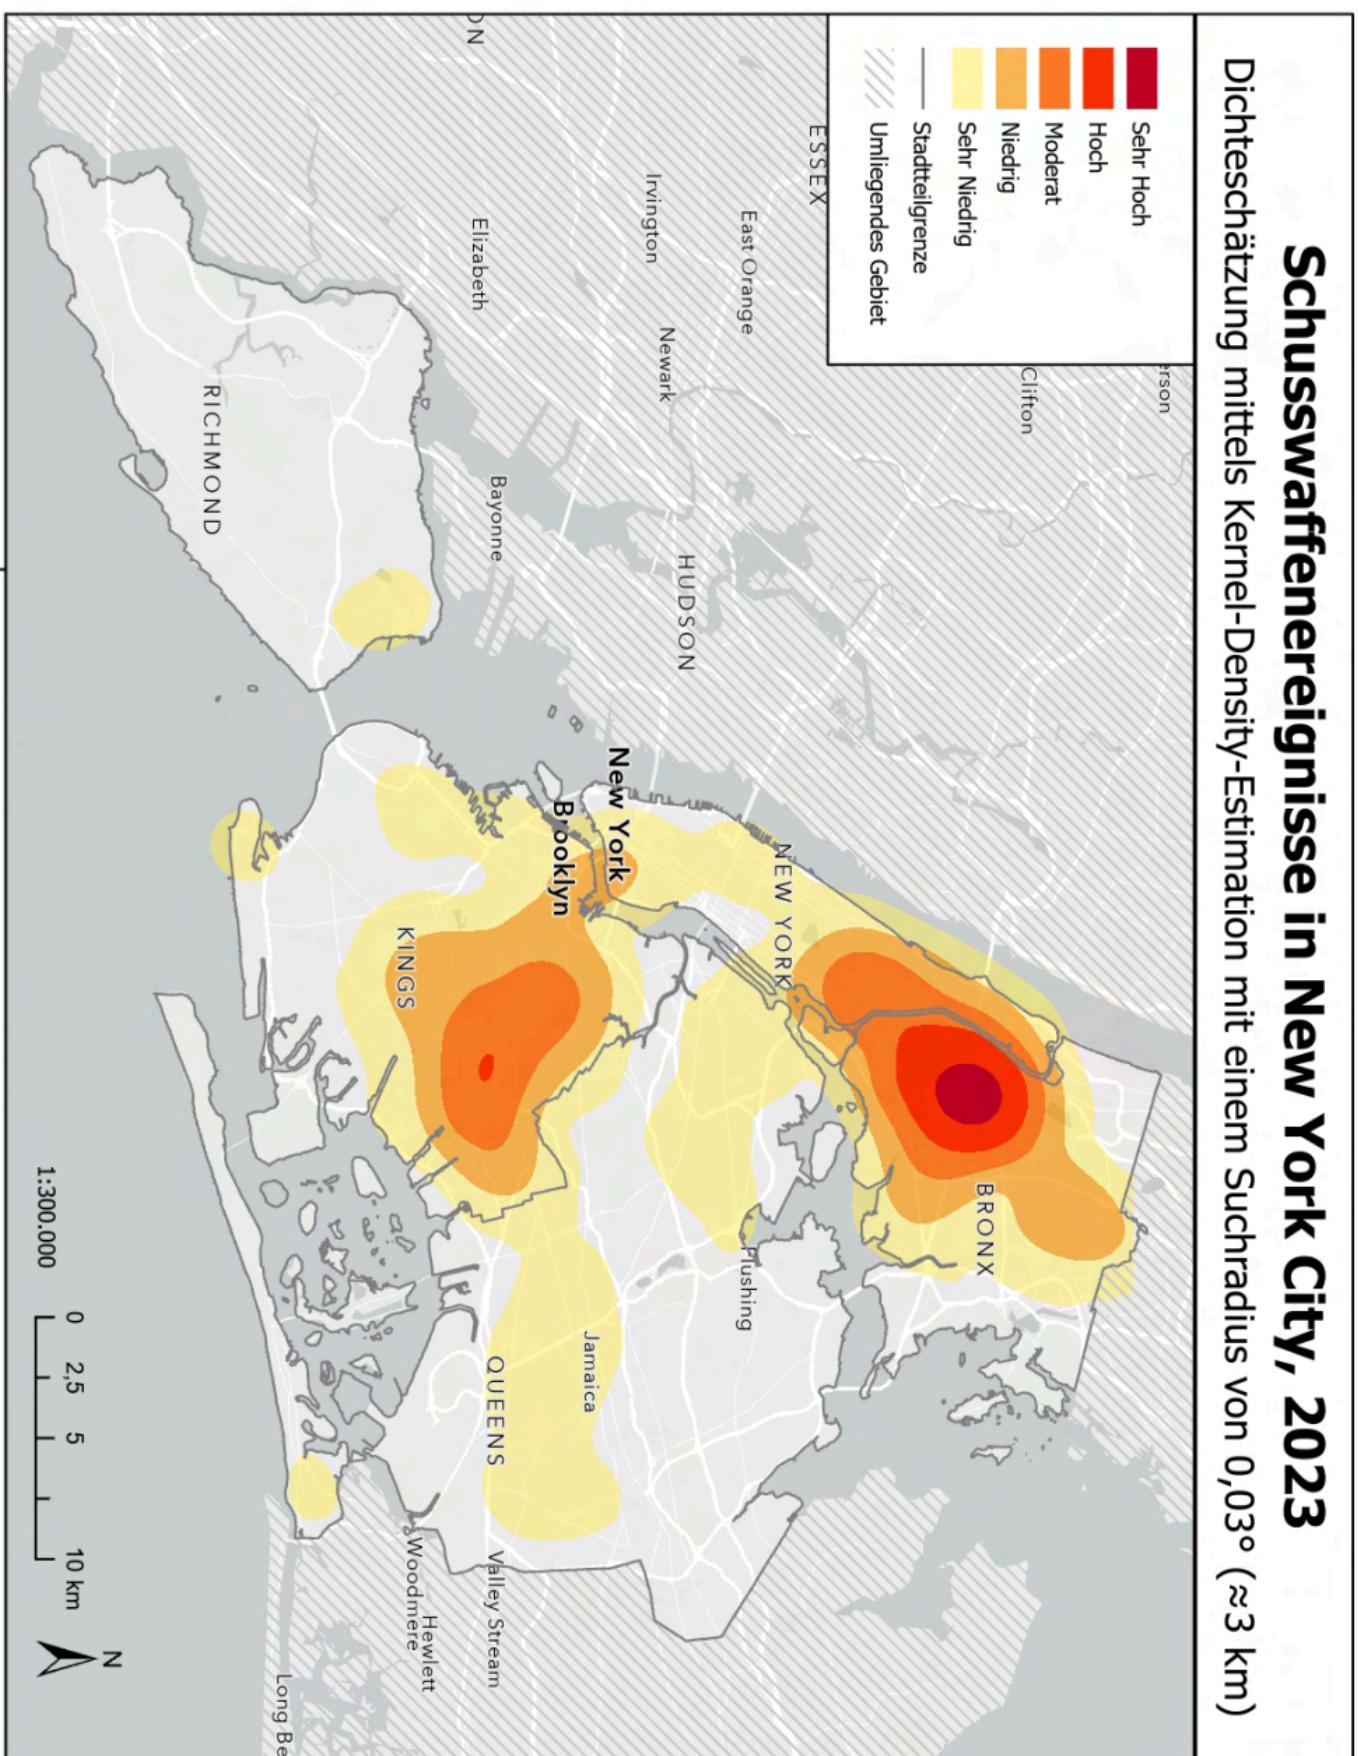
Schusswaffeneignisse in New York City, 2023

Dichteschätzung mittels Kernel-Density-Estimation mit einem Suchradius von 0,01° ($\approx 1 \text{ km}$)



Schusswaffeneignisse in New York City, 2023

Dichteschätzung mittels Kernel-Density-Estimation mit einem Suchradius von 0,03° (≈ 3 km)



7.3.3 Getis-Ord Local Gi-Statistik

Ähnlich wie bei der KDE-Methode bietet ArcGIS Pro auch für die statistisch signifikante Hot-Spot-Ermittlung mithilfe der Getis-Ord Local Gi-Statistik ein eigenes Tool an: *Hot Spot Analysis (Getis-Ord Gi*)* (HSA). Wie im Kapitel zu LISA-Statistiken beschrieben, muss hierfür allerdings die Bedingung erfüllt sein, dass jedes beobachtete Ereignis zusätzlich zu seinem X und Y Koordinatenwert, einen weiteren Identitätswert besitzt (Levine, 2004).

Im Falle der Schusswaffenereignisse mussten dazu die einzelnen Ereignisse zunächst in gewisse Zonen aggregiert werden. Dies erfolgte über das Tool *Aggregate Points* (siehe Abbildung 34), wobei die Ereignisse in sogenannten Bins aggregiert wurden (Punkte Aggregieren (Standard Feature Analysis) - ArcGIS Pro, o. D.). Dabei fiel die Wahl auf hexagonale Bins, die den Vorteil bieten, dass sie von ihrem Mittelpunkt aus gleichmäßige Abstände zu allen Ecken aufweisen und somit eine konsistenter und damit genauere Darstellung räumlicher Beziehungen ermöglichen als beispielsweise quadratische Bins (Warum Hexagone? - ArcGIS Pro, o. D.). Um möglichst präzise Berechnungen zu erhalten und gleichzeitig eine für den Betrachter visuell ansprechende Karte zu erhalten, wurde die Größe der Bins auf 500 Meter festgelegt.

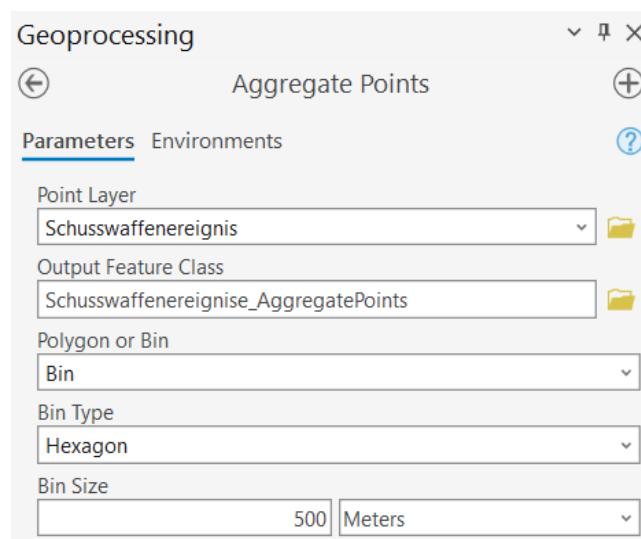


Abb. 34: Local Gi: Aggregate Points Tools (ArcGIS Pro)

Zusätzlich zur ersten Bedingung für LISA-Statistiken muss zusätzlich noch eine zweite Bedingung gegeben sein. Dabei handelt es sich um die genaue Definition der Nachbarschaft, also um die Größe des Distanzbandes (Levine, 2004). Das Distanzband bestimmt hierbei den maximalen Abstand, innerhalb dessen umliegende Bins in die Berechnung des Gi-Wertes für den jeweils beobachteten Bin einbezogen werden (Modellierung von räumlichen Beziehungen - ArcGIS Pro, o. D.). Die Wahl der Größe hat somit einen erheblichen Einfluss auf das Endergebnis und die Aussagekraft der ermittelten Hot Spots und Cold Spots. Für die Bestimmung der optimalen Distanzbandgröße gibt es in ArcGIS Pro das *Incremental Spatial Autocorrelation*-Tool, mit dem die räumliche Autokorrelation von aggregierten Ereignissen über verschiedene Distanzskalen untersucht werden kann (Incremental Spatial Autocorrelation (Spatial Statistics) - ArcGIS Pro, o. D.).

Im Falle der Schusswaffenereignisse wurden die aggregierten Ereignisse als Input gewählt und das Feld mit der Anzahl an Ereignissen pro Bin (COUNT) als Input-Feld festgelegt (siehe Abbildung 35). Zudem wurden folgende Parameter für die Ermittlung festgelegt: 15 Distanzbänder mit einem Anfangsband bei 500 Metern und einer Steigerung von 400 Metern pro Band. Dabei war es wichtig, dass das Anfangsband beim kleinstmöglichen Wert beginnt, für den jeder Bin im Datensatz mindestens einen Nachbarn hat (Incremental Spatial Autocorrelation (Spatial Statistics) - ArcGIS Pro, o. D.). Bei gleich großen Bins im gesamten Untersuchungsgebiet entspricht dieser Wert der Größe der Bins (500 m). Für die beiden weiteren Eingabewerte mussten durch mehrmaliges Ausprobieren geeignete Parameter evaluiert werden. Schließlich wurde als Distanzmethode *Manhattan* gewählt. Dadurch werden die Distanzen entlang der Straßenlinien einer Stadt gemessen, was sich besonders für urbane Gebiete mit rechtwinkligen Straßennetzen wie in NYC eignet, um eine möglichst realistische Berechnung der Distanzen zu erhalten (Modellierung von räumlichen Beziehungen - ArcGIS Pro, o. D.).

Das Ergebnis der Berechnung wurde anschließend sowohl grafisch als auch tabellarisch in einem PDF-File gespeichert. Abbildung 36 zeigt die Ergebnisgrafik, in der die Ergebnisse der Analyse der räumlichen Autokorrelation über 15 Distanzbänder dargestellt sind. Hieraus konnte nun entnommen werden, bei welcher Distanz die stärkste räumliche Autokorrelation (Max Peak) vorliegt: Max Peak bei 4900,00 m mit einem Z-Score von 9,162571.

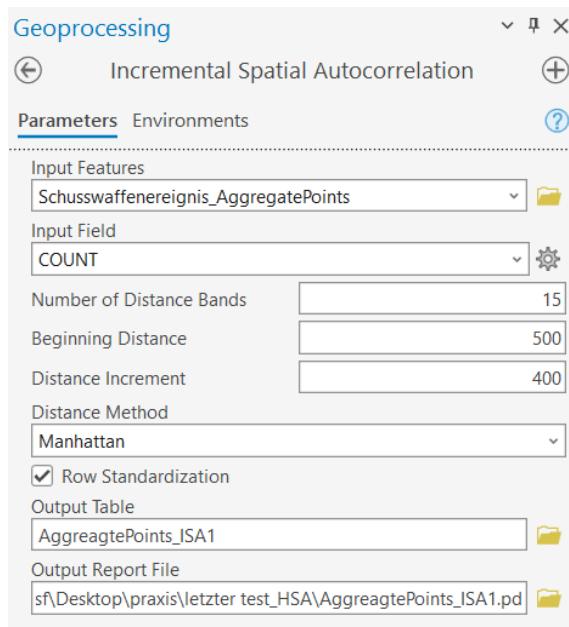


Abb. 35: Local Gi: Incremental Spatial Autocorrelation Tool (ArcGIS Pro)

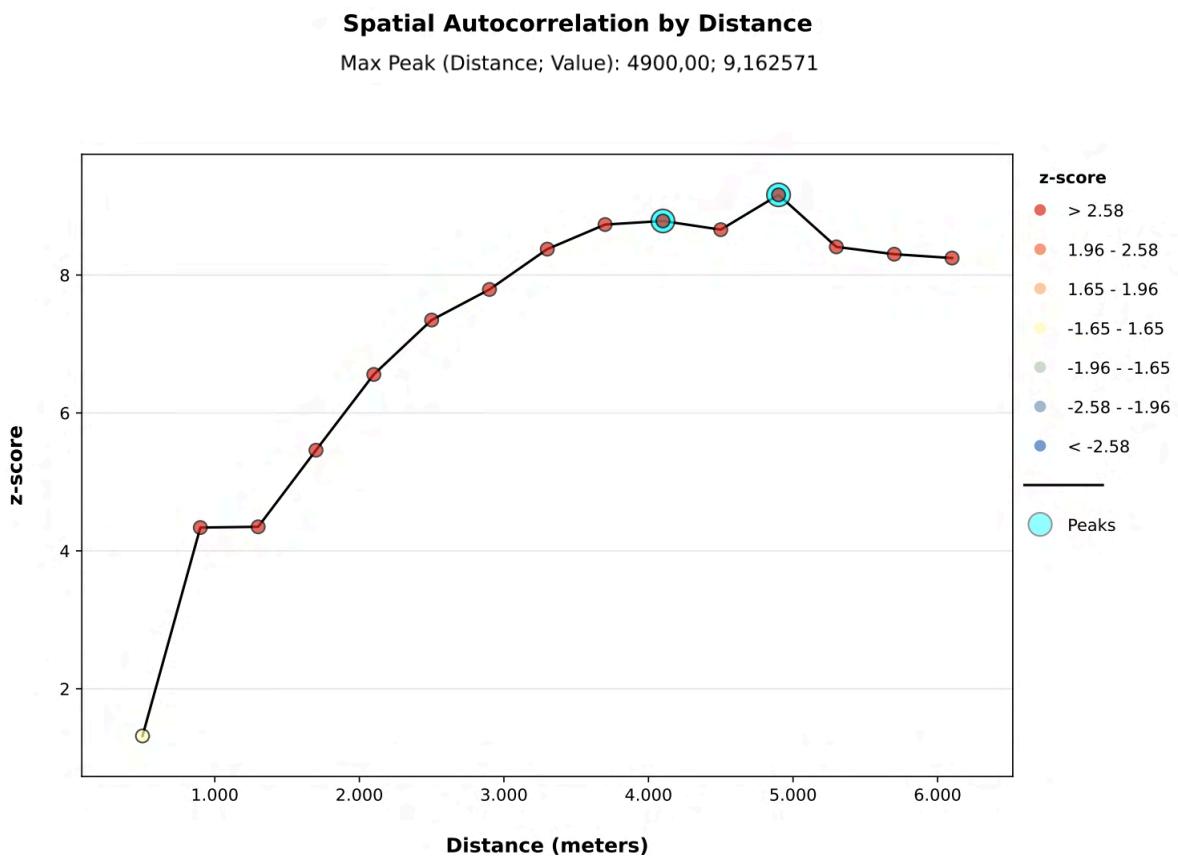


Abb. 36: Local Gi: Ergebnisgrafik des Incremental Spatial Autocorrelation Tool (ArcGIS Pro)

Nachdem nun die allgemeinen Voraussetzungen für LISA-Statistiken erfüllt waren, konnten sowohl das ermittelte Distanzband, als auch die aggregierten Ereignisdaten für die Berechnung innerhalb des *Hot Spot Analysis*-Tools verwendet werden (siehe Abbildung 37). Dabei wurde das Feld mit der Anzahl an Ereignissen pro Bin (COUNT) als Input-Feld und Manhattan als Distanzmessmethode gewählt.

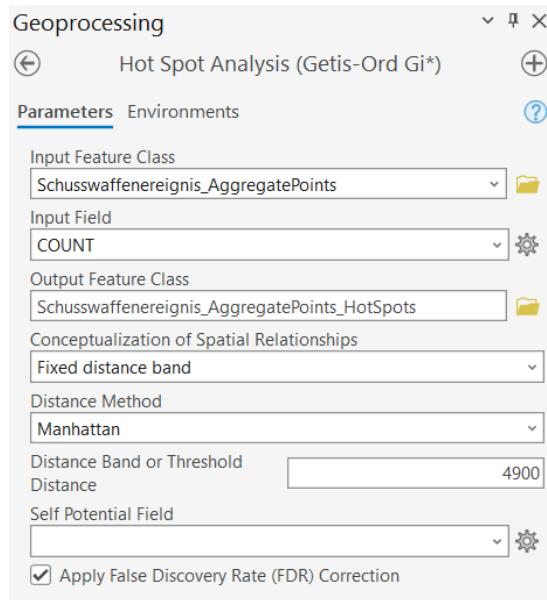


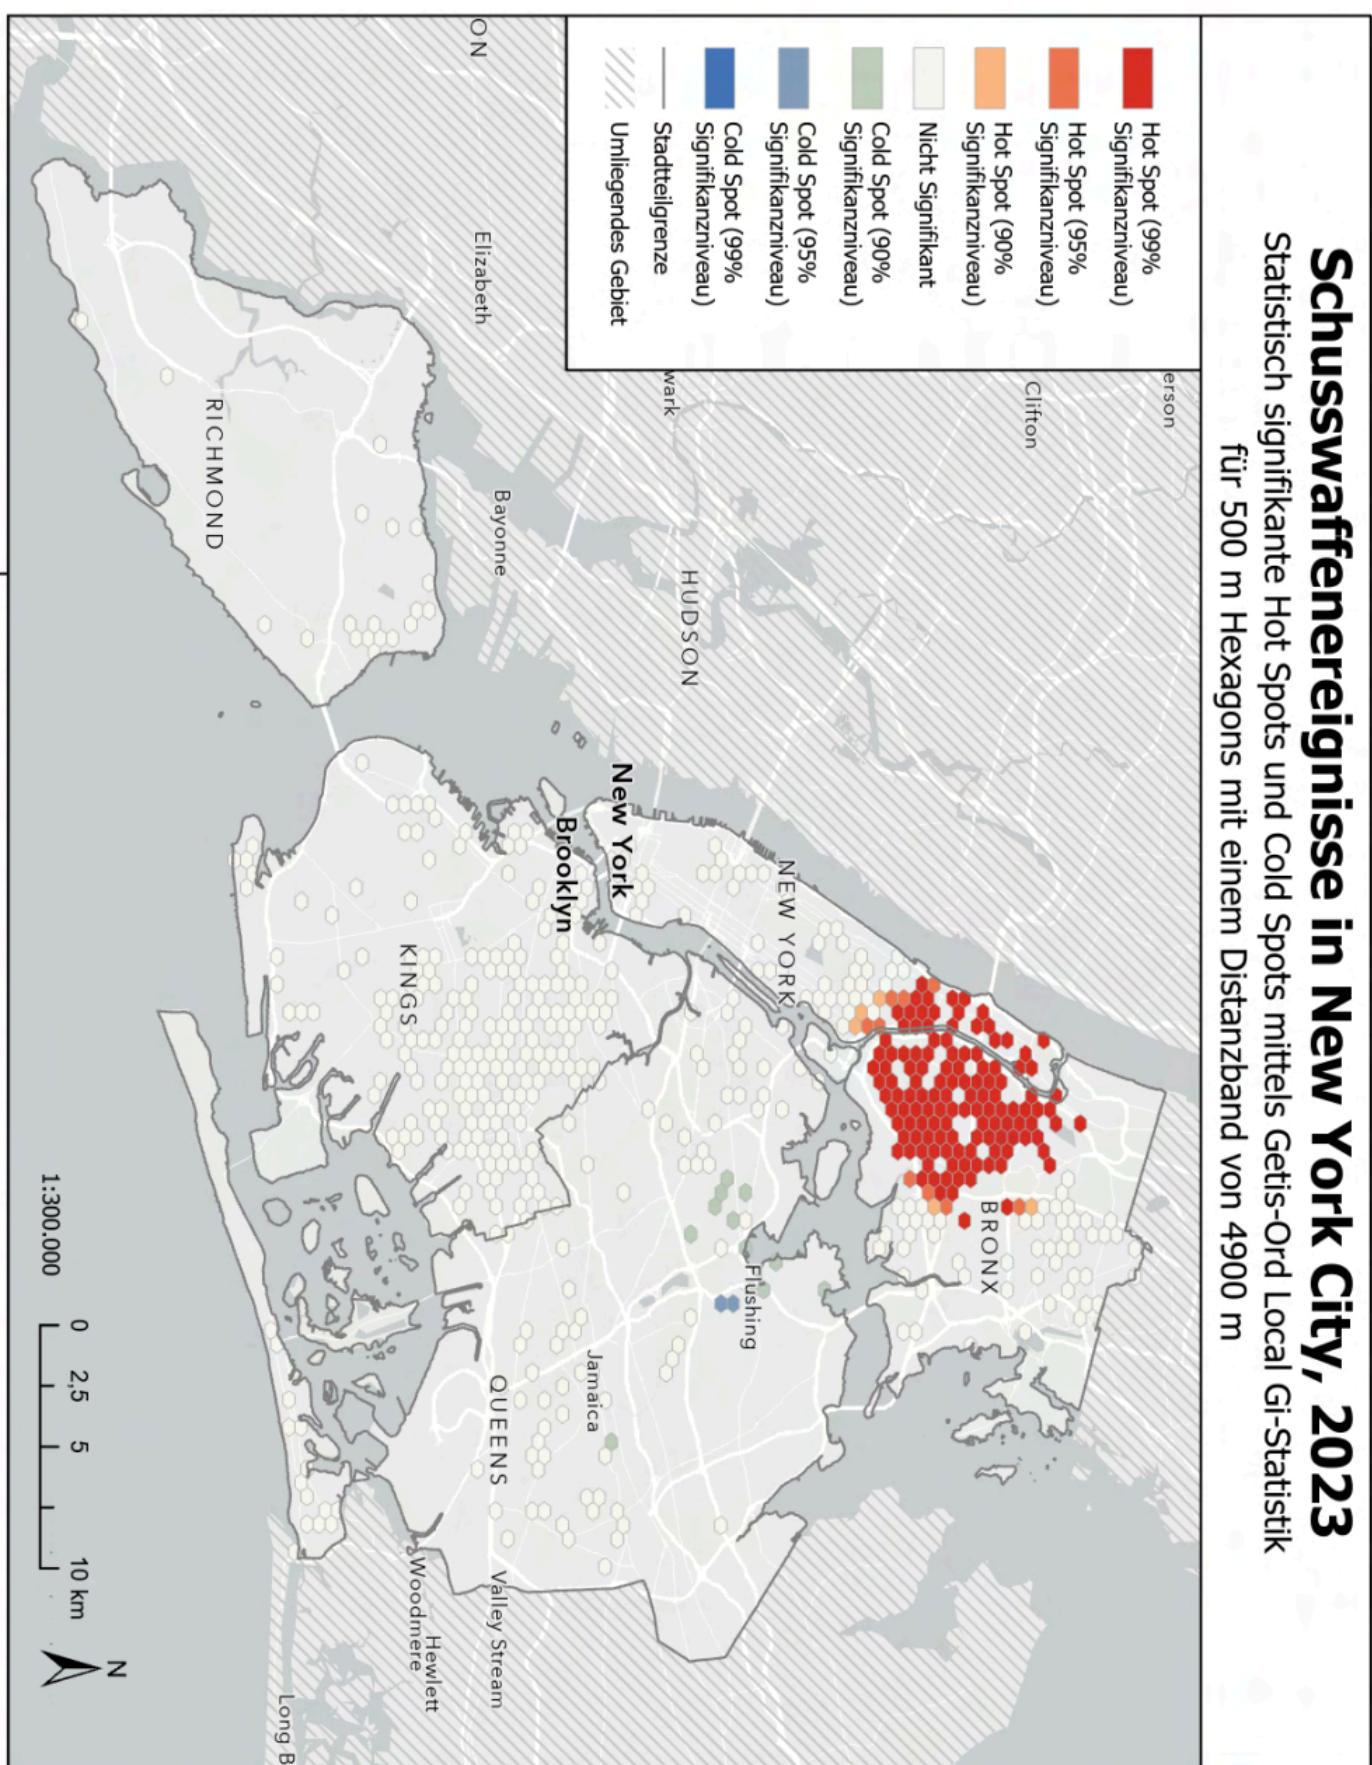
Abb. 37: Local Gi: Hot Spot Analysis (Getis-Ord Gi*) Tool (ArcGIS Pro)

Zusätzlich wurde die False Discovery Rate (FDR) Correction aktiviert, um die Genauigkeit der lokalen räumlichen Autokorrelation zu erhöhen, indem die Anzahl an falsch positiven Ergebnissen für ein bestimmtes Konfidenzniveau geschätzt wird und kritische p-Werte entsprechend angepasst und entfernt werden (Was ist ein Z-Wert? Was ist ein p-Wert? - ArcGIS Pro, o. D.). Abbildung 38 zeigt schließlich die fertige Hot-Spot-Karte mit 90%, 95% und 99% Signifikanzniveaus für Hot Spots und Cold Spots.

Abb. 38: Local Gi: Hot-Spot-Karte (ArcGIS Pro)

Schusswaffeneignisse in New York City, 2023

Statistisch signifikante Hot Spots und Cold Spots mittels Getis-Ord Gi-Statistik für 500 m Hexagons mit einem Distanzband von 4900 m



7.4 Berechnung des Prediction Accuracy Index (PAI)

Um die erstellten Hot-Spot-Karten anschließend hinsichtlich ihrer Genauigkeit und Effizienz zu vergleichen, wurde für jede Karte der von Chainey et al. (2008) ins Leben gerufene Prediction Accuracy Index (PAI) berechnet. Für die Berechnung mussten zuvor allerdings noch einige Parameter ermittelt werden: Die Fläche des gesamten Untersuchungsgebiets, die Flächen der jeweiligen ermittelten Hot Spots sowie die Anzahl an Ereignissen für jeden ermittelten Hot Spot.

Die Fläche des Untersuchungsgebiets konnte schnell und einfach mithilfe des Shapefiles der Stadtteilgrenzen ermittelt werden, indem die Summe aller Bezirksflächen in km² unter dem Punkt *Explore Statistics* in der Attributabelle eingesehen werden konnte (Summenstatistik (Analysis) - ArcGIS Pro, o. D.).

The screenshot shows a table of New York City borough areas and their respective areas, followed by a summary statistics window with a red arrow pointing to the total area.

boro_name	Fläche
Staten Island	150,838253
Manhattan	59,135371
Bronx	110,293838
Brooklyn	179,68748
Queens	282,559097

Sum
782,514039

Abb. 39: PAI: Flächengröße des Untersuchungsgebietes (ArcGIS Pro)

7.4.1 Ermittlung der Hot-Spot-Parameter

Um die Fläche der Hot Spots und die Anzahl der Ereignisse in den Hot Spots zu ermitteln, musste zuvor festgelegt werden, welche konkreten Klassen als Hot Spots definiert werden. Die Wahl fiel auf die jeweils zwei größten Klassen, um sich auf die Gebiete mit einer möglichst hohen Ereignisdichte zu konzentrieren. Dabei wurde sich an Arbeiten wie Levine (2004) orientiert, welcher für seine Vergleiche jeweils Konfidenzintervalle ab 95% als Hot Spots betrachtet.

Im Falle der **Rasterkarte** wurden zunächst alle Raster ab der zweiten Klasse herausgefiltert. Dazu mussten alle Raster mit einer Anzahl von Ereignissen ≥ 12 mit der Funktion *Select by Attributes* markiert werden (siehe Abbildung 40) (Auswählen von Features nach Attributen - ArcGIS Pro, o. D.).

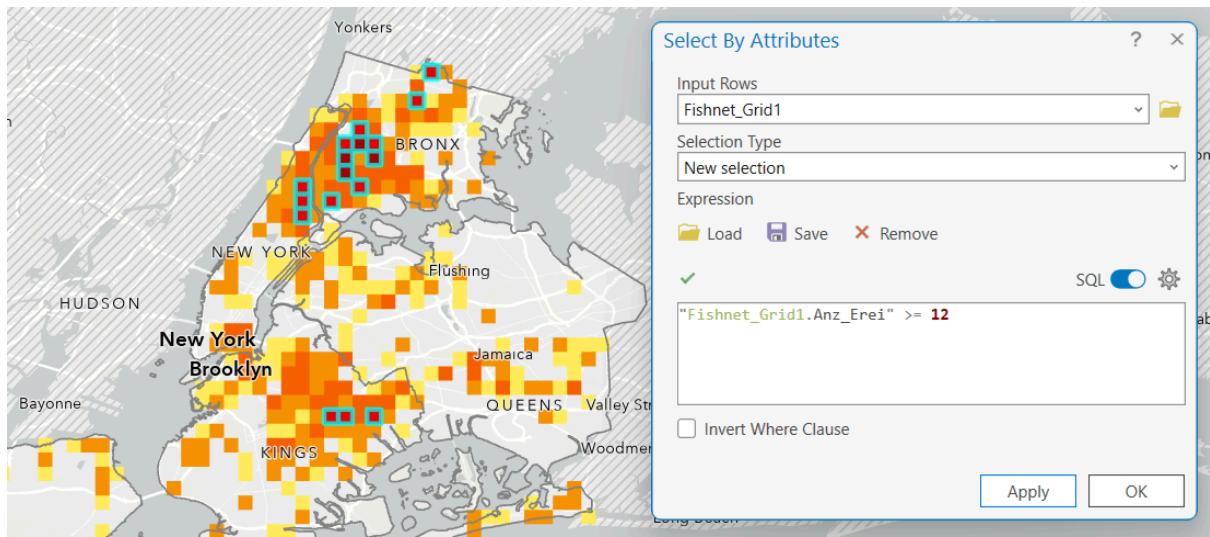


Abb. 40: PAI-Raster: Select By Attributes Funktion (ArcGIS Pro)

Anschließend konnten die 17 markierten Raster mithilfe des Tools *Spatial Join* zusammen mit den Schusswaffeneignissen in einem neuen Shapefile zusammengefügt werden. Innerhalb der Attributabelle dieses Shapefiles musste nun ein neues Feld (Fläche) hinzugefügt werden, für das mit der Funktion *Calculate Geometry* (siehe Abbildung 41) die Flächengröße der einzelnen Raster in km² berechnet wurde (Geometrieattribute berechnen (Datenmanagement) - ArcGIS Pro, o. D.). Schließlich konnte erneut, über den Punkt Explore Statistics, die Summe der Fläche in km², als auch die Summe aller Ereignisse innerhalb der Flächen (Join_Count) eingesehen werden (siehe Abbildung 42).

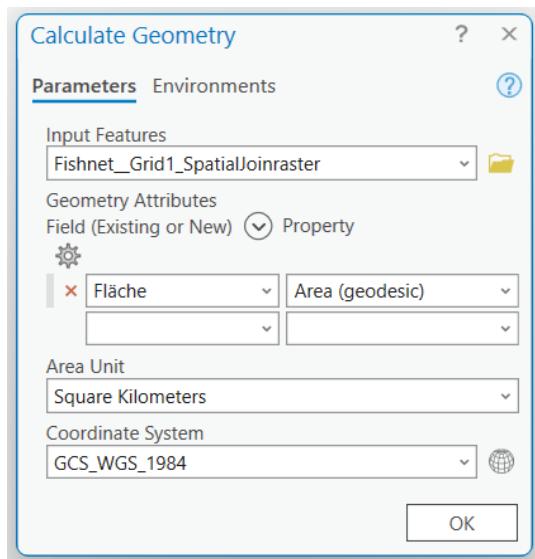


Abb. 41: PAI-Raster: Calculate Geometry Funktion (ArcGIS Pro)

Field Name	Sum
Join_Count	280
Fläche	15,929155

Abb. 42: PAI-Raster: Ereigniszahl & Flächengröße (ArcGIS Pro)

Für die beiden **KDE-Dichtekarten** wurden die Flächengrößen und die Anzahl der Ereignisse in ähnlicher Weise ermittelt. Zunächst musste auch hier die Fläche mit den beiden höchsten Klassen herausgefiltert werden. Da das Ergebnis der Dichteschätzung durch KDE in Rasterzellen ausgegeben wurde, musste hierfür das Tool Raster Calculator (siehe Abbildung 43 & 44) verwendet werden. (Raster berechnen (Spatial Analyst) - ArcGIS Pro, o. D.). Die angegebenen Formeln $\text{Con} ("KernelID_001" > 92072.473162, 1, 0)$ bzw. $\text{Con} ("KernelID_003" > 76463.817402, 1, 0)$ sagen hierbei folgendes aus: Wenn der Wert einer Rasterzelle, aus dem Shapefile KernelID_001 (bzw. KernelID_003), > 92072.473162 (bzw. > 76463.817402) ist, bekommt diese Zelle den Wert 1. Für den Fall, dass der Wert dieser Zelle ≤ 9072.473162 (bzw. ≤ 76463.817402) ist, bekommt diese den Wert 0.

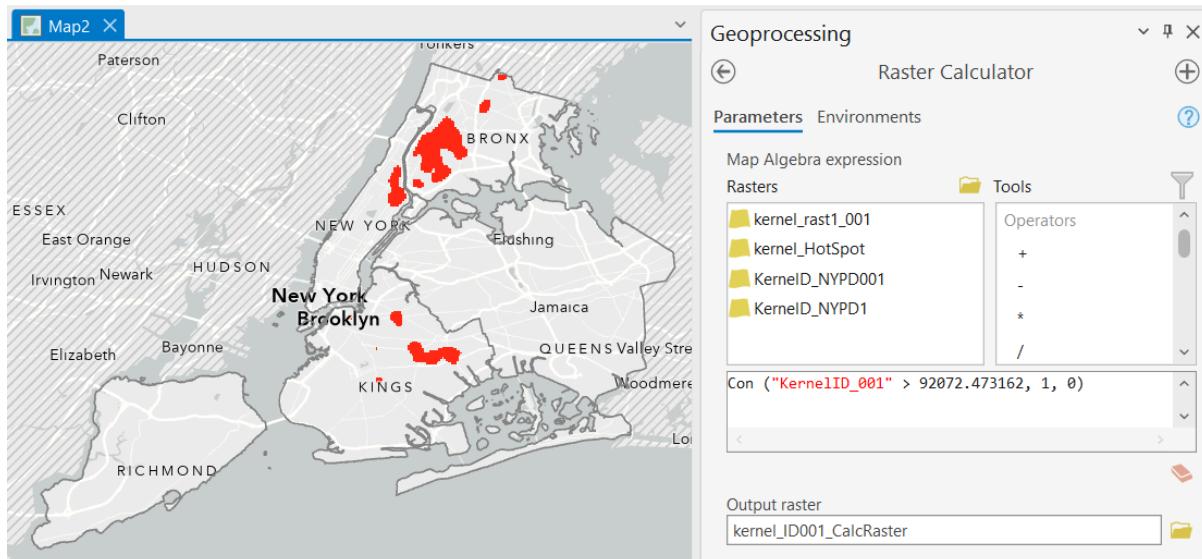


Abb. 43: PAI-KDE: $0,01^\circ$ Raster Calculator Tool (ArcGIS Pro)

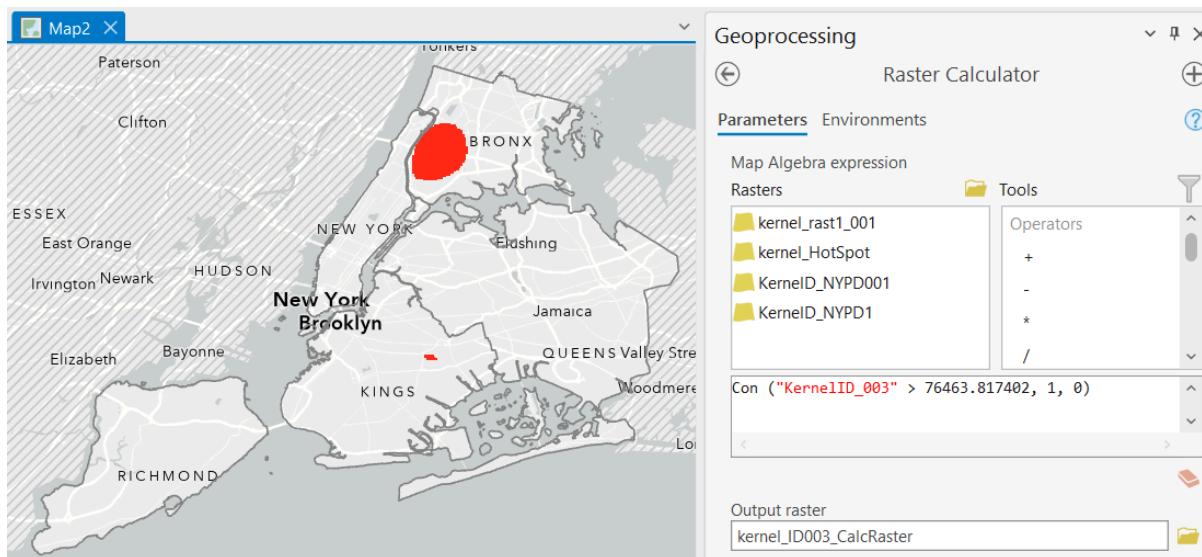


Abb. 44: PAI-KDE: $0,03^\circ$ Raster Calculator Tool (ArcGIS Pro)

Anschließend wurden die ausgeschnittenen Raster mit dem Tool *Raster to Polygon* jeweils in Polygone umgewandelt (Raster in Polygon (Conversion) - ArcGIS Pro, o. D.). Dadurch konnte, wie bei der Rasterkarte, die Flächengröße mit der Funktion *Calculate Geometry* ermittelt werden und die Ereignisanzahl innerhalb der Hot Spots mithilfe des *Spatial Join*-Tools herausgelesen werden, wobei für jedes Ereignis innerhalb der ausgeschnittenen Polygone eine eigene Zeile in der Join-Attributabelle aufgeführt wurde. Somit galt: Anzahl an Zeilen = Anzahl an Ereignissen.



Abb. 45: PAI-KDE: Ereignisanzahl & Flächengröße für $0,01^{\circ}$ & $0,03^{\circ}$ (ArcGIS Pro)

Um die Flächengröße und die Anzahl der Ereignisse für die statistisch signifikanten Hot Spots zu bestimmen, die mit der **Getis-Ord Local Gi-Statistik** berechnet wurden, konnte vom ersten Schritt an genauso vorgegangen werden wie bei der Rasterkarte. Abbildung 46 zeigt die mithilfe der *Select by Attributes*-Funktion ausgewählten Hot Spots, wobei Z-Score Werte ≥ 1.96 ausgewählt wurden, also statistisch signifikante Hot Spots mit einem Konfidenzniveau ab 95%.

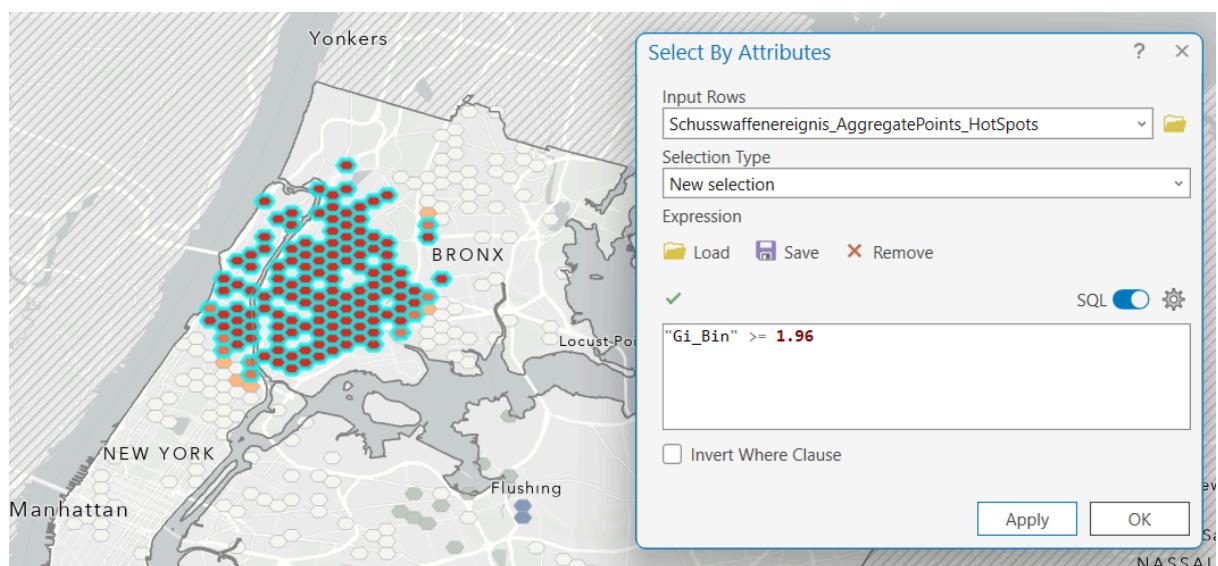


Abb. 46: PAI-Gi: Select By Attributes Funktion (ArcGIS Pro)

In Abbildung 47 kann die schlussendlich ermittelte Ereignisanzahl (Gi_Bin) sowie die Hot Spots Fläche (Fläche) in km² eingesehen werden.

Field Name	Sum
Gi_Bin	434
Fläche	23,403581

Abb. 47: PAI-Gi: Ereignisanzahl & Flächengröße (ArcGIS Pro)

7.4.2 Berechnung des PAI mithilfe der ermittelten Parameterwerte

Für die abschließende Berechnung des Prediction Accuracy Index (PAI) wurden die ermittelten Parameterwerte zusammen mit der Gesamtzahl an Ereignissen (1201) jeweils in die Grundformel (siehe Formel 10) eingesetzt:

$$PAI_{(Raster)} = \frac{\left(\frac{280}{1201} \right) * 100}{\left(\frac{15,93}{782,51} \right) * 100} = 11,45$$

Formel 12: Raster: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008)

$$PAI_{(KDE_{0,01})} = \frac{\left(\frac{401}{1201} \right) * 100}{\left(\frac{23,88}{782,51} \right) * 100} = 10,94$$

Formel 13: KDE-0,01°: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008)

$$PAI_{(KDE_{0,03})} = \frac{\left(\frac{229}{1201}\right) * 100}{\left(\frac{17,38}{782,51}\right) * 100} = 8,58$$

Formel 14: KDE-0,03°: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008)

$$PAI_{(Gi)} = \frac{\left(\frac{434}{1201}\right) * 100}{\left(\frac{23,40}{782,51}\right) * 100} = 12,08$$

Formel 15: Local Gi: Berechneter PAI-Wert (In Anlehnung an Chainey et al., 2008)

8. Diskussion

Nach Abschluss des praktischen Teils dieser Arbeit folgt eine detaillierte Diskussion der Ergebnisse der Literaturrecherche und des Praxistests. Dazu werden zunächst alle in der Arbeit vorgestellten Methoden bewertet und miteinander verglichen. Anschließend werden die Ergebnisse des Praxistests ausgewertet und analysiert. Zum Schluss erfolgt eine allgemeine Bewertung der Konzepte Hot-Spot-Mapping und -Policing.

8.1 Bewertung der untersuchten Methoden

Die thematische Kartierung von Grenzgebieten und im Raster bietet den Vorteil, dass für die Erstellung und Interpretation nur geringe Fachkenntnisse erforderlich sind und keine speziellen Formeln zur Berechnung benötigt werden. In der Karte werden lediglich die absoluten Werte der Ereignisse angezeigt, die in bestimmten Zonen oder im Raster aggregiert sind. Der spezielle Vorteil der Kartierung in Grenzgebieten ist, dass diese leicht mit weiteren Datenquellen, die ebenfalls für diese Gebiete existieren, wie beispielsweise demografische Informationen, verknüpft werden können (Chainey, 2005), was die Vielseitigkeit für mögliche Analysen erhöhen könnte. Ein Problem könnten jedoch die unterschiedlichen Formen und Größen der Gebiete darstellen, die keine einheitliche Karte ergeben. Außerdem kann durch einen Blick auf die Karte nicht festgestellt werden, wo sich die Kriminalität innerhalb eines Gebietes konzentriert. So könnte sich die Kriminalität gleichmäßig innerhalb des Gebietes verteilen, oder auch an bestimmten Stellen konzentriert sein. Generell betont Chainey (2005), dass diese Art der Kartierung in erster Linie bei größeren betrachteten Gebieten nützlich ist und häufig für politische und administrative Zwecke verwendet wird. Gezielte polizeiliche Maßnahmen sind in solchen größeren Gebieten nur schwer möglich. Daher könnten diese Karten gut als ein erster Schritt dienen, um einen Überblick über das gesamte Gebiet zu bekommen, bevor im Anschluss kleinere Bereiche betrachtet werden.

Die thematisch Kartierung im Raster löst das Problem der verschiedenen Formen und Größen von Grenzgebieten und ermöglicht durch die Kartierung in kleineren Rastern feinere und detailliertere Untersuchungen (Chainey, 2005). Diese Art der Kartierung könnte sich gut als nächster Schritt anbieten, nachdem ein gewisses Grenzgebiet mit einer hohen Kriminalitätsdichte ermittelt wurde, um zu untersuchen, wie sich die Kriminalität innerhalb dieses administrativen oder politischen definierten Gebietes verteilt. Beide Kartierungsarten können jedoch auch irreführend sein, da sie die Grenzen von Kriminalität in vordefinierten

Zonen darstellen, wodurch räumliche Details verloren gehen und der natürliche Verlauf der Kriminalität nicht widergespiegelt wird. Außerdem kritisieren Forscher wie Chainey (2005) das blockige Erscheinungsbild einer solchen Rasterkarte.

Hot-Spot-Analysen mithilfe von Programmen wie Spatial and Temporal Analysis of Crime (STAC) und Nearest Neighbor Hierarchical Clustering (NNH) ermitteln Hot Spots mithilfe von bestimmten Clusteringroutinen und gehen damit über die einfache Aggregierung von Ereignissen hinaus. Stattdessen versuchen sie räumliche Muster anhand von räumlichen Abständen zwischen Kriminalitätsereignissen zu identifizieren (Levine, 2004). Dabei bieten diese Methoden den Vorteil, dass sie Hot Spots als räumliche Ellipsen und konvexe Hüllen darstellen, die keine Rücksicht auf vordefinierte Grenzen oder Raster nehmen. Zudem betont Levine (2004), dass STAC und NNH mit den meisten GIS-Anwendungen kompatibel sind, was ihre Anwendung erleichtert. Dennoch sind auch bestimmte Nachteile hervorzuheben, wie beispielsweise eine gewisse Einarbeitungszeit, da Benutzer*innen hierbei eine ganze Reihe an Parametern angeben müssen (Levine, 2004). Diese müssen sorgfältig gewählt sein, da sie die schlussendlich ermittelten Hot Spots in der Karte maßgeblich beeinflussen. Laut Levine (2004) wird neuen Nutzer*innen zudem kaum Hilfestellung innerhalb der Anwendungen geboten. Dies könnte schnell zu Mehrdeutigkeiten und Unklarheiten führen, indem verschiedene Analysten, obwohl sie mit denselben Daten arbeiten, aufgrund unterschiedlich gewählter Parameter zu unterschiedlichen Ergebnissen kommen könnten. Schließlich ist die Darstellung mithilfe von Ellipsen und konvexen Hüllen zwar realitätsnäher als die thematische Kartierung, dennoch zeigen diese Darstellungsmethoden keine Abstufungen innerhalb der Hot Spots. Dadurch könnten sie in vielen Fällen irreführend sein und Betrachter*innen fälschlicherweise suggerieren, dass eine gleichmäßige Kriminalität innerhalb und keine Kriminalität außerhalb der Hot Spots vorherrscht. Chainey et al. (2008) nennt hierbei das Beispiel, dass Analysten dazu verleitet werden könnten, sich auf kleinere Gebiete mit geringer Kriminalität innerhalb eines größeren Ellipsen-Hot-Spots zu fokussieren.

Die Darstellung kontinuierlicher Isolinien in Form von Dichtekarten mittels Kernel Density Estimation (KDE) wirkt dieser gleichförmigen Darstellung von Hot Spots entgegen. Dies hat den großen Vorteil, dass innerhalb der Hot Spots gewisse Abstufungen in der Kriminalitätsdichte erkennbar sind und somit die Lage und räumliche Verteilung der Kriminalitätsschwerpunkte genauer wiedergegeben wird. Zudem können Nutzer*innen

hierbei selbst entscheiden, welche Dichtwerte sie als konkrete Hot Spots betrachtet, wodurch bestimmte Analyseziele spezifischer angegangen werden können. Die Anwendungen ArcGIS Pro und CrimeStat bieten für die KDE-Methode eigenständige Tools (Levine (2004)). Nutzer*innen müssen hierbei lediglich den Suchradius als Parameter einzugeben, wodurch die Methode trotz der komplexen Berechnungen auch für neue Anwender*innen relativ einfach zu handhaben ist. Die Einstellung eines für den jeweiligen Analysezweck geeigneten Suchradius muss jedoch sorgfältig durch Ausprobieren evaluiert werden und schafft eine gewisse Subjektivität. Ein weiterer Nachteil dieser Methode ist, dass die ausgegebenen Werte nicht interpretierbar sind, weshalb Abstufungen in der Karte lediglich von hoch zu niedrig erfolgen. Dadurch sind sie für Analysten womöglich weniger greifbar als beispielsweise thematische Karten.

Durch die Darstellung einer fließenden DichteVerteilung überwindet die KDE-Methode also die Beschränkung auf Hot Spots in Form von vordefinierten geometrischen Formen. Allerdings fehlt es dieser Methode noch an einer Möglichkeit, um Hot Spots statistisch zu bewerten. Hier setzen statistische Analysen räumlicher Beziehungen an, die die statistische Signifikanz der Hot Spots testen.

Die räumliche Maßzahl des NNI bewertet die Verteilung der Ereignisse im gesamten Untersuchungsgebiet und gibt einen globalen Wert zurück, der bestimmt, ob eine statistisch signifikante Clusterbildung in Form von Hot Spots vorliegt (Levine, 2004). Die Berechnung des NNI kann somit ein schneller erster Schritt vor der Erstellung einer Hot-Spot-Karte sein. Laut Chainey (2005) ist diese Art von Tests besonders hilfreich, da sie den Analytiker*innen wertvolle Zeit ersparen kann, für den Fall, dass das Testergebnis keine Clusterbildung anzeigt und somit keine Hot Spots existieren. In diesem Fall wäre die Erstellung einer Hot-Spot-Karte überflüssig. Da dieser Wert jedoch keine spezifischen Hot-Spot-Gebiete in der Karte kenntlich macht, wäre es ratsam, ihn anschließend mit LISA-Statistiken zu kombinieren, die die statistische Signifikanz mit einer visuellen Darstellung in der Karte verbinden.

Die Lokal Moran Ii Statistik kann verwendet werden, um zu testen, ob bestimmte Gebiete ähnlich oder unähnlich zu ihren Nachbarn sind. Eine große Schwierigkeit dieser Methode kann jedoch bei der Interpretation der Kartenwerte auftreten. Denn ob es sich bei den ermittelten ähnlichen oder unähnlichen Gebieten um Hot Spots oder Cold Spots handelt, ist nicht ersichtlich. Um dies herauszufinden, muss eine zweite Referenzkarte mit den absoluten

Ereigniswerten der Zonen herangezogen und verglichen werden. Demnach geht die Methode der Ii-Statistik meist mit einer thematischen Kartierung derselben Zonen einher (Levine, 2004). Da es sich hierbei um ein Hot-Spot-Mapping-Verfahren handelt und die Werte ähnlich wie bei anderen Hot-Spot-Karten von blau nach rot dargestellt werden, könnten Außenstehende schnell zu falschen Schlüssen kommen, indem sie annehmen, dass positive Werte in der Karte Hot Spots und negative Werte Cold Spots darstellen. Es wäre daher ratsam, dass die Ersteller solcher Karten mit eindeutigen Kartenüberschriften arbeiten, um solche Fehlinterpretationen zu vermeiden. Der große Vorteil dieser Methode besteht darin, dass hierbei Ausreißer, sogenannte isolierte Hot Spots, identifiziert werden können, die inmitten von Zonen mit negativen Werten liegen (Levine, 2004), was für bestimmte Analysezwecke von großem Nutzen sein könnte.

Während die Local Moran Ii Statistik lediglich eine positive oder negative räumliche Autokorrelation erkennt, also ähnliche und unähnliche benachbarte Zonen, identifiziert die Gi-Statistik konkrete statistisch signifikante Hot Spots und Cold Spots in einer Karte (Levine, 2004). Dadurch ist sie für den Betrachter leicht zu verstehen und räumt mögliche Fehlschlüsse aus dem Weg. Die größte Einschränkung der Gi-Statistik ist, dass sie keine negative räumliche Autokorrelation erkennt und daher auch keine isolierten Hot Spots identifiziert werden können (Levine, 2004). Es wäre daher ratsam, die beiden LISA-Statistiken zu verbinden und beide Methoden als eine gegenseitige Ergänzung zu betrachten.

8.2 Auswertung des praktischen Versuchs

ArcGIS Pro bietet für die Methoden Kernel Density Estimation (KDE) und Getis-Ord General Gi Statistik eigene Tools, bei denen die zugrundeliegenden komplexen Berechnungen zur Hotspot-Ermittlung im Hintergrund durchgeführt werden können. Anwender*innen müssen lediglich die Parameter eingeben, was diese Methoden in der Anwendung besonders praktikabel macht. Bei der KDE-Methode konnten durch mehrmaliges Ausprobieren daher schnell zwei geeignete Suchradien ermittelt werden, wodurch die Fertigstellung dieser Karten am schnellsten erfolgte. Die Ermittlung eines geeigneten Distanzbandes für das Gi-Statistik-Tool erforderte hingegen mehr Zeit und Wissen. Insbesondere die thematische Kartierung im Raster erwies sich als langwieriger als erwartet, da hierfür die meisten Analyseschritte notwendig waren. Obwohl die Rasterkartierung technisch weniger

anspruchsvoll ist, hat sich gezeigt, dass sich der Analyseaufwand aufgrund der zur Verfügung gestellten Tools bei den drei Methoden letztlich nicht so stark unterscheidet wie zuvor angenommen.

Die anschließende Ermittlung der Parameterwerte für die Berechnung des Prediction Accuracy Index (PAI) war für die KDE-Methode am aufwendigsten, da die Daten als Raster vorlagen und sich somit von der Analyse der anderen beiden Methoden, die jeweils als Polygone vorlagen, unterschieden. Die Ergebnisse der PAI-Berechnung sind dabei etwas überraschend. Alle vier Karten ergeben sehr hohe PAI-Werte über 1, was eine sehr gute Vorhersagegenauigkeit aller Methoden bedeutet. Die KDE-Methode mit einem Suchradius von $0,03^\circ$ hat mit 8,58 den vergleichsweise niedrigsten PAI-Wert, was auch zu erwarten war, da sie die am stärksten generalisierten Hot Spots aufzeigt. Ein Vergleich mit der Karte mit einem Suchradius von $0,01^\circ$ zeigt deutlich die Genauigkeitsunterschiede der beiden Suchradiuseinstellungen. Ein gutes Beispiel hierfür ist der Harlem River, der als Fluss die Stadtteile Bronx und Manhattan trennt. Bei einem Suchradius von $0,03^\circ$ wird der Fluss nicht als Grenze berücksichtigt und es entsteht ein großer zusammenhängender Hot Spot über den Fluss hinweg. Beim kleineren Suchradius von $0,01^\circ$ trennen sich die Hot Spots am Fluss, was eine genauere und realistischere Darstellung beweist. Obwohl ein kleiner Suchradius auf den ersten Blick stets vorzuziehen ist, muss dabei immer auch auf die Größe des Untersuchungsgebiets und das Analyseziel geachtet werden, da insbesondere bei größeren Gebieten ein kleiner Suchradius schnell zu einer optisch unansehnlichen Karte führt und viele zusammenhängende Hot-Spot-Gebiete nicht mehr erkannt werden.

Überraschenderweise liegen die berechneten PAI-Werte der Methoden KDE- $0,01^\circ$, Rasterkartierung und Gi-Statistik mit nur 1,04 Wertepunkten Unterschied sehr nah beieinander. Die Tatsache, dass die Gi-Statistik, die mit einer komplexen Berechnung und Mehrfachtests sowie einer FDR-Autokorrektur einhergeht, einen ähnlich hohen Wert ausweist wie die einfache Aggregierung der Ereignisse im Raster, ist bemerkenswert und zeigt, dass effektive Hot-Spot-Karten nicht gezwungenermaßen komplexe Berechnungen benötigen. Dennoch ist die Gi-Statistik ein wichtiger Bestandteil in einer umfassenden Hot-Spot-Analyse, da mit ihrer Hilfe festgestellt werden kann, ob es sich tatsächlich um statistisch signifikante Hot Spots handelt.

Die Hot Spots der höchsten Klasse, sowohl in der KDE- $0,01^\circ$ -Methode als auch in der Rasterkartierung, weisen nicht nur eine sehr ähnliche Platzierung im Gebiet auf, sondern auch

annähernd die gleiche Form, da beide wie ein umgedrehtes U an der gleichen Stelle im Norden des Gebiets platziert sind. Generell erkennen beide Karten die Hot Spots im gesamten Gebiet sehr ähnlich, was sich auch in den PAI-Werten widerspiegelt. Mit einer Differenz von gerade einmal 0,51 Punkten liegen die beiden Methoden in ihrer Vorhersagegenauigkeit am nächsten beieinander.

Die Gi-Statistik erkennt statistisch signifikante Hot Spots nur im nördlichen Teil der Stadt am Übergang von Manhattan zu Bronx, wobei der Großteil im Gebiet Bronx liegt. Dafür liegen dort fast ausschließlich Hot Spots mit einem Signifikanzniveau von 99 % vor, sprich mit Z-Werten $> 2,58$, was auf eine sehr hohe räumliche Autokorrelation hinweist. Während man durch einen Blick auf die drei anderen Hot-Spot-Karten auch im Stadtteil Kings statistisch signifikante Hot Spots erwarten würde, zeigt die Gi-Statistik dort keine signifikanten Cluster. Dies unterstreicht die Bedeutung des Tests auf statistische Signifikanz, denn es zeigt, dass Gebiete, in denen viele Ereignisse stattfinden und die auf den ersten Blick als Hot Spots erscheinen, nicht zwangsläufig auch statistisch signifikant sein müssen. Darüber hinaus ist diese Methode in der Lage, signifikante Cold Spots zu identifizieren. Konkret werden im nördlichen Teil von Queens eine Reihe von Cold Spots mit einem Signifikanzniveau von 90 % bis 95 % aufgezeigt und im Zentrum von Queens ein vereinzelter Cold Spot mit einem Signifikanzniveau von 90 %. Diese Art von statistisch signifikanten räumlichen Mustern lässt sich aus den Karten der anderen Methoden unmöglich erkennen, was die Stärke der Gi-Statistik abschließend noch einmal hervorhebt.

8.3 Allgemeine Bewertung von Hot-Spot-Mapping und -Policing

Der wesentliche Vorteil des Crime-Hot-Spot-Mapping besteht darin, dass es Bereiche mit hoher Kriminalitätsdichte isoliert und es Strafverfolgungsbehörden ermöglicht, Ressourcen gezielt in diesen Gebieten einzusetzen. Dies liefert den Analytiker*innen wertvolle Informationen, die möglicherweise zuvor unbekannt waren. Insbesondere in großen städtischen Gebieten, in denen Polizeidienststellen häufig unterbesetzt sind, können sich Hot-Spot-Karten als äußerst nützlich erweisen, um mit geringen Ressourcen bestmögliche Ergebnisse zu erzielen und Ressourcenverschwendungen zu minimieren. Ein weiterer Vorteil besteht darin, dass die Daten für Hot-Spot-Karten in der Regel aus der täglichen Polizeiarbeit stammen, was ihre unmittelbare Anwendbarkeit gewährleistet (Levine, 2004). Außerdem basieren diese Techniken auf systematischen Algorithmen, die eine mögliche

Voreingenommenheit der Analysten minimieren und die Karten somit objektiver machen. Dennoch erfordert die Eingabe bestimmter Parameter und die Definition von dem, was als Hot Spot gilt, eine gewisse Subjektivität. Levine (2004) beschreibt die Erstellung solcher Karten deshalb als eine Art Kunstform. Es wäre daher ratsam, Experten sowohl bei der Erstellung als auch bei der Interpretation hinzuzuziehen. Schließlich stellt die allgemeine visuelle Darstellung auf der Karte einen großen Vorteil dar, die es auch unerfahrenen Beamten*innen ermöglicht, die Verteilung der Kriminalität und deren Muster leicht erkennen und deuten zu können.

Ein großer Nachteil von Hot-Spot-Karten ist jedoch, dass sie lediglich die Konzentration von Straftaten anzeigen, dabei aber keine Rückschlüsse auf mögliche Gründe für das Auftreten an genau diesen Orten liefern. Daher ist es wichtig anzumerken, in einer umfangreichen Analyse auch stets die zugrundeliegenden Ursachen hinter bestimmten Straftaten zu ergründen. Denn eine erhöhte Konzentration könnte immer auch zufällig an bestimmten Orten entstehen. Um effektive Maßnahmen ergreifen zu können, ist es laut Chainey et al. (2008) daher ratsam, größere Zeitabschnitte zu betrachten und diese gegebenenfalls miteinander zu vergleichen. Neben polizeilichen Patrouillen könnten außerdem zusätzliche Maßnahmen wie die Einbeziehung der Bevölkerung erforderlich sein, um langfristig gegen Hot Spot Gebiete vorzugehen, beispielsweise durch die Schaffung von Arbeitsplätzen, die generelle Bekämpfung von Armut oder die Förderung von Bildung.

Obwohl zahlreiche Studien die Wirksamkeit gezielter Polizeipräsenz an Hot Spots belegen (siehe Kapitel 4.2), sollten Polizist*innen beachten, dass diese Methode nicht für alle Arten von Kriminalität gleich wirksam ist. Grove et al. (2012) stellten beispielsweise fest, dass Hot-Spot-Strategien bei der Verhinderung von Einbrüchen sehr effektiv sind, sich bei sexuellen Übergriffen jedoch als wenig erfolgreich herausstellen. Kritiker wie Rappetto (1976) werfen dieser Methode zudem vor, dass sie die Kriminalität lediglich an andere Orte verschieben würde, die nicht durch polizeiliche Maßnahmen geschützt sind (Johnson et al., 2012). Dies erscheint logisch, besonders im Hinblick auf Theorien wie die Crime-Opportunity-Theorie (siehe Kapitel 4.3.2), die besagt, dass Täter bei ihren Straftaten ihre Chancen gegen die potenziellen Risiken abwägen und dadurch in weniger bewachte Gebiete abwandern könnten, in denen potenzielle Risiken geringer sind. Dennoch betonen Forscher wie Weisburd und Braga (2006), dass vorliegende Erkenntnisse darauf hindeuten, dass die Vorteile dieser Polizeistrategie einer potenziellen Verlagerung weit überwiegen.

9. Fazit und Ausblick

In der vorliegenden Bachelorarbeit wurde das Konzept des Crime-Hot-Spot-Mapping im Rahmen des Predictive Policing und dessen Anwendung in der Strategie des Hot-Spot-Policing eingehend untersucht, wobei der Fokus auf den wichtigsten und gängigsten Methoden zur Kartierung von Hot Spots lag. In einer umfassenden Literaturrecherche wurden die Methoden hinsichtlich ihrer Vorgehensweise, Komplexität und Genauigkeit untersucht und verglichen. Durch einen praktischen Versuch in ArcGIS Pro konnten weitere Stärken und Schwächen einzelner Methoden aufgezeigt werden und ein Bild davon gemacht werden, wie ein konkreter Ablauf im Hot-Spot-Mapping in der Praxis aussehen kann.

Die Arbeit hat verdeutlicht, dass Crime-Hot-Spot-Mapping ein wertvolles Instrument zur Identifizierung von Kriminalitätsschwerpunkten darstellt. Anhand von Studien konnte gezeigt werden, dass die Identifizierung von geografischen Kriminalitätsschwerpunkten es den Polizeibehörden ermöglicht, Ressourcen effizienter einzusetzen, präventive Maßnahmen gezielter zu planen und die Anzahl an Straftaten durch präventive Maßnahmen zu reduzieren. Zudem hat sich gezeigt, dass Hot-Spot-Karten in der Regel leicht verständlich sind und sie in Polizeibehörden auf großen Zuspruch stoßen.

Darüber hinaus wurde festgestellt, dass sich die Methoden sowohl in ihrem Ansatz als auch in ihrer Komplexität deutlich unterscheiden. Während einige Methoden auf statistischen Signifikanztests, komplexen Formeln oder bestimmten Clusteringverfahren beruhen, basieren andere Methoden lediglich auf der Aggregation von Ereignissen in bestimmten Zonen.

Schließlich konnte gezeigt werden, dass die Genauigkeit dieser Methoden variiert, sowohl in der Darstellung der Hot Spots auf der Karte als auch in der Fähigkeit, genaue Hot-Spot-Gebiete zu identifizieren. Beim Praxistest war besonders interessant, dass auch einfache Kartierungsmethoden, wie die einfache Aggregation in Rastern, ohne komplexe Berechnungen eine hohe Genauigkeit aufweisen können. Jedoch wurde auch deutlich, dass statistische Methoden wie die Getis-Ord Gi Statistik einen wichtigen Schritt darstellen, um validieren zu können, dass die identifizierten Hot Spots tatsächlich statisch signifikant sind und nicht das Ergebnis einer zufälligen Häufung darstellen. Zudem hat die Fähigkeit der Identifizierung von Cold Spots die Bedeutung dieser Methode unterstrichen.

Obwohl die in dieser Arbeit vorgestellten Methoden gute Ergebnisse liefern, wäre es ratsam, dem Fortschritt der Technologie zu folgen und die Implementierung von KI-basierten Methoden im Crime-Hot-Spot-Mapping zu erwägen. Trotz der derzeitigen Herausforderungen, wie der geringen Akzeptanz bei Polizist*innen, die den Ergebnissen bisheriger KI-basierter Methoden aufgrund undurchsichtiger Analysen im Bereich des maschinellen Lernens meist skeptisch gegenüberstehen, kann der Einsatz von KI großes Potenzial mit sich bringen. Es wäre daher empfehlenswert, an der Entwicklung transparenterer und verständlicherer KI-Systeme zu arbeiten und gleichzeitig gezielte Schulungen für Polizeikräfte in diesem Bereich zu fördern. Diese Maßnahmen könnten dazu beitragen, die Effektivität und den Nutzen von Crime-Hot-Spot-Mapping weiter zu verbessern und präventive Maßnahmen noch effizienter planen zu können, um die Sicherheit und das Wohlergehen der gesamten Gesellschaft zu fördern.

10. Literaturverzeichnis

- Ahmadi, M. (2003). *Crime mapping and spatial analysis*. e International Institute for Geo-information Science and Earth Observation.
- Andresen, M. A., & Malleson, N. (2011). Testing the stability of crime patterns: Implications for theory and policy. *Journal of Research in Crime and Delinquency*, 48(1), 58-82.
- Anselin, L. (1995). Local indicators of spatial association—LISA. *Geographical analysis*, 27(2), 93-115.
- Auswählen von Features nach Attributen—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/help/mapping/navigation/select-features-using-atributes.htm>, aufgerufen am 20. April 2024
- Block, C. R. (1995). STAC hot-spot areas: A statistical tool for law enforcement decisions. In *Crime analysis through computer mapping*. Washington, DC: Police Executive Research Forum (pp. 15-32). Citeseer.
- Bivand, R. S., & Wong, D. W. (2018). Comparing implementations of global and local indicators of spatial association. *Test*, 27(3), 716-748.
- Budd, T. (2001). *Burglary: Practice messages from the British crime survey*. Great Britain, Home Office, Policing and Reducing Crime Unit.
- Burrell, J. (2016). How the machine ‘thinks’: Understanding opacity in machine learning algorithms. *Big data & society*, 3(1), 2053951715622512.
- Boba, R. (2005). Crime analysis and crime mapping. Sage Publications.
- Borough Boundaries | NYC Open Data. (o. D.). NYC Open Data.
<https://data.cityofnewyork.us/City-Government/Borough-Boundaries/tqmj-j8zm>, aufgerufen am 16. April 2023
- Braga, A. A., Hureau, D. M., & Papachristos, A. V. (2011). The relevance of micro places to citywide robbery trends: A longitudinal analysis of robbery incidents at street corners and block faces in Boston. *Journal of Research in Crime and Delinquency*, 48(1), 7-32.
- Braga, A. A., Papachristos, A. V., & Hureau, D. M. (2008). Crime Prevention Research Review. *US Department of*.
- Braga, A., Papachristos, A., & Hureau, D. (2012). Hot spots policing effects on crime. *Campbell Systematic Reviews*, 8(1), 1-96.

Brayne, S. (2020). *Predict and Surveil: Data, discretion, and the future of policing*. Oxford University Press, USA.

Chainey, S. (2005). Methods and Techniques for Understanding Crime Hot Spots. *Mapping crime: Understanding hot spots*.

Chainey, S., Tompson, L., & Uhlig, S. (2008). The Utility of Hotspot Mapping for Predicting Spatial Patterns of Crime. *Security Journal*, 21(1-2), 4–28. doi: 10.1057/palgrave.sj.8350066

Chainey, S., & Ratcliffe, J. (2013). *GIS and crime mapping*. John Wiley & Sons.

Chamard, S. (2006). The History of Crime Mapping and Its Use by American Police Departments. *Alaska Justice Forum*, 23(3), 4-8.

City of New York - NYPD shooting incident data (Year to date). (19. Januar 2024). <https://catalog.data.gov/dataset/nypd-shooting-incident-data-year-to-date>, aufgerufen am 15. April 2024

Dağlar, M., & Argun, U. (2016). Crime mapping and geographical information systems in crime analysis. *Journal of Human Sciences*, 13(1), 2208-2221.

Datenklassifizierungsmethoden—ARCGIS Pro | Dokumentation. (o. D.). <https://pro.arcgis.com/de/pro-app/latest/help/mapping/layer-properties/data-classification-methods.htm>, aufgerufen am 18. April 2024

Di Tella, R., & Schargrodsky, E. (2004). Do police reduce crime? Estimates using the allocation of police forces after a terrorist attack. *American Economic Review*, 94(1), 115-133.

Eck, J. E. (2005). Crime hot spots: What they are, why we have them, and how to map them. *Mapping crime: Understanding hot spots*, 1.

Eck, J. E., & Weisburd, D. (1995). Crime Places in Crime Theory. *Crime and Place, Crime Prevention Studies*. 4.

Egbert, S., Esposito, E., & Heimstädt, M. (2022). Vorhersagen und Entscheiden : Predictive Policing in Polizeiorganisationen. *Soziale Systeme*, 26(1-2), 189–216. doi: 10.1515/sosys-2021-0007

ERASE (Analysis)—ArCGIS Pro | Documentation. (o. D.). <https://pro.arcgis.com/en/pro-app/latest/tool-reference/analysis/erase.htm>, aufgerufen am 17. April 2024

Esposito, E. (2022). Transparency versus explanation: The role of ambiguity in legal AI. *Journal of Cross-disciplinary Research in Computational Law*, 1(2).

Feld berechnen: Python-Beispiele—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/data-management/calculate-field-examples.htm>, aufgerufen am 20. April 2024

Forrester, D., Chatterton, M., Pease, K., & Brown, R. (1988). *The Kirkholt burglary prevention project, Rochdale* (Vol. 13). London: Home Office.

Funktionsweise von “Kerndichte”—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-analyst/how-kernel-density-works.htm>, aufgerufen am 20. April 2024

Frydl, K., & Skogan, W. (Eds.). (2004). *Fairness and effectiveness in policing: The evidence*. National Academies Press.

Geometrieattribute berechnen (Datenmanagement)—ArcGIS Pro | Documentation. (o. D.-b).
<https://pro.arcgis.com/en/pro-app/latest/tool-reference/data-management/calculate-geometry-attributes.htm>, aufgerufen am 16. April 2024

Grove, L. E., Farrell, G., Farrington, D. P., & Johnson, S. D. (2012). *Preventing repeat victimization: A systematic review*. Brotsförebygganderådet/The Swedish National Council for Crime Prevention.

Harcourt, B. E. (1998). Reflecting on the subject: A critique of the social influence conception of deterrence, the broken windows theory, and order-maintenance policing New York style. *Mich. L. Rev.*, 97, 291.

Harries, K. D. (1999). *Mapping crime: Principle and practice*. US Department of Justice, Office of Justice Programs, National Institute of Justice, Crime Mapping Research Center.

How Hot Spot Analysis (Getis-Ord Gi*) works—ArcGIS Pro | Documentation. (o. D.).
<https://pro.arcgis.com/en/pro-app/3.1/tool-reference/spatial-statistics/h-how-hot-spot-analysis-getis-ord-gi-spatial-stati.htm>, aufgerufen am 16. April 2024

Incremental Spatial Autocorrelation (Spatial Statistics)—ARCGIS Pro | Documentation. (o. D.).
<https://pro.arcgis.com/en/pro-app/latest/tool-reference/spatial-statistics/incremental-spatial-autocorrelation.htm>, aufgerufen am 20. April 2024

Johnson, S. D., Guerette, R. T., & Bowers, K. J. (2012). Crime displacement and diffusion of benefits. *The Oxford handbook of crime prevention*, 337. S.337

Kannan, M., & Singh, M. (2020). *Geographical information system and crime mapping*. CRC Press.

Kerndichtevehältnis berechnen (Spatial Analyst)—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-analyst/calculate-kernel-density-ratio.htm>, aufgerufen am 13. April 2024

Kundakci, E. (2014). Identification of urban traffic accident hot spots and their characteristics by using GIS. *Master Tezi, Orta Doğu Teknik Üniversitesi, Ankara.*

Levine, N. (2004). CrimeStat III: a spatial statistics program for the analysis of crime incident locations (version 3.0). *Houston (TX): Ned Levine & Associates/Washington, DC: National Institute of Justice.*

Li, Y., Zhang, L., Yan, J., Wang, P., Hu, N., Cheng, W., & Fu, B. (2017). Mapping the hotspots and coldspots of ecosystem services in conservation priority setting. *Journal of Geographical Sciences*, 27, 681-696.

Lutters, W. G., & Ackerman, M. S. (1996). An introduction to the Chicago School of Sociology. *Interval Research Proprietary*, 2(6), 1-25.

Manepalli, U. R., Bham, G. H., & Kandada, S. (2011, September). Evaluation of hotspots identification using kernel density estimation (K) and Getis-Ord (Gi*) on I-630. In *3rd International Conference on Road Safety and Simulation* (Vol. 21, pp. 14-16). Indianapolis Indiana, United States: National Academy of Sciences.

Mark, D. M., Chrisman, N., Frank, A. U., McHaffie, P. H., & Pickles, J. (1997). The GIS History Project.

Modellierung von räumlichen Beziehungen—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-statistics/modeling-spatial-relationships.htm>, aufgerufen am 16. April 2024

Mohler, G. O., Short, M. B., Malinowski, S., Johnson, M., Tita, G. E., Bertozzi, A. L., & Brantingham, P. J. (2015). Randomized Controlled Field Trials of Predictive Policing, *Journal of the American Statistical Association*, 110:512, 1399-1411. DOI: 10.1080/01621459.2015.1077710

Netz erstellen (Data Management)—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/data-management/create-fishnet.htm>, aufgerufen am 16. April 2024

New York, NY | Data USA. (o. D.). Data USA. <https://datausa.io/profile/geo/new-york-ny>

OpenStreetMap (Light Gray Canvas). (28. März 2024).
<https://hub.arcgis.com/maps/esri::openstreetmap-light-gray-canvas-1/about>, aufgerufen am 20. April 2024

Punkte aggregieren (Standard Feature Analysis)—ArcGIS Pro | Dokumentation. (o. D.).
<https://pro.arcgis.com/de/pro-app/latest/tool-reference/feature-analysis/aggregate-points.htm>, aufgerufen am 12. April 2024

Ratcliffe, J. (2010). Crime mapping: spatial and temporal challenges. *Handbook of quantitative criminology*, 5-24.

Räumliche Kriminalanalyse. (o. D.).

https://bmi.gv.at/magazin/2022_01_02/Raeumliche_Kriminalanalyse.aspx, aufgerufen am 15. April 2024

Räumliche Verbindung (Analysis)—ARCGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/analysis/spatial-join.htm>, aufgerufen am 16. April 2024

Resampling Method (Environment setting)—ArcGIS Pro | Documentation. (o. D.).

<https://pro.arcgis.com/en/pro-app/latest/tool-reference/environment-settings/resampling-method.htm#:~:text=Cubic%E2%80%94Performs%20a%20cubic%20convolution,range%20of%20the%20input%20raster.>, aufgerufen am 20. April 2024

Povalej, R., & Volkmann, D. (2021). Predictive Policing. *Informatik-Spektrum*, 44(1), 57–61. doi:10.1007/s00287-021-01332-4

Raster berechnen (Spatial Analyst)—ArcGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-analyst/raster-calculator.htm>, aufgerufen am 20. April 2024

Raster in Polygon (Conversion)—ArCGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/conversion/raster-to-polygon.htm>, aufgerufen am 16. April 2024

Rosser, G., Davies, T., Bowers, K. J., Johnson, S. D., & Cheng, T. (2017). Predictive Crime Mapping: Arbitrary Grids or Street Networks? *Journal of Quantitative Criminology*, 33(3), 569–594. doi: 10.1007/s10940-016-9321-x

Sampson, R. J., Raudenbush, S. W., & Earls, F. (1997). Neighborhoods and violent crime: A multilevel study of collective efficacy. *science*, 277(5328), 918-924.

Santos, R. B. (2016). *Crime analysis with crime mapping*. Sage publications.

Sarnoff, L. (21. Februar 2024). 1 in 4 children in New York City are living in poverty, study says. *ABC News*.

<https://abcnews.go.com/US/1-4-children-new-york-city-living-poverty/story?id=107414019#:~:text=Overall%20the%20city's%20poverty%20rate,decade%2C%20according%20to%20the%20report.>, aufgerufen am 16. April 2024

Shariff, S. R., Maad, H. A., Halim, N. N. A., & Derasit, Z. (2018). Determining hotspots of road accidents using spatial analysis. *Indones. J. Electr. Eng. Comput. Sci*, 9(1), 146-151.

Shaw, C. R., & McKay, H. D. (2010). Juvenile delinquency and urban areas: A study of rates of delinquency in relation to differential characteristics of local communities in American cities (1969). In *Classics in environmental criminology* (pp. 103-140). Routledge.

Sherman, L. W., Gartin, P. R., & Buerger, M. E. (1989). Hot spots of predatory crime: Routine activities and the criminology of place. *Criminology*, 27(1), 27-56.

Sherman, L. W., Gartin, P. R., & Buerger, M. E. (2003). Hot Spots of Predatory Crime. *Crime: Critical Concepts in Sociology*, 2(1), 373.

Sherman, L. W. (1995). Hot spots of crime and criminal careers of places. *Crime and place*, 4(enero).

Sugomori, Yusuke., et al. *Deep Learning*. Packt Publishing, 2017.

Summenstatistik (Analysis)—ArcGIS Pro | Dokumentation. (o. D.).

[https://pro.arcgis.com/de/pro-app/latest/tool-reference/analysis/summary-statistics.htm#:~:tex](https://pro.arcgis.com/de/pro-app/latest/tool-reference/analysis/summary-statistics.htm#:~:text=SUM%3A%20Die%20Werte%20f%C3%BCr%20das,des%20angegebenen%20Feldes%20wird%20ermittelt.,)t=SUM%3A%20Die%20Werte%20f%C3%BCr%20das,des%20angegebenen%20Feldes%20wird%20ermittelt., aufgerufen am 17. April 2024

Taylor, R. (2000). Breaking Away from Broken Windows: Baltimore Neighborhoods and the Nationwide Fight Against Crime, Grime, Fear, and Decline. Boulder, CO: Westview Press.

Trotta, M., Kazprzyk, J. P., & Donnay, J. P. (2013). Crime mapping and modelling. *Bulletin de la Société Géographique de Liège*, 60.

Überschneiden (Intersect) - ArcGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/analysis/intersect.htm>, aufgerufen am 14. April 2024

US Census Bureau. (8. Oktober 2021). Cartographic Boundary Files - Shapefile. Census.gov. <https://www.census.gov/geographies/mapping-files/time-series/geo/carto-boundary-file.html>, aufgerufen am 20. April 2024

Verbindung hinzufügen (Data Management)—ArcGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/data-management/add-join.htm>, aufgerufen am 22. April 2024

Wang, D., Ding, W., Lo, H., Stepinski, T., Salazar, J., & Morabito, M. (2013). Crime hotspot mapping using the crime related factors—a spatial data mining approach. *Applied Intelligence* (Dordrecht, Netherlands), 39(4), 772–781. doi: 10.1007/s10489-012-0400-x

Warum Hexagone?—ArCGIS Pro | Dokumentation. (o. D.).

<https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-statistics/h-whyhexagons.htm>,
aufgerufen am 20. April 2024

Was ist ein Z-Wert? Was ist ein p-Wert?—ArcGIS Pro | Dokumentation. (o. D.).

https://pro.arcgis.com/de/pro-app/latest/tool-reference/spatial-statistics/what-is-a-z-score-what-is-a-p-value.htm#ESRI_SECTION1_2C5DFC8106F84F988982CABAEDBF1440,
aufgerufen am 20. April 2024

Weisburd, D., & Braga, A. A. (2006). Hot spots policing as a model for police innovation. *Police innovation: Contrasting perspectives*, 225-244.

Weisburd, D., & Green, L. (1994). Defining the drug market: The case of the Jersey City DMA system. *Drugs and crime: Evaluating public policy initiatives*, 61-76.

Weisburd, D., & Lum, C. (2005). The diffusion of computerized crime mapping in policing: Linking research and practice. *Police practice and research*, 6(5), 419-434.

Weisburd, D., & McEwen, T. (2015). Crime mapping and crime prevention.

White, V. M., Hunt, J., & Green, B. (2023). A discussion of current crime forecasting indices and an improvement to the prediction efficiency index for applications. Security Journal. doi: 10.1057/s41284-023-00367-4

Wilson, J. Q., & Kelling, G. L. (1982). Broken windows. *Atlantic monthly*, 249(3), 29-38.

11. Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die vorliegende Bachelorarbeit selbstständig und ohne Benutzung anderer als der angegebenen Hilfsmittel und Quellen angefertigt habe. Alle Stellen, die wörtlich oder inhaltlich den angegebenen Quellen entnommen wurden, sind als solche kenntlich gemacht. Die vorliegende Arbeit wurde bisher weder im Inland noch im Ausland in gleicher oder ähnlicher Form als Prüfungsarbeit eingereicht.

A handwritten signature in black ink, appearing to read "E. Bink".

Wien, am 29.04.2024